人工智能中的意识：来自意识科学的洞见

帕特里克·巴特林*　罗伯特·朗*　埃里克·埃尔莫兹尼诺

约书亚·本吉奥　乔纳森·伯奇　阿克塞尔·康斯坦特

乔治·迪恩　斯蒂芬·M·弗莱明　克里斯·弗里斯

徐吉　良太·金井　科林·克莱因

格蕾丝·林赛　马蒂亚斯·米歇尔　利亚德·穆德里克

梅根·A·K·彼得斯　埃里克·施维茨格贝尔　乔纳森·西蒙

鲁芬·范鲁伦

摘要

当前或近期的人工智能系统是否可能具备意识，这一话题既引起了科学界的浓厚兴趣，也日益引发公众的广泛关注。本报告主张并举例说明了一种严谨且基于实证的研究方法，用于探讨人工智能的意识问题：即依据我们目前所掌握的、最具说服力的神经科学意识理论，对现有的人工智能系统进行细致评估。我们综述了几种颇具影响力的意识科学理论，包括循环处理理论、全局工作空间理论、高阶理论、预测加工理论以及注意力模式理论。从这些理论中，我们提炼出意识的“指标属性”，并以计算化的形式加以阐释，从而能够针对这些属性对人工智能系统展开评估。我们运用这些指标属性，对若干近期的人工智能系统进行了评估，并探讨了未来人工智能系统如何实现这些指标属性。我们的分析表明，目前尚无任何人工智能系统具备意识，但同时也指出，构建满足这些指标属性的人工智能系统在技术上并无明显障碍。1

* 共同第一作者与通讯作者（patrickbutlin@gmail.com，rgblong@gmail.com）1 此句先前版本为“……但也表明，构建具有意识的人工智能系统并不存在明显障碍。”我们已对此进行修订，以更准确地体现报告的核心信息：满足这些指标或许是可行的。但即便满足了这些指标，也并不意味着该人工智能系统就一定具备意识。

作者

帕特里克·巴特林*，牛津大学人类未来研究所

罗伯特·朗*，人工智能安全中心

埃里克·埃尔莫兹尼诺，蒙特利尔大学与魁北克人工智能研究所MILA

约书亚·本吉奥，蒙特利尔大学与魁北克人工智能研究所MILA

乔纳森·伯奇，伦敦政治经济学院自然与社会科学哲学中心

阿克塞尔·康斯坦特，萨塞克斯大学工程与信息学院及蒙特利尔大学伦理研究中心

乔治·迪恩，蒙特利尔大学哲学系

斯蒂芬·M·弗莱明，伦敦大学学院实验心理学系及威康人类神经影像中心

克里斯·弗里斯，伦敦大学学院惠康人类神经影像中心与伦敦大学哲学研究所

徐吉，蒙特利尔大学与魁北克人工智能研究所MILA

梁田亮太，阿拉亚公司

科林·克莱因，澳大利亚国立大学哲学学院

格蕾丝·林赛， 心理学系与数据科学中心，新 约克大学

马蒂亚斯·米歇尔，纽约大学心智、大脑与意识研究中心

利亚德·穆德里克，特拉维夫大学心理科学学院与萨戈尔神经科学学院，以及脑、心智与意识CIFAR项目

梅根·A·K·彼得斯，加州大学欧文分校认知科学系及脑、心智与意识CI-FAR项目

埃里克·施维茨格贝尔，加州大学河滨分校哲学系

乔纳森·西蒙，蒙特利尔大学哲学系

鲁芬·范鲁伦，法国国家科学研究中心脑与认知研究中心，图卢兹大学

详情

作者声明: PB和RL为共同第一作者。PB和RL共同规划并协调了该项目，提出了核心思路。PB起草了报告的大部分内容，RL作出了重要贡献。EE撰写了第3.1.2节和第3.1.3节的初稿，GD撰写了第4.1.2节的初稿，GL则撰写了关于注意力的框注。所有作者均参加了研讨会，在研讨会上我们共同规划了报告内容、构思了相关理念并审阅了各稿。除PB、RL和EE之外的其他作者按字母顺序排列。

致谢： 作者谨向以下人士表示感谢：尼克·博斯特罗姆，他向PB和RL提出了该项目构想，并在项目初期作出了重要贡献；蒂姆·贝恩、马特·博特维尼克、大卫·查尔默斯、哈克万·劳、马特·麦吉尔和穆瑞·沙纳汉，他们参加了研讨会或参与了其他讨论，为报告的撰写提供了宝贵意见；桑德·巴尔维特，她在项目最后阶段担任研究助理，给予了大力协助；以及查理·汤普森，他在图形设计和排版方面提供了重要帮助。

资金：

- RL和PB为该报告举办了研讨会，这些研讨会得到了有效投资和EA长期未来基金的支持。
- EE得到了魁北克省研究基金会战略集群计划（UNIQUE中心）以及范尼尔加拿大博士生奖学金的支持。
- 该研究得到了欧洲研究理事会资助（XSCAPE）ERC-2020-SyG 951631的支持。
- YB、AC、GD 和 JS 获得了开放慈善组织的资助。
- JS获得了魁北克研究基金会的资助以及加拿大社会科学与人文研究理事会的资助。
- MM得到了坦普尔顿世界慈善基金会的支持，作为“分析与融合意识理论”资助项目的一部分，该资助项目由纽约大学心智、大脑与意识研究中心实施。
- SMF得到了惠康基金会/皇家学会亨利·戴尔爵士 fellowship（206648/Z/17/Z）的支持。
- SMF、LM 和 MAKP 得到了CIFAR大脑、心智与意识项目奖学金的支持。
- XJ得到了IVADO的支持。
- CK获得了坦普尔顿世界慈善基金会的资助，资助编号为TWCF-2020-20539。

作者们无利益冲突需要报告。

执行摘要

人工智能系统是否具备意识这一问题正日益紧迫。人工智能领域的进展迅猛惊人，顶尖研究人员正从人类大脑中与意识相关的一些功能中汲取灵感，以进一步提升人工智能的能力。与此同时，能够逼真地模仿人类对话的人工智能系统的兴起，很可能会使许多人误以为自己所交互的这些系统具有意识。在本报告中，我们主张，评估人工智能中的意识最好借鉴神经科学关于意识的理论。我们介绍了此类颇具代表性的理论，并探讨了它们对人工智能的启示。

我们认为本报告的主要贡献在于：

1. 这表明，对人工智能中意识的评估在科学上是可行的，因为意识本身可以进行科学研究，而这些研究发现也适用于人工智能；

2. 提出一种评估人工智能意识的评分标准，其形式为基于科学理论提炼出的一系列指标属性清单；
3. 提供了初步证据，表明许多指标属性可利用当前技术在人工智能系统中实现，尽管目前尚无任何现有系统堪称具备意识的有力候选者。

我们提出的这一框架是暂定的，因为我们预计随着研究的深入，所纳入的指标属性清单可能会发生变化。

我们在人工智能中研究意识的方法有三大核心原则。首先，我们采用计算功能主义——即认为执行恰当类型的计算是意识的充分且必要条件——作为一项工作假设。这一假说在心灵哲学领域属于主流观点，尽管也存在争议。我们之所以采纳这一假设，是出于实用考量：与各种竞争性观点不同，它表明从原则上讲，人工智能具备产生意识的可能性；同时，研究人工智能系统的运作机制对于判断它们是否可能具备意识具有重要意义。这意味着，如果计算功能主义为真，那么探讨其对人工智能意识的启示将富有成效。其次，我们认为，有关意识的神经科学理论获得了有意义的实证支持，能够帮助我们评估人工智能中的意识状态。这些理论旨在识别那些对人类意识而言既必要又充分的功能；而计算功能主义则暗示，类似的功能同样足以支撑人工智能的意识。第三，我们主张，一种理论导向型的研究方法最适合于探究人工智能中的意识问题。具体而言，就是考察人工智能系统是否执行着与科学理论所认定的、与意识密切相关的功能，然后根据以下因素来确定相应的置信度：(a) 功能之间的相似程度；(b) 相关理论所获证据的强度；以及(c) 个人对计算功能主义的信念程度。与此方法相对立的主要替代方案是采用行为测试来判定意识，但这种方法并不可靠，因为人工智能系统可以被训练成模仿人类行为，而其内在运作方式却截然不同。

目前，各种理论都是意识科学领域中的热门候选者，因此我们在此并不支持任何单一理论。相反，我们基于对意识理论的调研，提炼出了一组指标属性。据称，这些指标属性中的每一项对于意识而言都是必要的

根据一种或多种理论，某些子集被称作共同充分。然而，我们的主张是：具备更多指标属性的人工智能系统更有可能具有意识。要判断一个现有或拟议的人工智能系统是否是具备真正意识的有力候选者，就应当评估该系统是否已具备或可能具备这些属性。

我们所探讨的科学理论包括重复加工理论、全局工作空间理论、计算型高阶理论等。我们不考虑整合信息理论，因为它与计算功能主义并不相容。此外，我们还探讨了主体性和具身性作为指示性属性的可能性，尽管这些属性必须从其所蕴含的计算特征这一角度来理解。由此得出以下指示性属性列表：

重复加工理论
RPT-1：使用算法递归的输入模块 RPT-2：生成有组织、整合的感知表征的输入模块
全局工作空间理论
GWT-1：多个可并行运行的专用系统（模块） GWT-2：容量有限的工作空间，导致信息流出现瓶颈，并引发选择性注意机制
GWT-3：全局广播：工作区信息对所有模块的可用性
GWT-4：状态依赖性注意，使系统能够利用工作空间依次查询各个模块，从而完成复杂任务。
计算高阶理论
HOT-1：生成式、自上而下或噪声感知模块 HOT-2：元认知监控，用于区分可靠的感知表征与噪声
热门-3：由一种通用的信念形成与行动选择系统引导的智能体，以及一种强烈倾向于根据输出结果更新信念的倾向。 元认知监控
热门-4：稀疏且平滑的编码生成“质量空间”
注意模式理论
AST-1：一种预测模型，用于表征并实现对当前注意力状态的控制。
预测性处理
PP-1：使用预测编码的输入模块
代理与体现
AE-1：机构：从反馈中学习，并选择输出以实现目标，尤其是在需要灵活应对相互竞争的目标时。
AE-2：实现：建模输出与输入之间的偶发关系，包括一些系统性效应，并在感知或控制中使用该模型。

表1：指标属性

我们在报告第2节中概述了这些属性所依据的理论，并阐述了支持这些理论的证据与论据，同时对表格中所采用的表述方式进行说明。

在制定了这份指标属性清单后，我们在第3.1节中讨论了如何利用这些指标属性构建或已构建的AI系统。在大多数情况下，可以采用标准的机器学习方法来构建具备该清单中单个属性的系统，尽管仍需通过实验来掌握如何构建和训练能够综合运用多种属性的功能性系统。清单中有些属性已有明确的现有AI系统满足（例如RPT-1、算法递归），而另一些属性则尚存争议（例如AE-1的第一部分、主体性）。研究人员还针对一些特定的意识理论设计并试验了相关系统，包括全局工作空间理论和注意模式理论。

在第3.2节中，我们探讨了一些现有的特定人工智能系统是否具备这些指标属性。其中包括基于Transformer的大型语言模型和Perceiver架构，我们针对全局工作空间理论对它们进行了分析。我们还分析了DeepMind的自适应智能体，这是一种在三维虚拟环境中运行的强化学习智能体；一个通过控制虚拟啮齿动物身体来完成任务的训练系统；以及被描述为“具身多模态语言模型”的PaLM-E。我们以这三种系统作为案例研究，用以说明有关代理性和具身性的指标属性。本研究并不表明任何现有的人工智能系统都是具有意识的有力候选者。

本报告远未就这些议题给出最终结论。我们强烈建议支持对意识科学及其在人工智能领域应用的进一步研究。我们还建议紧急考虑构建具有意识的人工智能系统的道德和社会风险，这一主题我们并未在本报告中涉及。我们所考察的证据表明，如果计算功能主义为真，那么在不久的将来，具备意识的人工智能系统完全有可能被实际构建出来。

内容

1 简介 9

1.1 术语 9

1.2 方法与假设 11 1.2.1

计算功能主义 13

1.2.2 意识的科学理论..... 14

1.2.3 理论导向的方法..... 17

2 意识的科学理论 19

2.1 递归处理理论 19 2.1.1

递归处理理论简介 19

2.1.2 重复加工理论的证据.....20

2.1.3 来自递归处理理论的指标.....21

2.2 全局工作区理论 22 2.2.1

全局工作区理论简介.....22

2.2.2 全局工作空间理论的证据.....24

2.2.3 来自全局工作区理论的指标.....25

2.3 高阶理论 29 2.3.1

高阶理论导论 29

2.3.2 计算HOTs和GWT.....30

2.3.3 来自计算性高阶思维的指标.....31

2.4 其他理论和条件 33 2.4.1

注意模式理论..... 33

2.4.2 预测处理 34

2.4.3 中脑理论 35

2.4.4 无限联想学习 35

2.4.5 代理与体现 . . . . . 37 2.4.5(a)

机构 37

2.4.5(b) 实施例 40

2.4.5(c) 代理和体现指标.....43

2.4.6 时间与重复 44

2.5 意识指标 45

3 人工智能中的意识 47

3.1 在人工智能中实现指标属性……48

3.1.1 实施 RPT 和 PP…… …… …… …… …… …… …… 48

3.1.2 实现 GWT 49

3.1.3 实施PRM…… …… …… …… …… …… …… …… 51

3.1.4 实现 AST 55

3.1.5 实施机构与体现……56

3.2 当前系统的案例研究 58

3.2.1 GWT 的案例研究 58

3.2.2 具身智能的案例研究……60

4 含义 64

4.1将意识归因于人工智能……64 4.1.1 对人工智能的意识归因不足……64 4.1.2 对人工智能的意识归因过度……65 4.2 意识与能力……66 4.3 建议……68

术语表 71

1 简介

在过去十年中，人工智能（AI）领域取得的显著进展重新激发了人们对人工智能长期存在的深刻问题的兴趣，其中包括人工智能系统是否可能具有意识这一问题。本报告旨在探讨当前及近期人工智能系统中支持与反对意识存在的最佳科学证据。

由于意识在哲学上令人困惑，难以定义，也难以通过实证方法进行研究，因此专家们对意识——尤其是对人工智能系统的意识——的看法差异极大。然而，我们相信，尽管存在这种分歧，我们仍有可能在人工智能意识这一课题上取得进展。目前有一些关于意识的科学理论获得了强有力的实证支持，并且与各种有关意识形而上学的观点相兼容。尽管这些理论主要基于对人类的研究，但它们所提出的与意识相关的属性和功能同样适用于人工智能系统。我们认为，利用这些理论为我们提供的工具，是当前评估人工智能系统是否可能具有意识的最佳方法。在本报告中，我们将详细阐释这一方法，识别前沿科学理论所提供的工具，并展示如何运用这些工具。

我们发布这份报告的部分原因在于，我们认真对待这样一种可能性：有朝一日，我们可能在相对较近的未来——也就是未来几十年内——构建出具有意识的人工智能系统。此外，无论短期内具备意识的人工智能是否真的可行，基于大型语言模型的系统日益普及，这些系统能够模仿人类对话，很可能会让许多人误以为某些人工智能系统已经具备了意识。这些前景引发了深刻的道德和社会问题，不仅关乎整个社会，也关乎与人工智能系统互动的人们，以及开发和部署人工智能系统的公司和个人。如果我们能更深入地了解意识的科学及其对人工智能的影响，人类将更有准备去应对这些变革。我们的目标是通过提供一种主流的、跨学科的视角，促进对这些问题的理解，这种视角将阐明有关人工智能意识的问题在多大程度上是可以用科学方法加以研究的，并为未来的相关研究奠定基础。

在本节的其余部分，我们概述了本报告所依据的术语、方法和假设。

1.1 术语

在本报告中，“有意识”指的是什么？说一个人、动物或人工智能系统是有意识的，意味着他们当前正在经历一种有意识的体验，或者他们具备产生有意识体验的能力。我们用“意识”及其相关术语来指代有时被称为“现象学意识”的东西（Block 1995）。在我们的术语中，“意识”的另一个同义词是“主观体验”。因此，本报告探讨的是人工智能系统是否可能具有现象学意识，换句话说，它们是否可能具备有意识或主观体验的能力。

说一个人、动物或人工智能系统具有（现象学的）意识体验，这意味着什么？一种有益的表述方式是：当一个系统作为该体验的主体时，它“有某种感受”——这就是所谓的意识体验（纳格尔）。

1974). 然而，除此之外，很难用一个同义词或表达来定义“有意识的体验”或“意识”，因此我们更倾向于通过举例来说明我们如何使用这些术语。根据施维茨盖贝尔（2016）的观点，我们将同时提及正面和负面的例子——即，既有属于有意识体验的认知过程的例子，也有不属于有意识体验的例子。所谓“意识”，指的是最明显地将正面和负面例子区分开来的现象。

许多最清晰的、关于意识体验的正面例子都涉及我们感知自身身体和周围世界的能力。如果你正在屏幕上阅读这份报告，那么你就是在对屏幕进行有意识的视觉体验。我们也有有意识的听觉体验，比如听到鸟鸣声，以及其他感官模式下的有意识体验。能够被意识到的身体感觉包括疼痛和瘙痒。除了这些对真实、当下事件的体验之外，我们还有对意象的有意识体验，比如想象所爱之人的脸庞。

此外，我们还有诸如恐惧和兴奋之类的有意识情绪。但关于情感体验是否仅仅是一种身体体验——比如起鸡皮疙瘩的感觉——这一点尚存争议。对于思想和欲望的体验，也存在分歧（Bayne & Montague 2011）。我们有可能有意识地思考该看什么电视节目，但一些哲学家认为，其中涉及的有意识体验纯粹是感官或意象性的，例如想象观看一档游戏节目的感觉；而另一些哲学家则认为，我们拥有“认知性”的有意识体验，这种体验具有一种独特的现象学特征1，专门与思想相关。

至于负面例子，大脑中存在着许多过程，包括一些极为复杂的信息处理，而这些过程完全是无意识的。一个例子是激素释放的调节，大脑在完全无意识的情况下就能完成这一过程。另一个例子是记忆存储：你或许能记得自己成长的那所房子的地址，但大多数时候，这并不会对你的意识产生任何影响。此外，各种感官的感知都涉及大量的无意识加工，比如，当有人对你说话时，从听觉刺激流中提取出有意识体验所需的加工过程便是如此。最后，大多数视觉科学家都认同，受试者会无意识地加工那些通过各种心理物理技术变得不可见的视觉刺激。例如，在“掩蔽”实验中，一种刺激会在屏幕上短暂闪现，随后迅速紧接着出现第二种刺激，即所谓的“掩蔽刺激”（Breitmeyer & Ogmen 2006）。尽管第一种刺激并未产生任何有意识的体验，但它的某些特性却会影响后续任务的表现，比如通过“启动效应”使受试者更快地识别出某种事物（例如，Vorberg et al. 2003）。

在使用“现象意识”这一术语时，我们意在根据布洛克（1995，2002）的观点，将我们的主题与“可及意识”区分开来。布洛克写道：“如果一种状态能够被自由地用于推理，并直接用于对行为的‘理性’控制（包括报告），那么它就是[可及意识]状态”（2002，第208页）。似乎，在我们的意义上，一种心理状态具有意识，与其内容能够被我们向他人报告或用于做出理性选择之间存在着密切联系。例如，如果我们对某个短暂呈现的视觉刺激有过意识体验，我们理应能够报告自己看到了它；而如果缺乏这种意识体验，我们就无法报告自己看到了它。

1 意识体验的“现象学”或“现象特征”就是主体所具有的那种感觉。按照我们的术语，所有且仅所有意识体验都具有现象特征。

如果不是这样，情况就不同了。然而，这两种心理状态的性质在概念上是不同的。现象意识与可及意识之间的关系仍是一个悬而未决的问题。

最后，术语“sentient”有时可与（现象学上的）“conscious”互换使用，但我们更倾向于使用“conscious”。“sentient”有时指具有感官，例如视觉或嗅觉。然而，拥有意识并不等同于拥有感官。一个系统有可能感知自身或环境，却没有任何意识体验；同样，一个系统也可能拥有意识，却并不感知自身或环境。“sentient”有时也指能够拥有诸如愉悦或痛苦之类的意识体验——这些体验会让人感到好或坏——但我们并不想暗示，拥有意识的系统就必须具备这些能力。即使一个系统只拥有“中性”的意识体验，它依然可以按照我们的定义拥有意识。愉悦和痛苦固然重要，但它们并非我们在此讨论的重点。2

1.2 方法与假设

我们研究当前或近期人工智能系统是否可能具有意识的方法基于三个假设。它们是：

1. 计算功能主义： 实现某种类型的计算是意识的必要且充分条件，因此原则上非有机的人工系统也有可能具备意识。

2. 科学理论: 神经科学研究在表征与意识相关且可能是意识的必要或充分条件的功能方面取得了进展；这些功能由意识的科学理论加以描述。

3. 以理论为导向的方法： 一种特别有前景的方法，用于研究人工智能系统是否可能具有意识，就是评估它们是否满足源自科学理论的功能或架构条件，而不是寻找与理论无关的行为特征。

这些思想以不同的方式指导着我们的研究。我们采用计算功能主义作为一项工作假设，因为这一假设使得得出推论相对简单。

2 为进一步说明，这里是一些关于现象意识的其他定义：

查尔默斯（1996）：“当我们思考和感知时，既有信息处理的嗡嗡声，也存在主观层面。正如纳格尔（1974）所言，作为有意识的有机体， 体验某种 感受。这种主观层面就是体验。例如，当我们看见时，我们 会体验 视觉感受：红色的质感、明暗的体验，以及视场中深度的特质。其他体验则伴随不同感官的感知而出现：单簧管的声音、樟脑丸的气味。此外还有身体感觉，从疼痛到性高潮；内在浮现的心理图像；情感的质感，以及意识思维流的体验。将所有这些状态统一起来的是：身处其中时，总有一种 感受。

格拉齐亚诺（2017）：“你可以将一台计算机连接到相机，并对其进行编程，以处理视觉信息——颜色、形状、大小等等。人脑也做着同样的事情，但除此之外，我们还会报告对这些视觉属性的主观体验。这种主观体验并不总是存在。大量的视觉信息进入眼睛，被大脑处理，甚至通过启动效应影响我们的行为，却从未进入意识层面。在视野角落快速闪过一抹绿色，然后请人们说出他们脑海中浮现的第一种颜色，他们很可能不假思索地回答‘绿色’，甚至不知道为什么。然而，在某些时候，我们也会声称：‘我有主观的视觉体验。我用我的意识看到了那个东西。看到的感觉就像某种东西一样。’”

从神经科学的意识理论到关于人工智能的主张。该领域的部分研究者反对计算功能主义（例如，塞尔1980年，托诺尼与科赫2015年），但我们的观点是，值得探讨其潜在含义。我们认可一些意识科学理论的相关性和价值，因为它们描述了可在人工智能中实现的功能，而且我们认为这些理论得到了良好的实验证据支持。此外，我们的观点是，尽管在其他情况下可能并非如此，但对于人工智能而言，采用理论导向的方法是必要的。所谓理论导向的方法，是指专注于系统的工作原理，而非关注它们是否表现出可能被视为有意识生物特性的外在行为形式（伯奇2022b）。我们在本节中将更详细地阐释这三种观点。

在继续之前，关于我们的方法和假设，还有两点值得注意。第一点是，为方便起见，我们通常会假定系统的意识与否是一个非此即彼的问题，并且对此问题总存在一个确定的事实（尽管在许多情况下，这一事实可能难以获知）。然而，我们也愿意接受这样一种可能性：即系统可能只是部分地具有意识，或者仅在某种程度上具有意识，又或者既不能确定地具有意识，也不能确定地不具有意识（参见方框1）。

方框1：确定性、度量、维度

在本报告中，我们通常将意识视为一种非此即彼的问题：一个系统要么有意识，要么没有。然而，实际上存在多种其他可能性。似乎有许多属性的边界是“模糊”的，也就是说，某个对象是否具有该属性可能是不确定的。例如，一件衬衫的颜色可能处于黄色与绿色之间的某个临界点上，以至于根本无法确定它究竟是黄色还是非黄色。从原则上讲，意识也可能具有这种特性：可能存在一些生物，它们既不是确定地有意识，也不是确定地无意识（西蒙 2017，施维茨格贝尔即将出版）。如果真是如此，一些人工智能系统就可能处于这种“模糊”状态。这种不确定性无疑源于关于意识的唯物主义观点（伯奇 2022a）。

另一种可能性是，意识可能存在不同程度，因此一个系统有可能比另一个系统更具意识（李，2022）。在这种情况下，或许有可能构建出具备意识但仅具极低程度的AI系统，甚至可能构建出意识程度远高于人类的系统（舒尔曼与博斯特罗姆，2021）。或者，与其采用单一尺度，意识或许会沿多个维度而变化（伯奇等人，2020）。

最后，可能存在多种意识要素。这些要素并非意识某种进一步属性的必要条件，而是构成意识的组成部分。这些要素在人类中通常共同出现，但在其他动物或人工智能系统中则可分离。在这种情况下，一个系统有可能部分具备意识，即拥有其中一些要素。

第二，我们建议从置信度或确信度的角度来思考人工智能中的意识问题。目前，关于这一主题的不确定性是不可避免的，但仍然有充分的理由认为，某个系统比另一个系统更有可能具备意识，而这对于我们的行为方式可能具有重要意义。因此，思考自己对相关主张的置信度是有益的。

区域。例如，人们可能会认为，对一组理论主张的合取具有约0.5的置信度是合理的，这些理论主张意味着给定的AI系统是有意识的；如果是这样，那么人们也应同样相信该系统是有意识的。

1.2.1 计算功能主义

关于意识的计算功能主义是一种关于与意识相关联的系统属性类型的主张。根据关于意识的功能主义，一个系统要具备意识，既必要又充分的条件是它具有某种功能组织：也就是说，它能够进入一系列特定的状态，这些状态彼此之间以及与环境之间存在某些因果关系。计算功能主义是功能主义的一种版本，它进一步主张，相关的功能组织是计算性的。3

执行计算的系统通过实现算法来处理信息；计算功能主义认为，只要一个状态在实现恰当类型的算法时发挥了恰当的作用，它就足以具备意识。一个系统要实现特定算法，意味着它在某一抽象层次上具有一组特征：具体而言，就是一系列可能承载信息的状态，以及在这些状态之间进行转换的特定倾向。系统所实现的算法是对状态间转换的抽象描述，包括输入和输出，而系统正是按照这种描述进行转换的。例如，一台袖珍计算器之所以实现了特定的算术算法，是因为它通过经历一系列内部状态，将按键操作转化为屏幕上的结果。

因此，计算功能主义的一个重要结论是：一个系统是否具有意识，取决于比其物理构成的最低层次细节更为抽象的特征。系统的物质基础本身对意识并无影响，除非这种基础会影响系统能够实现哪些算法。这意味着，从原则上讲，意识是可以多重实现的：它可以在多种不同的基质中存在，而不仅仅局限于生物大脑。不过，计算功能主义并不意味着任何基质都能用来构建一个有意识的系统（布洛克，1996）。正如米歇尔和劳（2021）所言：“瑞士奶酪无法实现相关的计算。”我们暂且假设，我们所熟知的计算机原则上能够实现足以产生意识的算法，但我们并不声称这一点是确定无疑的。

同样值得注意的是，计算相同数学函数的系统可能采用不同的算法来实现，因此计算功能主义并不意味着，在输入-输出函数相同的意义上“做同样事情”的系统在意识上必然相似（Sprevak 2007）。此外，根据计算功能主义的观点，意识可能取决于对具有特定表征格式的状态执行操作，例如模拟表征（Block 2023）。从马尔（1982）的分析层次来看，这一观点认为，意识取决于系统中正在发生的事情。

3 计算功能主义与关于意识与实现计算的物理状态之间关系的各种观点相容。特别是，它既与以下观点相容：(i) 一个状态具有意识这一事实，不过就是它在实现计算中扮演着某种特定角色；也与以下观点相容：(ii) 一个状态具有意识，仅仅是因为它拥有独特的现象学属性，而其在实现计算中的角色对此已足够。

算法和表示层面，而非实现层面，或更抽象的“计算”（输入-输出）层面。

我们采用计算功能主义作为工作假设，主要是出于实用主义的考虑。大多数关于意识的前沿科学理论都可以用计算的方式加以解释——也就是说，这些理论都提出了有关计算特征的主张，而这些特征对于人类的意识而言是必要或充分的。如果计算功能主义为真，并且这些理论是正确的，那么这些特征对于人工智能系统的意识而言也将是必要或充分的。人类与人工智能系统之间的非计算差异将无关紧要。因此，计算功能主义这一假设使我们能够从计算科学理论中推导出关于人工智能意识可能条件的结论。另一方面，如果计算功能主义为假，就无法保证那些与人类意识相关的计算特征也能很好地指示人工智能的意识状态。例如，有可能是生物体的某种非计算特征才是意识所必需的（塞爾 1980，塞思 2021），在这种情况下，非有机的人工系统便不可能具备意识。

话虽如此，如果这一论点不够可信，那么在计算功能主义假设下研究人工意识就毫无意义。尽管我们对计算功能主义的信服程度各不相同，但我们一致认为它具有一定的可信度。4 这些不同的信服程度会影响我们个人对特定人工智能系统是否具备意识的判断，以及对具备意识的人工智能究竟是否可能实现的评估。

1.2.2 意识的科学理论

指导我们方法的第二个理念是，一些关于意识的科学理论得到了大量实证证据的支持，并提出了能够帮助我们评估人工智能系统是否具备意识的主张。这些理论经过数十年高质量神经科学研究的开发、检验和改进（有关最新综述，请参阅Seth & Bayne 2022，Yaron et al. 2022）。如果我们根本不知道哪些计算功能是重要的，那么仅仅假设计算功能足以构成意识，将难以取得实质性进展；但这些理论为我们提供了宝贵的线索。

意识的科学理论与意识的形而上学理论不同。意识的形而上学理论从最一般的意义上探讨意识与物质世界的关系。意识形而上学中的立场包括属性二元论（Chalmers 1996, 2002）、泛心论（Strawson 2006, Goff 2017）、唯物论（Tye 1995, Papineau 2002）和幻觉论（Frankish 2016）。例如，唯物论主张现象属性就是物理属性，而属性二元论则否认这一点。相比之下，意识的科学理论则着眼于哪些具体的物质现象——通常是大脑过程——与意识相关联。一些理论明确旨在确定意识状态的神经关联，即被定义为足以共同产生这些状态的最小神经事件集合（Crick & Koch 1990, Chalmers 2000）。意识科学理论的核心问题是：什么区分了产生意识体验的情形与不产生意识体验的情形？

4 一个有影响力的论点来自查尔莫斯（1995）：如果一个人的神经元逐渐被功能等效的人工假体所取代，他们的行为将保持不变，因此他们不太可能在意识体验上发生任何根本性的变化（如果真的发生了，他们表现出来的行为就好像根本没有注意到一样）。

那些不包含这种情况的，尽管这并非此类理论可能解决的唯一问题，但却是本报告的重点。

我们在第2节中详细讨论了几个具体的科学理论。在此，我们简要概述了意识科学的方法，以表明意识是可以进行科学研究的。

对意识的科学研究依赖于关于意识与行为之间联系的假设（Irvine 2013）。例如，在一项关于视觉的研究中，实验者可能会以某种方式操纵视觉刺激（如一个红色三角形）——比如以两种不同的速度闪烁它。如果他们发现受试者在一种条件下报告看到了该刺激，而在另一种条件下则没有，他们可能会认为受试者在一种条件下对该刺激有意识的视觉体验，而在另一种条件下则没有。随后，他们可以测量这两种条件下的脑活动差异，并据此推断脑活动与意识之间的关系——这种方法被称为“对比分析”（Baars 1988）。这种方法依赖于这样一个假设：受试者的报告能够很好地反映他们的意识体验。

作为一种研究人类及其他动物意识的方法，依赖于被试报告存在两个主要问题。第一个问题是，对于意识体验、报告以及可能参与报告的认知过程（如注意和记忆）之间的关系尚不确定。由于报告或可报告性需要比意识体验更多的加工处理，因此依赖报告的研究可能会产生误导：那些参与刺激加工和报告生成但并非意识所必需的脑部过程，可能被错误地认定为意识的神经相关物（Aru等，2012）。另一种可能性是，现象意识本身具有相对丰富的内涵，其中只有一部分内容会被注意选择出来进行进一步加工，从而获得认知访问，而这种认知访问反过来又是产生报告所必需的。在这种情况下，依赖报告可能会导致我们误将访问的神经基础当作现象意识的基础（Block，1995；2007）。这里的方法学问题可以说更为严重，因为目前尚不清楚现象意识是否真的会以这种方式“溢出”认知访问——研究人员对此持有截然不同的观点（Phillips，2018a）。

针对这一问题的部分解决方案可能是采用“无报告范式”，即在实验中使用除报告以外的其他意识指标，并已在单独的实验中经过校准，以确定其与意识状态的相关性——这些单独的实验确实采用了报告方式（Tsuchiya 等，2015）。这种范式的优点在于，受试者无需在主实验中进行报告，这或许能缓解报告混淆的问题。尽管无报告范式并非解决这一问题的“灵丹妙药”（Block 2019，Michel & Morales 2020），但它们或许是朝着解决这一问题迈出的重要一步。

另一种可能的意识测量方法是使用元认知判断，例如信心评分（例如，Peters & Lau 2015）。例如，可以要求受试者对自己关于某一刺激的答案有多大的把握，比如判断一个短暂呈现的刺激是垂直方向还是水平方向。其背后的思路是，受试者利用信心评分来追踪自己反应准确性的能力（即元认知敏感性）取决于他们是否意识到相关的刺激。同样，这种方法并不完美，但它相较于要求受试者报告自己的意识体验具有一些优势（Morales & Lau 2021；Michel 2022）。意识科学中存在各种潜在的混淆因素，但研究人员可以通过综合不同类型研究的证据，以削弱方法论质疑的力度。

(劳 2022）。

报告方法的第二个问题在于，显然有一些具有意识经验的主体无法做出报告，包括非人类动物、婴儿以及患有某些认知障碍的人。这一问题在非人类动物身上可能尤为紧迫，因为如果我们能更多地了解动物的意识——尤其是那些与我们相对不同的动物——或许就能更全面地把握与意识相关的脑部过程范围。这一棘手问题最近受到了越来越多的关注（例如，Birch 2022b）。然而，尽管当前关于意识的科学理论主要基于健康成年人类的数据，但考察人工智能系统是否采用了与这些理论所描述的过程相似的机制，仍然极具启发意义。

方框2：形而上学理论与意识科学

无意义

意识形而上学中的主要立场包括唯物主义、属性二元论、泛心论和幻觉论（欲了解详细且有影响力的概述，请参阅Chalmers 2002）。

唯物主义认为，意识是一种完全的物理现象。有意识的体验是物理世界的状态——通常是大脑状态——而构成我们体验的主观特征的属性，即所谓的现象属性，正是这些状态的物理属性。例如，一位唯物主义者可能会声称，看到一朵红郁金香的体验就是一种特定的大脑状态，而这种体验的“红色”则正是该状态的一个特征。

属性二元论否认唯物主义，声称现象属性是非物理属性。与实体二元论不同，这种观点认为只存在一种实体或存在物，同时断言它同时具有物理属性和现象属性。观看郁金香时的“红色”可能就是所涉大脑状态的一种属性，但它与该状态的任何物理属性都截然不同。

泛心论认为，所有基本的物理实体都具有现象属性，或者更简单但相关的“原现象”属性。泛心论者可能会声称，作为基本粒子的电子，要么具有像郁金香体验中的“红色”那样的属性，要么具有这种属性的某种特殊前驱。泛心论者通常并不主张万物都具有意识体验——相反，基本实体的现象层面仅在少数宏观尺度的实体中（例如人类）才会结合而产生意识体验。

幻觉主义声称，我们在对意识的思考中受到一种幻觉的支配，要么意识根本不存在（强幻觉主义），要么我们对其某些特征普遍存在误解（弱幻觉主义）。然而，即使是强幻觉主义也承认“准现象性”属性的存在，这些属性是通过内省被错误地表征为现象性的。例如，一位幻觉主义者可能会说，当一个人似乎拥有看到一朵红郁金香的意识体验时，某种大脑状态被内省错误地表征为具有现象性的“红色”属性。

重要的是，意识科学在这四个形而上学立场上都有工作要做。如果**唯物主义**是正确的，那么一些大脑状态就是有意识的体验

和其他人则不然，神经科学的作用就在于找出它们之间的区别。同样地，**属性二元论**和**泛心论**都声称，只有某些大脑状态才会伴随有意识体验，而这一观点与通过科学手段研究这种差异的可能性是相容的。根据**幻觉主义**，神经科学能够解释为何会产生意识的幻觉，尤其是为何这种幻觉只会在某些大脑状态中出现，而在其他状态下却不会出现。

1.2.3 理论导向的方法

在1.2.1节中，我们采用了计算功能主义这一假设，即实现某些计算过程是意识的必要且充分条件；在1.2.2节中，我们指出存在一些科学理论旨在描述计算过程与意识之间的相关性。将这两点结合起来，为研究人工智能系统中的意识提供了一种颇具前景的方法：我们可以观察这些系统是否使用了与意识科学理论所描述的类似的计算过程，并据此调整我们的评估。初步来看，我们对某个系统是否具有意识的信心，可由以下因素决定：(a) 其计算过程与某一特定意识科学理论所假定的计算过程的相似程度；(b) 我们对该理论的信心程度；(c) 我们对计算功能主义的信心程度。5 如果同时考虑多种理论，则能获得更全面的图景。这种方法代表了一种“理论导向”的人工智能意识研究路径。

“理论导向”一词源自伯奇（2022b），他探讨了我们如何以科学的方式研究非人类动物，尤其是无脊椎动物的意识。

伯奇反对在这种情况下采用理论导向的方法。伯奇提出的一个反对意见是，支持科学理论的人类证据并未告诉我们，在多大程度上可以放宽这些条件，同时仍足以产生意识（参见卡鲁瑟斯，2019）。也就是说，尽管我们可能有充分的证据表明某种过程对人类的意识而言是充分的，但这些证据并不能告诉我们，另一种动物体内存在的一种在某些方面相似但在其他方面不同的过程，是否也足以产生意识。要确定这一点，我们需要事先了解哪些非人类动物或系统具有意识——遗憾的是，这恰恰是我们尚不确定的问题。

另一种思考这个问题的方式，是着眼于我们应当如何解读意识理论。正如我们在本报告中将看到的，人们既可以相对严格地解读这些理论，即仅声称人类所具有的某些特定特征足以构成意识；也可以采取更为宽松、抽象的条件，而这些条件甚至可能被相当简单的人工系统所满足（Shevlin 2021）。那些在吸引人的普遍性（意识并不仅仅是人类大脑中这种非常具体的过程）与非直观的宽松性（意识并非仅仅由极其简单的系统所具备的属性）之间取得平衡的适度解读颇具吸引力，但目前尚不清楚这些解读是否比其他替代方案更具实证支持。

5 该理论可能涉及计算功能主义，在这种情况下，(c) 就是不必要的。但我们认为，强调一下是有帮助的：如果计算功能主义是你对理论进行阐释时的一个背景假设，那么你就应当同时考虑对该假设的不确定性，以及对该理论具体细节的不确定性。

尽管这一反对意见确实指出了以理论为导向的方法的一个重要局限性，但它并未表明以理论为导向的方法就无法为我们提供有关人工智能中意识的有用信息。一些人工智能系统所采用的流程与意识理论所识别的流程更为相似，而这一反对意见并不能否定这样一种论断：那些采用更相似流程的系统相应地更有可能具备意识。开展研究时，借鉴意识理论是必要的，因为它们是我们能找到的最佳指引，能够帮助我们确定应当关注哪些特征。对动物意识的研究则有所不同，因为我们已有理由相信，与人类亲缘关系更近、表现出更复杂行为的动物更有可能具备意识。认知架构的相似性很可能与谱系亲缘关系存在显著相关性，因此，虽然寻找这些相似性多少会有些启发意义，但其信息量仍不及在人工智能领域的研究。 6

人工智能领域中，与理论导向方法相对的主要替代方案是采用行为测试，这些测试旨在对科学理论保持中立。专门针对人工智能中的意识问题，已提出了若干行为测试（Elamrani & Yampolskiy 2019）。一个有趣的例子是施奈德（2019）的人工意识测试，该测试要求人工智能系统在对话中表现出对与意识相关概念和思想的熟练掌握，甚至可能展现出“问题直觉”，例如判断光谱反转是可能的（Chalmers 2018）。图灵测试也被提议作为意识的检验标准（Harnad 2003）。

总的来说，我们对人工智能中基于行为的意识研究方法能否避免以下问题持怀疑态度：人工智能系统可能被训练成模仿人类行为，但在实际运作中却采用截然不同的方式，从而“玩弄”行为测试（安德鲁斯与伯奇，2023）。以大型语言模型为基础的对话式智能体，例如ChatGPT，在某些方面生成的输出极为类似人类，但其工作方式却与人类大相径庭。这既体现了此类情况的可能性，也表明企业有动力去构建能够模仿人类的系统。7施奈德（2019）提出，可通过限制待测系统获取有关意识的人类文献，从而避免“玩弄”行为测试，使这些系统无法学会模仿我们谈论这一主题的方式。然而，尚不清楚这一措施是否足够有效，也难以确定是否能在不给系统过多数据以至于使其能够“玩弄”测试的前提下，为其提供足够的数据以参与测试（尤德尔与施维茨格贝尔，2021）。

6 伯奇（2022b）倡导一种“理论轻量型”方法，该方法包含两个方面：(1) 拒绝这样一种观点，即我们应通过寻找特定理论所关联的、与意识相关的进程来评估非人类动物的意识；(2) 目前不拘泥于任何特定理论，而是致力于在未来掌握更多关于动物（或许还有人工智能）意识的证据后，发展出更完善的理论。我们的方法在某种程度上是“理论厚重型”的，因为与“理论轻量型”方法的第一方面形成对比，我们确实会通过寻找科学理论所关联的、与意识相关的进程来评估人工智能系统。不过，和伯奇一样，我们目前也并未执着于任何单一理论。更一般地说，伯奇的方法提出了有关如何发展意识科学研究的建议，而我们关注的只是，在当前知识水平下，究竟应采用何种证据来评估人工智能系统的意识。7 关于可能存在大量看似有意识但实际上并无意识的人工智能系统的风险，请参见第4.1.2节的讨论。

2 意识的科学理论

在本节中，我们综述了部分关于意识的科学理论、一些并非严格意义上的意识理论但与我们的研究项目相关的科学主张，以及科学家和哲学家提出的有关意识必要条件的其他论断。从这些理论和主张中，我们旨在提炼出一套可用于特定人工智能系统的意识指标，以评估这些系统具备意识的可能性。8 由于我们寻找的是与人工智能相关的指标，因此在本节的某些部分，我们讨论了意识理论和条件在人工智能中的可能实现方式。不过，我们将在第3节中更详细地探讨这一主题，该节将重点讨论人工智能系统要具备我们所识别的意识指标特征所需满足的条件。

第2.1至2.3节涵盖了循环处理理论、全局工作空间理论以及更高阶的意识理论——其中第2.3节特别关注感知现实监控理论。这些都是与我们的计算功能主义框架相兼容的成熟科学意识理论。第2.4节讨论了其他一些科学理论，以及关于意识的其他提议条件，第2.5节则给出了我们的指标列表。

我们并不打算对本节中所探讨的这些理论进行裁决，尽管我们会指出它们各自的一些优势和不足。我们既不采纳任何一种特定的理论，也不声称某种特定条件是意识的绝对必要条件，更不宣称某种条件组合是意识的充分必要条件。正因如此，我们在第2.5节中列出的清单，我们将其描述为意识的指标清单，而非条件清单。清单中的各项特征之所以被列出，是因为某些理论或理论家声称它们是必要的或充分的，但我们所作的仅仅是一种可信的假设：即这些特征是必要的，或者（在组合情况下）是充分的，因为这正是可信理论所暗示的。如果一个系统具备这些特征，那么它具有意识的可能性就更大。我们主张，根据目前科学界对该领域的认知水平，评估一个系统是否具备这些特征，是判断其是否可能具有意识的最佳方式。

2.1 递归处理理论

2.1.1 递归处理理论简介

循环处理理论（RPT；Lamme 2006, 2010, 2020）是众多神经科学意识理论中的重要一员，这些理论聚焦于大脑中感知区域的加工过程（其他相关理论参见Zeki & Bartels 1998, Malach 2021）。这些理论有时被称为“局部”（相对于“全局”）意识理论，因为它们主张，在相对局限的大脑区域内以正确形式发生的活动就足以产生意识，当然，这需要满足某些背景条件。RPT主要是一种关于视觉意识的理论：它试图解释，哪些状态下的刺激能够被有意识地看到，而哪些状态下的刺激仅仅由视觉系统的活动无意识地表征。该理论

8 在查尔莫斯（2023）一书中，我们发现了与人工智能意识问题类似的处理方法。该书探讨了大型语言模型的若干特征，这些特征使我们有理由认为它们具有意识，同时也讨论了通常被提出的若干“反驳”大型语言模型具备意识的观点。其中许多考量，如同我们的指标一样，均源自关于意识的科学理论。

声称无意识与意识状态对应于视觉处理中的不同阶段。在视觉区域的层级结构中，最初的前馈活动扫描足以完成一些视觉操作，例如从场景中提取特征，但不足以产生有意识的体验。然而，当刺激足够强烈或显著时，就会发生循环处理，即信号会从视觉层级结构中的较高区域向较低区域反馈。这种循环处理生成了对有序场景的有意识表征，而这一表征会受到知觉推理的影响——即通过其他特征推断出场景或知觉的某些特征的加工过程。按照这一观点，有意识的视觉体验并不需要非视觉区域（如前额叶皮层）或注意力的参与——这与“全局”理论形成了鲜明对比，比如全局工作空间理论和高阶理论，我们将在稍后加以讨论。

2.1.2 重复处理理论的证据

RPT的证据有两种：第一种是证明重复处理对于有意识视觉是必要的，第二种是反驳那些主张需要额外处理以实现感知组织之外的功能的替代理论。

第一类证据来自涉及后向掩蔽和经颅磁刺激的实验，这些实验表明，初级视觉皮层（即上述第一阶段的处理过程）中的前馈活动不足以产生意识（Lamme 2006）。Lamme还指出，尽管前馈处理足以实现诸如特征分类等基本视觉功能，但诸如特征分组与整合、以及图形与背景分离等重要功能则需要循环反馈。因此，他主张，循环处理对于生成一个有组织、一体化的视觉场景是必要的——这种场景正是我们在有意识视觉中所体验到的场景（Lamme 2010, 2020）。

反对更严苛的竞争对手理论的证据包括来自脑损伤和大脑刺激研究的结果，这些结果表明，前额叶皮层的额外加工对于有意识的视觉感知并非必要。这在一定程度上反驳了非“局部”观点，因为后者声称前额叶皮层的功能对意识是必要的（马拉赫，2022；有关反对此观点的分析，请参阅米歇尔，2022）。RPT的支持者还指出，用于支持竞争对手观点的证据受到实验要求的干扰，这些要求涉及与报告相关的下游认知过程。其核心思想是：当参与者做出用以指示有意识感知的报告（以及其他行为反应）时，这一过程本身需要一些认知机制，而这些机制本身并不是意识所必需的。因此，当竞争对手理论主张下游过程对意识是必要的时，RPT及其类似理论的倡导者则回应称，相关证据可由混杂因素加以解释（请参阅第1.2.2节中讨论的方法论问题）。

2.1.3 来自递归处理理论的指标

对RPT有多种可能的解释，这些解释对人工智能意识具有不同的含义。就我们的目的而言，一个关键问题是：循环处理是必要的这一说法意识可以以两种不同的方式来解释。在大脑中，单个神经元通常会接收来自其自身先前输出的输入，这是由连接区域的反馈回路所导致的。然而，无需这种结构也能实现某种形式的递归：任何具有反馈回路的网络所执行的有限操作序列，都可以通过一个具有足够层数的前馈网络来模拟。为了实现这一点，前馈网络需要具备多个

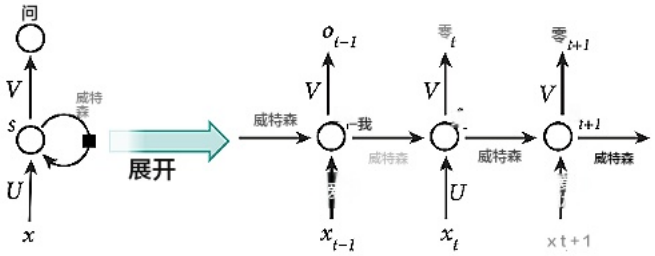

图1：一个展开的循环神经网络，如LeCun、Bengio和Hinton（2015）所描绘。知识共享署名-相同方式共享4.0国际许可协议。

具有共享权重的层，以便重复执行相同的操作——从而模拟由单组神经元对信息进行多次处理的效果，这种效果会由具有反馈回路的网络产生（Savage 1972，LeCun 等人 2015）。在当前的人工智能中，循环神经网络的实现方式与深度前馈网络无异，后者各层之间共享权重，不同组的输入节点依次将连续的输入送入网络的各个层。

我们将说，具有反馈回路的网络，例如大脑中的那些网络，允许物理实现的神经元反复处理信息，表现出实现性递归。然而，具有权重共享的深层前馈网络仅表现出算法性递归——它们在算法上类似于实现性递归网络，但底层结构不同。因此，这里存在两种可能的RPT解释：一种是认为意识需要实现性递归，另一种则是仅提出较弱的主张，即意识需要算法性递归。Doerig等人（2019）将RPT解读为意识需要实现性递归，并针对这一主张进行了批评。不过，在个人交流中，Lamme向我们暗示，RPT也可以被赋予较弱的算法性解释。

实现性和算法性重复都可能是人工智能中意识的指标，但我们重点关注算法性重复。构建一个表现出实现性重复的人工系统是可能的，但这需要确保每个神经元都由硬件中的特定组件以物理方式实现。这将与当前人工智能的标准方法大相径庭，在标准方法中，神经网络是通过模拟来实现的，并未使用特定的硬件组件来实现网络的每个组成部分。因此，实现性重复这一指标与我们的项目关联性较小，所以我们并未采用这一指标。

相比之下，使用算法递归是一种较弱的条件，许多人工智能系统早已满足。然而，这并非微不足道，我们将在下文论证，除了……之外，还有其他原因。

RPT的证据，证明算法递归对于意识是必要的。因此，我们将其作为第一个指标：

RPT-1：使用算法递归的输入模块

这是一个重要的指标，因为缺乏此功能的系统在意识方面明显逊色。

RPT 还提出了第二个指标，因为它可能被解读为声称，只要利用算法递归生成有组织、连贯场景的整合感知表征，并具备图形-背景分离以及物体在空间关系中的表征，就足以实现意识。这个第二个指标是：

RPT-2：生成有组织、整合的感知表征的输入模块

RPT的一个重要对比在于特征提取与知觉组织之间的功能差异。在人类的无意识加工中，可以提取视觉场景中的特征；然而，诸如图形-背景分离之类的知觉组织操作可能需要有意识的视觉参与；这正是RPT-2强调有组织、整合的知觉表征的原因。

RPT还有另外两种可能的解释，我们出于不同原因将其暂且搁置。首先，根据RPT的生物学解释，大脑中的循环处理对于意识来说是必要且充分的，因为它与某些特定的生物学现象相关，例如募集特定类型的神经递质和受体，从而促进突触可塑性。这种生物学解释得到了Lamme部分论点的支持（Lamme在个人交流中也曾向我们提出过这一观点）：Lamme（2010）认为，大脑中的前馈处理与循环处理之间可能存在“根本性的神经差异”，因此我们理应期待意识与某种“基本的神经机制”相关联。我们暂且搁置这一解释，因为如果某种特定的、以生物学特征定义的神经机制是意识所必需的，那么人工系统就不可能具备意识。

其次，RPT或许可被理解为仅适用于视觉意识的理论，它并未对更普遍意义上的意识所需或充分条件作出任何承诺。按照这种解释，RPT将同时留下以下两个问题未决：(i) 非视觉的意识体验是否需要与视觉体验类似的处理过程；(ii) 一些通常在人类中满足但该理论并未明确规定的背景条件，是否甚至对于视觉意识而言也是必需的。鉴于该理论尚未扩展到视觉以外的领域，且很难断定体外持续存在的视觉脑区活动足以引发意识（Block 2005），这种对理论的解释是合理的。然而，按照这种解释，RPT对人工智能的启示将非常有限。

2.2 全局工作区理论

2.2.1 全局工作区理论简介

全局工作区意识理论（GWT）建立在这样一个理念之上：人类和其他动物使用许多专门的系统，通常称为模块，来执行认知任务。

特定类型的。这些专用系统能够高效、独立且并行地执行任务。然而，它们也通过大脑的某些特征相互集成，从而实现信息共享。这种集成使得各个模块能够以协调且灵活的方式协同工作，进而提升整个系统的功能。GWT认为，模块之间的一种集成方式是它们共同访问一个“全局工作区”——这是系统中另一个“空间”，用于表示信息。在全局工作区中表示的信息可以影响任何模块中的活动。由于工作区的容量有限，因此需要持续的竞争与选择过程来决定哪些信息会被存储在那里。

GWT认为，一个状态之所以具有意识，就是因为它在全局工作空间中得到了表征。另一种表述方式是：当状态通过工作空间被“全局广播”到多个模块时，这些状态便具备了意识。GWT由巴尔斯（1988）提出，并由德海纳及其同事进一步发展和完善，他们还提出了该理论的神经学版本（德海纳等，1998，2003；德海纳与纳卡什，2001；德海纳与尚克，2011；马舒尔等，2020）。GWT的支持者认为，全局工作空间解释了为何某些特定的知觉（以及其他）表征会在某一时刻被优先选中，从而用于推理、决策以及情景记忆的存储等功能。知觉表征会因刺激强度而增强，或因与当前任务相关而受到注意的放大；因此，这些表征便“赢得了竞争”，得以进入全局工作空间。这使得它们能够影响产生它们的模块之外的其他模块中的信息处理过程。

GWT的神经版本声称，存在一个广泛分布的“工作空间神经元”网络，该网络起源于额顶叶区域。这一网络中的活动由循环处理持续维持，构成了有意识的表征。当感知表征变得足够强烈时，就会发生一种称为“点燃”的过程，在此过程中，工作空间神经元中的活动开始编码其内容。点燃是一个阶跃函数，因此，给定表征是否被广播，进而成为有意识的，并不是程度问题。

GWT通常被视作一种关于访问意识的理论——即，大脑中所表征的信息并非全部都能用于理性决策的现象。然而，它也可以被解读为一种关于现象意识的理论，其动机在于这样的想法：访问意识与现象意识可能重合，甚至就是同一属性，尽管二者在概念上是不同的（Carruthers 2019）。由于我们的主题是现象意识，因此我们以这种方式来解读这一理论。值得注意的是，尽管GWT并未明确要求具备主体性，但只有当系统是一个理性主体时，它才能解释访问意识，因为访问意识被定义为可被用于理性控制行动的能力（我们在第2.4.5节中讨论了主体性问题）。

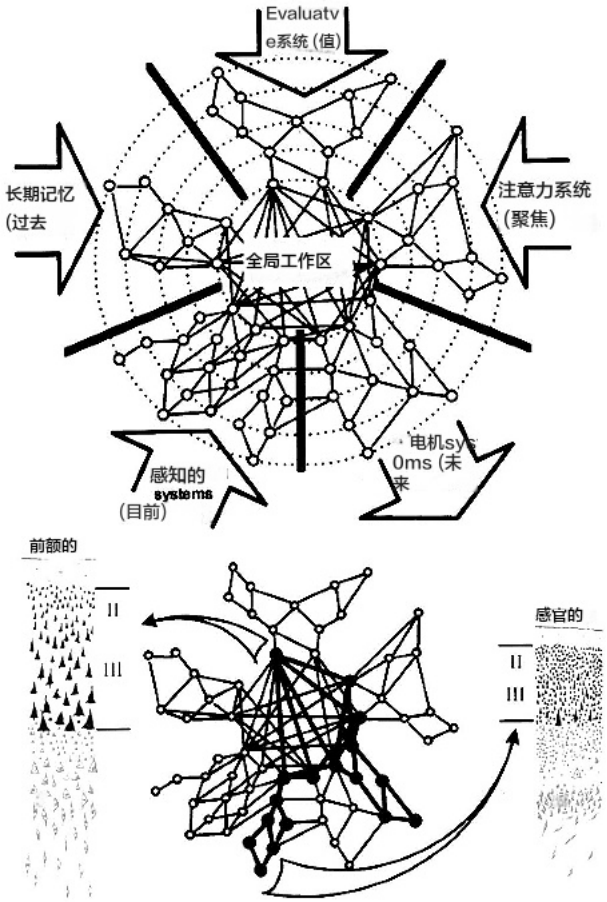

图2：全局工作区。Dehaene等人（1998）用来说明全局工作区基本思想的图表。请注意，向规划、推理和言语报告等广泛消费者系统广播的功能并未在该图中体现。1998年，美国国家科学院。经许可转载。

2.2.2 全局工作空间理论的证据

有大量证据支持全局工作空间理论，这些证据来自多项研究，我们仅举几个具有代表性的例子（有关综述，请参阅Dehaene 2014和Mashour等2020）。这些研究通常采用对比分析的方法，即测量大脑活动，并在意识状态与无意识状态之间进行比较，同时努力控制其他可能的差异。各种刺激和任务被用来诱发意识与无意识状态，而活动则通过fMRI、MEG、EEG或单细胞记录来测量。根据全局工作空间理论的支持者，这些研究表明，意识感知与广泛网络中的振荡活动相关，这些网络包括前额叶皮层（PFC）——这一主张与上文讨论的RPT的“局部”特性形成鲜明对比——而无意识状态则涉及更为局限的活动，局限于特定区域。这种广泛的活动似乎出现在知觉加工的后期阶段，即刺激开始后约250至300毫秒时，这支持了全球广播需要持续的知觉表征这一观点（Mashour等2020）。

支持前额叶皮层在意识中发挥作用的猴子记录研究实例包括Panagiotaropoulos等人（2012）和van Vugt等人（2018）的实验。在前一项研究中，研究人员能够从前额叶皮层的活动解码出双眼竞争期间意识体验的推定内容（Panagiotaropoulos等，2012）。在这项研究中，猴子只是被动地观看刺激——这与许多支持全局工作空间理论的研究形成对比——因此，结果不会受到行为要求的混淆（这是一个无需报告的范式；参见第1.2.2节和第2.1.2节）。在后一项研究中，研究人员记录了视觉区V1和V4以及背外侧前额叶皮层的活动，同时猴子执行一项任务：它们需要通过眼球运动对微弱的视觉刺激作出反应。猴子经过训练，如果未看到刺激则将视线移回默认位置，而如果看到刺激则移向另一个位置。当猴子看到刺激时，V1和V4区域的活动更为强烈，且前额叶皮层也表现出显著的晚期活动。重要的是，尽管早期视觉活动能记录下刺激的客观存在，而与动物的反应无关，但前额叶皮层的活动似乎编码了意识知觉，因为这种活动甚至出现在假警报中——即猴子看似看到了刺激但实际上并无刺激出现的情况。与未被看到的刺激相关的活动往往在从V1、V4到前额叶皮层的传递过程中逐渐减弱。利用不同测量技术的人类研究同样发现，意识体验与类似点火的活动模式相关，并可从前额叶皮层中解码出来（例如，Salti等，2015）。

2.2.3 来自全局工作区理论的指标

我们希望根据全局工作空间理论，确定一个系统要具备哪些条件才能拥有意识，因为这些条件将成为人工系统具备意识的指标。这意味着，一个关键问题就在于：究竟什么样的系统才能实现全局工作空间？多位作者指出，要使一个系统具备足够支持意识的全局工作空间，它在类似工作空间的特征上与人类大脑有多相似，并不明显（Bayne 2010，Carruthers 2019，Birch 2022b，Seth & Bayne 2022）。这个问题或许可从四个方面来探讨。首先，类似工作空间的架构可以与各种不同功能模块以多种组合方式搭配使用；正如Carruthers（2019）所指出的，人类拥有一套丰富而特定的能力，似乎正是由工作空间所促进的，而这些能力可能并不为其他系统所共有。因此，一个问题是：是否必须存在一组特定的模块访问工作空间，才能使工作空间活动具备意识？其次，尚不清楚，一个过程在多大程度上需要与人类大脑中的选择、激发和广播机制相似，才能支持意识的产生。第三，很难弄清楚那些采用类似工作空间机制但存在多个工作空间——或许整合了重叠的模块集合——或者工作空间并非全局性的，即无法整合所有模块的系统，该如何看待它们。第四，全球广播似乎涉及两个阶段——首先是在工作空间中进行表征的选择，然后由消费模块加以吸收——在这种情况下，就有一个问题：究竟是哪个阶段使特定状态具备了意识？

尽管这些问题颇具难度，但或许能够借助实证证据加以解答。例如，对非人类动物的研究有助于确定一种自然类，该类包含人类全局工作空间，并促进与意识相关的能力（Birch 2020）。对人工智能的反思在此同样大有裨益，因为我们能够识别出功能上的相似之处和差异。

实际或可能的系统与假设的全局工作空间之间的相似性，独立于系统的模块范围或神经生物学实现的细节，从而更清晰地理解该领域的可能功能类型。

GWT的支持者认为，全局工作区促进了人类及其他动物的一系列功能（Baars 1988，Shanahan 2010）。这些功能包括：使模块能够在任务期间持续地对其他模块施加控制（例如，在人群中寻找一张脸时），以及通过广播有关新刺激的信息来应对新奇的刺激，从而使系统能够学习最有效的反应。全局广播和在处理传入刺激的同时维持表征的能力，对于实现这些功能是必不可少的。由于全局工作区要求来自不同模块的信息以一种共同的“语言”进行表征，它还使得学习和生成跨模态类比成为可能（VanRullen & Kanai 2021，Goyal et al. 2022）。全局工作区一个特别复杂且引人注目的潜在功能是“系统2思维”，即执行复杂任务的策略，其中工作区促进了模块之间长时间且受控的交互（Kahneman 2011，VanRullen & Kanai 2021，Goyal & Bengio 2022）。例如，筹划一场晚宴可能涉及一个由这一目标所控制的长期过程，包括一系列探究性行动（查看冰箱里有什么）、调用情景记忆、各种模态的想象（食物尝起来会怎样、烹饪难度如何、客人之间会如何互动）、评估与决策。根据这一理论，在这种情况下，工作区将保持对目标的表征，或许还会保存中间结论的压缩摘要，并在模块之间传递查询与响应。

我们认为，GWT可以用四个逐步增强的条件来表述。满足这些条件越多的系统，就越具备完整全局工作空间架构的各个方面，因此也越有可能具备意识。

第一个条件是拥有能够并行执行任务的专用系统。我们称这些系统为“模块”，但它们并不一定需要符合福多（1983）所界定的严格意义上的模块；它们不必具备信息封闭性，也不必使用在训练前就已分配好功能的架构专用组件。马舒尔等人最近提出的全局神经元工作空间假说仅声称，发生无意识加工的模块是局部化的且专门化的，并且它们处理的是“特定的感知、运动、记忆和评估信息”（2020，第777页）。或许，拥有更多独立且分化的模块会使一个系统更适合作为意识的载体，但全球神经元工作空间假说最合理的解释是：对意识而言，重要的是整合各模块的过程，而非模块本身的精确特征。因此，我们从这一理论中得出的第一个指示是：

GWT-1：多个可并行运行的专用系统（模块）

在此基础上，GWT的一个核心条件是系统信息流中存在瓶颈：工作空间的容量必须小于向其馈送信息的各个模块的总容量。有限容量的工作空间使各模块能够高效地共享信息，这与涉及成对交互的方案（如Transformer）形成鲜明对比——后者随着规模扩大而变得成本高昂（Goyal等，2022；Jaegle等，2021a）。这一瓶颈还迫使系统学习有用、低维且多模态的表示（Bengio，2017；

Goyal & Bengio 2022）。随着瓶颈的出现，需要一种注意力机制，从模块中选择信息以在工作空间中进行表示。这产生了我们的第二个指标：

GWT-2：容量有限的工作空间，导致信息流出现瓶颈，并引发选择性注意机制

另一个核心条件是，工作区中的信息是全局广播的，这意味着所有模块都可以访问这些信息。到目前为止，我们所看到的这两个条件还不足以确保模块之间能够持续交互，或者工作区中的信息能够被多个输出模块访问，从而用于不同的任务。因此，我们的第三个指标是：

GWT-3：全局广播：工作区中信息对所有模块的可用性

这意味着所有模块都必须能够从全局工作区获取输入，包括那些处理整个系统输入的模块。前两个条件可由完全前馈系统满足，这类系统具有多个输入模块，它们将信息馈入一个容量有限的工作区，随后信息再流向一个或多个输出模块。但这一新条件要求信息还必须从工作区回流到输入模块，从而影响其处理过程。反过来，这就意味着输入模块必须是（算法上）递归的——这也进一步证明了指标RPT-1的合理性——尽管输出模块将工作区状态映射为行为，却无需具备递归性。

最后，为了使工作区能够促进模块之间持续、受控的交互，它必须具备另一个特性。那就是，决定从模块中获取信息的选择机制，不仅需要对系统的状态敏感，还需要对新输入敏感。也就是说，系统必须同时实现一种“自上而下注意”和一种“自下而上注意”。这使得工作区本身或其他模块中的表征能够影响从每个模块中选择哪些信息。依赖于状态的选择机制，对于满足GWT-3标准的系统而言，可以很容易地实现，因为全局广播意味着信息会从工作区流向各个模块。然而，要实现模块之间受控且功能性的交互，则需要对整个系统进行适当的训练。我们的第四个指标是：

GWT-4：状态相关注意力，使工作空间能够依次查询模块以执行复杂任务

与其他意识科学理论相比，已有更多关于在人工系统中实现GWT的提案（例如，Franklin & Graesser 1999，Shanahan 2006，Bao et al. 2020）。我们在第3.1节中讨论了GWT及其他理论的实现方式。

方框3：神经科学与人工智能中的注意力

神经科学和机器学习领域各自拥有独特的注意力概念（Lindsay 2020）。在机器学习中，已经开发出几种不同形式的注意力，但目前最常见的是“自注意力”（Vaswani et al. 2023）。这是Transformer网络的核心机制，而Transformer网络正是大型语言模型的驱动力。

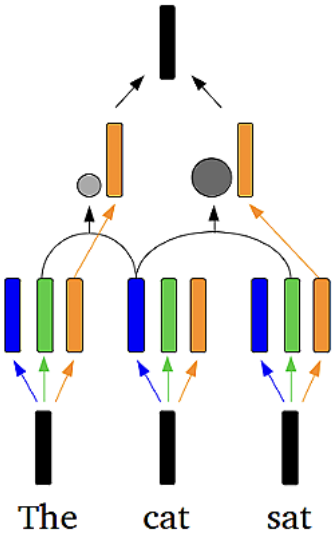

在自注意力机制中，输入序列中各个元素的表示（例如句子中的单词）可以相互进行乘法交互。具体而言，每个**单词表示**，即以向量形式给出，会被转换成三个新的向量：一个查询，一个键，以及一个值。一个单词的查询向量会与所有其他单词的键向量相乘，从而为这些单词中的每一个确定一个权重。这个权重会被应用于这些单词的值向量；这些加权值向量的总和构成了该单词新的**表示**。这一过程会同时对所有单词并行进行。

“交叉注意力”遵循类似的公式，但允许从一组表示中生成查询，而键和值则来自另一组（自注意力和交叉注意力都是“键-查询注意力”的形式）。这在例如使用……的翻译网络中可能会有所帮助。

目标语言中正在生成的句子的单词，以引导注意力转向原始语言中相应句子的单词。

关键查询注意力与神经科学中对注意力的概念化方式仅有松散的联系。与自注意力类似，增益调节（即注意力以乘法方式放大神经活动）已在许多神经系统中被发现（Treue & Trujillo 1999，Reynolds & Heeger 2009）。然而，这种注意力调节通常被认为源自于循环的自上而下的连接，而非来自对同时输入的并行处理（Noudoost et al. 2010，Bichot et al. 2015）。机器学习中先前版本的注意力机制依赖于循环处理，因此在某种程度上可被视为更类似于生物注意力（Mnih et al. 2014，Bahdanau et al. 2014）。不过，需要注意的是，神经科学中存在多种不同类型的注意力，其背后的神经机制也可能各不相同。因此，要明确指出哪种形式的人工注意力最接近于生物注意力，并非一件简单的事。

鉴于不同的意识理论依赖于循环处理或注意力机制的其他特定组件，自注意力可能不足以构成人工意识的基础。例如，在自注意力中不存在全局工作空间理论中类似二进制点燃过程的东西，因为注意力是以输入的分级加权方式实现的。此外，自注意力本身也没有内置的注意力过程模型，而这正是注意力模式理论所要求的。

2.3 高阶理论

2.3.1 高阶理论简介

布朗等人（2019）对高阶意识理论的核心主张进行了有益的提炼：

> 基本思想……是，有意识的体验包含某种对自己持续心理活动的最低限度的内在觉知，而这正是由于一阶状态在某种程度上被相关的高阶表征所监控或元表征所致。（第755页）

高阶理论与其他理论的区别在于，它们强调：要使一种心理状态成为有意识的，主体必须意识到自己正处于这种心理状态，而它们提出了解释这种意识的方式。这种解释依赖于高阶表征这一概念，该概念具有非常特定的含义。高阶表征是指表征其他表征 的表征，而第一阶表征则是指表征（非表征性）世界的表征。这一区分可以应用于心理状态。例如，对一个红苹果的视觉表征是一种第一阶心理状态，而相信自己拥有一个红苹果的表征，则是一种高阶心理状态。

高阶理论长期以来一直受到哲学家的推崇（Carruthers & Gennaro 2020，Rosenthal 2005）。这一观点的主要动机之一是所谓的“简单论证”（Lycan 2001）：如果一种心理状态是意识的，那么主体就会意识到自己处于这种状态；而意识到某事就涉及对它的表征；因此，意识要求对自己心理状态的高阶表征。该论证的核心承诺在于，存在一种单一的“意识”概念，使得两个前提都为真——这种概念既足够弱，足以使意识蕴含对心理状态的意识，又足够强，足以使这种意识蕴含高阶表征。在过去二十年里，高阶理论得到了神经科学家的进一步阐释、完善和检验，并受到元认知研究、信号检测理论以及预测加工理论中新的实验方法和思想的影响。

人们提出了多种高阶理论，这些理论描述了不同的监控或元表征形式，并暗示了意识的不同条件（Brown 等人，2019）。它们包括：若干哲学理论，包括高阶思想理论（Rosen-thal，2005）和表征的高阶表征理论（Brown，2015）；自我组织的元表征理论（Cleeremans 等人，2020）；高阶状态空间理论（Fleming，2020）；以及感知现实监控理论（Lau，2019，2022，Michel 即将出版）。我们将重点探讨感知现实监控理论（PRM），并在一定程度上也关注与之密切相关的高阶状态空间理论（HOSS）。这两种理论都是基于对神经科学证据的广泛评估而提出的最新计算理论。

PRM的核心主张是，意识依赖于一种机制，该机制能够将感知系统中的有意义活动与噪声区分开来。感知系统中存在多种可能的神经活动来源。这些活动可能是由环境中可感知的刺激引起的；也可能是这些刺激消失后仍持续存在的；还可能是自上而下产生的。

通过期望、想象、做梦或情景记忆；或者也可能是由随机噪声引起的。PRM声称，一种自动运行的“现实监控”机制被用来区分这些不同类型的活动，并评估一阶表征的可靠性。当感知表征被认定为可靠时，即与噪声有足够差异时，它们便是有意识的。

与此同时，HOSS也提出了类似的主张：“意识是一种生成性感知内容模型中的高阶状态”（弗莱明，2020年，第2页）。这种高阶状态是元认知推理的产物，它表明某种特定内容在感知系统中被表征的可能性。这一观点被用作意识报告的基础理论（即“我意识到/未意识到X”这类报告），但弗莱明认为，高阶意识状态对于意识本身而言是必要的。

2.3.2 计算HOTs和GWT

计算型高阶理论有时与GWT一起被归为“全局”理论，以区别于诸如RPT之类的“局部”理论（Michel & Doerig 2022）。与GWT类似，PRM等高阶理论也认为，前额叶皮层所支持的认知功能在意识中发挥着重要作用。因此，上述支持前额叶皮层参与意识的证据同样支持PRM以及GWT。PRM还声称，与GWT一样，“意识是一种门控机制，通过该机制，感知影响认知；它选择哪些感知信息应直接作用于我们的理性思维”（Lau 2022，第159页）。Lau（2022）认可大脑中存在全局广播这一现象，并且进一步确认其与意识存在关联：当表征处于意识状态时，“全局广播和访问”该表征“很可能发生”（第159页）。

然而，高阶理论家们反对这样一种说法：全局工作空间中的广播对于意识来说是必要且充分的。值得注意的是，根据高阶理论，无意识表征也可以被编码进全局工作空间，这意味着某种表征可能是无意识的，却仍可被用于高级认知过程，例如推理。高阶理论与GWT做出了不同的预测，而计算型高阶理论的支持者则援引检验这些预测的实验，认为它们为支持其观点提供了重要证据。

在一项这样的实验中，Lau和Passingham（2006）在一系列不同的掩蔽条件下进行了一项视觉辨别任务，并要求参与者按键以表明他们在每一轮试验中是真正看到了刺激的形状，还是仅仅猜到了。他们确定了两种不同的掩蔽条件，在这两种条件下，参与者辨别刺激的能力处于同一水平，但他们在报告自己是否看到刺激的可能性却有所不同。高阶理论家将这一结果解释为：即使在任务表现上没有相应差异，对刺激的意识感知也可能存在差异；他们声称，这一结果与全局工作空间理论（GWT）的预测不符（Lau & Rosenthal 2011）。GWT所提出的这一所谓预测是：意识上的差异应当导致任务表现上的差异，因为根据GWT，意识使信息能够被广泛的认知功能所利用，从而在各种各样的任务中发挥作用。此外，根据GWT，引发全局广播的点燃过程对于意识而言既是必要条件也是充分条件，而点燃过程又取决于影响视觉任务表现的相同因素，例如信号强度和注意力。

这里更广泛的论点是，关于GWT的证据因有意识与无意识状态之间表现差异而受到混淆（Morales等，2022）。导致全局广播的点燃与许多任务中的更好表现相关；在缺乏对照的情况下，更好的表现也与意识相关。但由于实验似乎表明表现与意识是可以分离的，因此有可能点燃既不是意识的必要条件，也不是充分条件（Fleming，2020；Lau，2022）。

2.3.3 来自计算性高阶思维的指标

正如我们所见，PRM认为，当感知状态被元认知监控机制认定为可靠时，它们就是有意识的。该机制会输出高阶表征，将一阶状态标记为对现实的准确表征。类似地，HOSS也认为，意识取决于以感知表征为导向的高阶觉知状态。因此，这两种理论都表明，对于人工智能中的意识而言，对具有相关属性的感知系统的元认知监控是必要的。

我们基于这一主张提出了两个指标：

热门-1：生成式、自上而下或嘈杂的感知模块

HOT-2：元认知监控区分可靠的感知表征与噪声

HOT-1 是意识的一个指标，因为根据计算型 HOTs 的观点，负责意识的监控机制的功能是区分感知系统中不同活动来源。这意味着，在存在多种可能活动来源的系统中，意识更有可能出现。这类系统的例子包括：在其中感知表征能够自上而下地在想象中产生，以及受随机噪声影响的系统。HOT-2 是计算型 HOTs 关于意识的主要必要条件的表述。

Lau (2022) 指出，生成对抗网络（GANs）可能具备这两种指标，我们在第 3.1.3 节中将进一步探讨这一可能性。然而，PRM 主张，当前的人工智能系统并不符合其理论的条件（Michel & Lau 2021，Lau 2022）。他们强调，感知现实监控系统必须具备另一项特征：除了能够区分不同的感知状态之外，感知现实监控机制还必须向一个“普遍信念形成与理性决策”系统输出信息（Michel & Lau 2021）。这一条件的理由在于，意识体验具有一种特定的“断言性力量”。我们的一些意识感知体验会以准确反映外部世界的印象呈现在我们面前，我们很难抗拒相信这些体验所呈现的事物就是真实的。9 即使我们意识到自己可能处于某种幻觉之中，我们对意识体验所呈现的世界真实性的印象依然存在——了解这一点

9 想象体验是一种例外，但PRM可以声称，它们被现实监控机制以不同方式分类，因此具有不同的现象特征。或者，像HOSS和PRM这样的高阶理论可以认为，想象体验具有一些最低限度的断言力，从而解释了这样一些实验结果：如果目标与参与者的心理意象一致，他们更有可能报告该目标是可见的（Dijkstra等人，2021、2022；Dijkstra与Fleming，2023）。

穆勒-莱尔错觉并不会阻止两条线看起来不相等。这种体验是持续作用于认知的输入，而这些输入并不受直接的认知控制。

这个想法的另一个方面是，之所以监控机制会将某些知觉内容标记为“真实”，是因为当这些内容被标记为“真实”时，人或整个系统倾向于将其视为真实。这就意味着，包含监控机制的系统必须是一个智能体，它在选择行动时依赖于那些被标记为“真实”的知觉表征。因此，现实性监控机制的作用就在于识别哪些知觉状态足够准确，可以以这种方式加以信赖。PRM的支持者提出，依赖知觉内容就是相信这些内容——按照他们对信念的理解，这表明了一种具有整体性的推理与行动选择系统，在这种系统中，任何信念原则上都可以被用于检验其他信念，或者用于推理该采取何种行动。这些主张为我们提供了由HOTs引出的第三个指标：

HOT-3：由一般信念形成和行动选择系统引导的智能体，以及根据元认知监控的输出更新信念的强烈倾向

计算型HOTs还提出了一个进一步的主张，从而得出第四种指标。与大多数关于意识的科学理论一样，PRM旨在回答这样一个问题：“是什么使一种状态具有意识，而非无意识？”然而，它也试图回答另一个更深层次的问题：“为什么有意识的心理状态会呈现出它们所具有的感受方式？”对于这个问题，PRM诉诸于“品质空间理论”，该理论认为，现象学品质可以还原为系统所允许的辨别能力（Clark 2000，Rosenthal 2010，Lau et al. 2022）。例如，两种特征之所以感觉相同，是因为从系统的角度来看，它们是无法区分的（Rosenthal 2010）。根据这一主张，两种经验的主观相似性与其可辨识性成反比，而主观品质的体验则依赖于对相似性空间的隐含知识。因此，品质空间理论提供了一种功能性的品质解释（参见Lau et al. 2022）。例如，要对郁金香的红色产生有意识的体验，就必须隐含地把握它与红苹果颜色的相似性，以及它与新叶绿色之间的可辨识性。一种假设是，这种隐含知识依赖于感知系统中的稀疏和平滑编码——也就是说，品质由相对较少的神经元来表征，并且采用连续编码方案，而非将刺激划分为绝对类别（Lau et al. 2022）。

重要的是，PRM声称，没有属性就不可能有意识，因此，尽管品质空间理论并非一种关于什么使状态具有意识的理论，但该理论所提出的假设却是意识的必要条件。因此，我们从HOTs得出的最终指标是：

HOT-4 稀疏且平滑的编码生成“质量空间”

在人工智能领域，这一条件可能相对容易满足：所有深度神经网络都使用平滑的表示空间，而且稀疏性也可以通过熟悉的机器学习技术实现（参见第3.1.3节）。

2.4 其他理论和条件

已提出了许多关于意识的科学理论（有关列表，请参阅Seth & Bayne 2022）。此外，还有一些颇具影响力的理论主张，它们并不完全是关于意识的理论，但与我们的研究密切相关。另外，可能存在一些对意识而言是必要条件，这些条件并未在科学理论中明确强调，因为所有人类都具备这些条件（例如拥有身体），但在人工智能的背景下却需要加以考虑。在本节中，我们首先概述了几种相关的理论、主张和条件，然后在第2.5节中介绍我们的指标。

我们下面不讨论的一种理论是整合信息理论（IIT；Oizumi 等，2014；Tononi & Koch，2015）。IIT的标准解释与我们所采用的计算功能主义假设不相容；Tononi 和 Koch（2015）认为，如果一个系统的组成部分类型不对，即使它实现了与人脑相同的算法，也不会具有意识。与此相关，IIT的支持者声称，该理论意味着无论运行何种程序，数字计算机都不太可能具有意识（Albantakis & Tononi，2021）。因此，与其他科学理论不同，IIT并不暗示基于传统硬件构建的一些人工智能系统会比其他系统更有可能具备意识；这使得它与我们的研究项目关联性较小。最近有人提出，信息整合度量可能与“全局意识状态”相关，例如清醒、睡眠和昏迷——这种范式被称为“弱IIT”（Michel & Lau，2020；Mediano 等，2022）。然而，弱IIT对我们项目的启示有限：它表明整合与分化这些可测量的属性对意识至关重要，但目前尚无法告诉我们应依赖哪些度量，以及如何解读这些度量应用于人工系统时的结果。

2.4.1 注意模式理论

意识注意模式理论（AST）认为，人脑会构建一个注意模型，该模型能够表征——也可能歪曲——当前注意对象的相关事实。这个模型有助于大脑控制注意力，其作用方式类似于身体模式对身体运动的控制。意识体验依赖于注意模式的内容。例如，如果注意模式表征我当前正关注着一个苹果，那么我就会产生看到苹果的意识体验（韦布与格拉齐亚诺，2015；格拉齐亚诺，2019a）。注意模式理论认为，注意模式的运作机制解释了我们对自身体验的直觉：由于注意模式并未详细表征注意力的机制，该理论指出，我们似乎以一种直接且看似神秘的方式与刺激（例如苹果）产生了关联。

可以将AST视为一种高阶意识理论，因为它声称意识依赖于特定类型的高阶表征（在本例中，即我们注意力的表征）。与其他高阶理论一样，它特别强调我们对自己心理状态的觉知。然而，与大多数高阶理论不同，AST的开发初衷正是为了阐释我们关于意识的信念和言论，例如我们是有意识的，以及意识似乎难以与世界的物理描述相协调（也就是说，AST旨在解决意识的元问题——参见查尔莫斯2018年）。

格拉齐亚诺 2019b）。由于它侧重于解释我们为何（可能错误地）相信有关意识的某些事情，AST 可被理解为一种试图解释消除 意识的尝试。但它也可被解读为对意识条件的一种阐述。

AST 为我们提供了人工智能意识的进一步指标：

AST-1：一种预测模型，用于表征并实现对当前注意力状态的控制

表征当前的注意状态，能让大脑同时了解注意所产生的影响，以及注意如何受到心智和环境中的事件所影响。因此，拥有一个模型能够使大脑更容易学会采取那些会改变注意状态的行为，因为这些行为会对其他认知过程产生有益的影响。尤其值得一提的是，预测性模型价值非凡，因为它能让大脑根据心智或环境的变化，预先推测注意对象可能发生的改变，并据此做出相应调整。这些调整甚至可以是预防性的，例如当预计会出现对重要任务的分心时。类似注意模式的模型，能够有效控制注意力，对于日益增多的采用注意力机制的人工智能系统而言，具有重要意义——这里的“注意力”被理解为对信息流的主动控制（Liu et al. 2023）。

2.4.2 预测处理

预测性处理（PP）被提出作为一种全面而统一的人类认知理论，并已被用作解答诸多心智问题的框架。由于它是一个通用框架，一些预测性处理理论家将其描述为一种关于意识的理论，而非一种对意识的理论（Seth & Hohwy 2021，Seth & Bayne 2022）——这是一种用于发展意识理论的范式。然而，预测性处理的支持者已利用这一框架来解释许多具体意识体验的特征，例如“感受质”令人费解的本质（Clark 2019），以及情绪和具身性的现象学（Seth 2021）。尽管预测性处理理论家对意识进行了广泛讨论，但相对而言，针对我们所关注的最重要问题却鲜有直接探讨：究竟是什么区分了有意识系统与无意识系统，又是什么区分了有意识系统内部的有意识状态与无意识状态（Deane 2021，Hohwy 2022，Nave et al. 2022）。

PP认为，人类和动物认知的本质是通过一种分层生成模型最小化预测感官刺激时所犯的错误。在感知过程中，该模型会持续地在多个层级上生成预测，每一层级的预测都受到相邻层级及近期预测的影响，同时也受到源自感官刺激本身的预测误差信号的影响。这一过程受到注意力的调节，并且根据“主动推断”的理论，它还能控制行为，因为行动本身可以成为降低预测误差的一种手段。如果生物体能够预测到自身的成功，就会选择适应性行为（弗里斯顿，2010）。

尽管PP并非一种意识理论，但它的流行意味着许多研究人员认为预测性处理是意识的一个合理的必要条件。因此，我们将在我们的指标中纳入预测编码的使用：

PP-1 使用预测编码的输入模块

根据“意识理论”的思想，PP框架已被应用于GWT和HOT的开发。Hohwy（2013）和Whyte（2019）提出，当感知推理过程确定某种环境状态表征为最可能时，就会发生全局广播（通过点燃），然后将该表征作为主动推理的基础提供出来。与此同时，高阶状态空间理论采用了PP框架（Fleming 2020）。

2.4.3 中脑理论

尽管我们迄今所讨论的意识的神经科学理论主要关注皮层过程，但默克尔（2007）认为，皮层并非意识所必需。这一观点在近期关于非人类动物意识的讨论中尤其具有影响力。默克尔提出，中脑和基底神经节某些区域的活动构成了“一种统一的多模态神经模型，用于表征主体在其环境中的状态，并根据主体当前的需求和状态进行加权”（克莱因与巴伦，2016），而这种活动足以产生主观体验。在默克尔的理论中，中脑的一个区域——上丘，整合了来自空间感官和前庭系统的信息，以构建机体在空间中的位置和运动模型。其他区域，包括下丘脑、导水管周围灰质以及基底神经节的部分区域，则输入有关机体生理状态的信息，并有助于识别机会和选择行动。从功能角度来看，中脑理论认为，意识依赖于“时空整合建模”来进行行动选择（克莱因与巴伦，2016）。

伯奇（2022b）总结并批判了支持中脑理论的证据。就我们的目的而言，这一点值得注意，因为它为认知整合对意识的重要性提供了一种独特的视角。中脑理论提出，意识所必需的整合功能是为了应对复杂运动动物在生物学上由来已久的决策问题而产生的，尤其是区分自我引发的运动对感知输入的影响这一需求（默克尔，2005）。因此，中脑理论强调需要将特定类型的信息——例如空间信息、情感信息和体内平衡信息——整合到一个单一的共同模型中。由此，该理论为我们提供了更多理由，相信用于身体在空间中进行有目的导航的系统对于意识是必要的，从而进一步支持我们在第2.4.5节中提出的指标。

2.4.4 无限联想学习

动物意识文献中另一个有影响力的理论是金斯堡和雅布隆卡（2019）提出的无限联想学习框架（伯奇等，2020）。该理论认为，无限联想学习（UAL）的能力是一种进化“过渡标志”，标志着某一谱系已发生向意识的进化转变：单一特征即可表明某一谱系已实现向意识的进化过渡。金斯堡和雅布隆卡将UAL确定为一种标志，理由是它需要结合若干“标志性特征”，而这些特征被论证共同足以构成生物体的意识。因此，UAL框架汇集了一系列似乎与意识相关的特征，并主张这些特征因促进了UAL而得以统一。

与本报告有些类似，UAL项目旨在确定一组共同充分的意识条件。这组条件总结在下表中（该表遵循Birch等人2020年对这些条件的表述）。

UAL 所定义的意识特征
整合感官、评估和记忆信息的全球可访问性 选择性注意
通过短期记忆的形式进行时间整合 身份认同与能动性
自我-他者注册，用于构建空间中运动身体的表征
能够重新评估和权衡需求的灵活价值系统；将特征绑定/统一以形成复合刺激，从而实现对复杂模式的辨别。
意向性，即身体和环境的表征

这一系列条件与我们在本节工作中所提出的条件类似（和我们一样，金斯堡和雅布隆卡在制定他们的清单时也考察了关于意识的科学理论）。全局可访问性和选择性注意这两个条件，由实现全局工作空间架构的系统来满足。时间上的整合条件也可能满足；我们将在2.4.6节中讨论时间上的整合问题。其他几个条件则与主体性和具身性相关，我们将在2.4.5节中加以讨论。这些条件不仅包括具身性和主体性本身，还包括自我-他者识别（这也与中脑理论相吻合），以及拥有灵活的价值观体系。我们认为，任何基于神经网络的人工智能系统都将满足绑定/统一条件，因为这类系统的设计目的就是学会区分复杂的模式。最后一个条件——系统应能表征自身身体及环境——引发了有关意向性的哲学问题，我们在此就不展开讨论了。不过，任何自然主义的意向性理论都极有可能推论出：满足其他条件的系统也将满足这一条件，因为其他条件本身就蕴含着能够支撑意向性的功能的实现。

那么，无限联想学习本身的能力又如何呢？这或许可被视为人工系统具备意识的一个指标。在UAL框架中，这种能力被定义为一种开放式联想学习能力。具体而言，要具备这种能力，有机体必须能够对复合刺激和新刺激进行条件反射，并能快速而灵活地更新其与刺激、行为和结果相关的数值。此外，它还必须具备二级条件反射能力，即能够将一系列联想连接起来；以及追踪条件反射能力，也就是在刺激之间存在时间间隔时仍能习得关联。因此，具备无限联想学习的能力意味着，一个有机体或系统能够跨模态、跨时间整合信息，并且能够评估刺激并根据新信息改变这些评估。

因此，这种能力也与我们的许多指标相关联。GWT 强调整合来自不同模态的信息以及灵活学习。PRM 也通过要求一种通用的信念形成和决策系统来提出类似的能力，该系统接收来自任何感官模态的输入，并接受元认知监控。评估和

评估性学习与主体性密切相关。将主体性与暗示整合性和灵活性的指标相结合的人工智能系统，可能尤其适合作为意识的候选者，因为它们将具备与UAL认为最有可能具有意识的动物相似的显著认知能力。此外，如果一种架构如GWT或PRM所描述的那样，能够促进灵活的学习，那么这种架构或许就是意识的特别有力证据。

然而，人工智能系统有可能以不同的方式实现无限联想学习的能力——所采用的架构既不同于GWT等理论所描述的架构，也不同于具备这种能力的动物所拥有的架构。这些系统可能具备这种能力，却并不具备金斯堡和雅布隆卡所确定的意识的一些典型特征。这将削弱针对此类系统中存在意识的论点，从而令人怀疑UAL本身是否能作为人工系统中意识的良好指标。另一个原因是，UAL假设的地位与我们所考虑的其他理论截然不同：它并非声称能够揭示意识体验背后的机制，而是声称能够识别生物体中意识的行为标志。基于这些原因，我们并未将无限联想学习的能力纳入我们的指标列表。

2.4.5 代理与体现

当前的人工智能系统与人类和其他动物对环境的互动方式往往大相径庭，有人认为，这些差异恰恰证明了此类系统缺乏意识。例如，让我们来看看著名的图像分类器AlexNet（Krizhevsky等，2012），这是一种相对较小且简单的深度神经网络，通过监督学习进行训练。我们通常认为具有意识的生物与AlexNet截然不同：它们是追求目标并做出选择的主体；它们是有生命的、拥有身体的；并且它们持续地与环境互动，这种互动涉及在短时间内存储和整合信息。相比之下，AlexNet的功能仅限于对图像进行分类，它既不采取行动，也不追求任何目标。从物理实现的角度看，定义它的权重和其他特征确实存储在物理存储设备中，但它并没有实体的身体。此外，AlexNet处理的输入在时间上彼此分离且相互独立，其前馈过程产生的输出也不会改变系统的状态。在本节及接下来的几节中，我们将探讨，在人类与某些人工智能系统之间这些“宏观”差异中，是否还能发现更多表明意识存在的指标。

正如本节所见，科学家和哲学家们曾论证，与主体性和具身性相关的各种属性对于意识而言是必要的。我们综述了其中一些论证，确定了可能的指标，然后讨论了这些指标是否能够以与计算功能主义相一致的方式进行表述。最后，我们通过在列表中再添加两个指标来结束本小节。

2.4.5(a) 代理

支持意识需要代理性的论点之一是，许多科学理论都隐含了这一点。我们所讨论的大多数意识理论都做出了一些

对机构的引用。

PRM特别明确地指出，主体性是意识的必要条件。PRM认为，能够区分感觉信号与噪声的子系统必须向“普遍的信念形成与理性决策系统”输出信息（Lau & Michel 2021）。该理论建立的基础理念之一是，有意识的感知体验具有一种“断言力”，这种断言力可被解释为信号作为输入持续作用于该决策系统的某种特性，或表现为一种强烈倾向于形成相应信念的倾向。在大多数哲学观点中，信念与其他表征的区别部分在于它们被用于决定如何行动（Stich 1978，Dretske 1988，Schwitzgebel 2021）。我们已经提出了一种指标来体现PRM的这一方面，但关键仍在于，主体性是该理论所提及功能的前提条件。

中脑理论明确要求具备主体性，因为它声称中脑的功能是整合信息以进行行动选择；GWT同样强调主体性，但并未如此明确地指出这是必要的。德海恩和纳卡什（2001）认为，全局工作空间中的表征对于信息能够用于有意行动是必需的，这与他们将GWT呈现为一种关于访问意识的理论相符，从而也说明了信息对理性主体性的可用性。UAL假说则主张，“主体性和具身性”以及“灵活的价值体系”（伯奇等人，2020）是意识的显著特征。

在哲学中，也有独立的论点认为，意识需要主体性（Evans 1982，Hurley 1998，Clark & Kiverstein 2008）。Hurley（1998）声称，意识需要有意图的主体性，她将其具体表述为一种具有以下特征的主体性：

> . . . [系统的行动整体上取决于它所感知与意图之间，或它所相信与渴望之间的关系。刺激与反应之间的关系并非一成不变，而是反映了它所感知与意图之间的合理关系以及各种可能的错误或误传。（第137页）

赫利提出这一主张的依据与意识的感觉运动理论以及具身认知和参与式认知理论相关，我们将在下文进一步探讨这些理论。一个关键观点是，意识需要对环境的一种视角或立场，而具身的能动性能够产生这种视角。赫利还指出，成为有意识的一部分在于能够访问自身意识体验的内容，而这又要求具备根据这些内容进行有意行动的能力。然而，其他哲学家则认为，至少在概念上存在这样的可能性：某些完全无法行动的实体也可能拥有意识体验（斯特劳森 1994，贝恩等人 2020）。

这些考量提出了三种可能的意识指标（此外，还有由PRM提出的指标HOT-3）。它们分别是：成为任何类型的主体；拥有灵活的目标或价值观，正如UAL的支持者所建议的那样；以及成为有意图的主体，正如赫利所建议的那样。后两者严格强于前者，但这本身并不意味着应排除任何一种指标。有可能的是，一般意义上的主体比非主体更可能是意识的有力候选者，而有意图的主体（例如）也比其他主体更可能是意识的有力候选者，在这种情况下，主体性和有意图的主体性都将被……

有用的指标。

在他们经典的AI教科书中，Russell和Norvig写道：“智能体是指任何能够通过传感器感知其环境，并通过执行器对该环境采取行动的事物”（2010，第34页）。这是一个非常宽泛的智能体定义。AlexNet满足这些条件——事实上，所有人工智能系统都满足这些条件——许多简单的工具，比如恒温器，也同样满足。因此，就我们的目的而言，这种智能体的概念过于宽泛了。

可以通过在罗素和诺维格的论述中增加三个条件，来定义一种更实质性的智能体概念。首先，一个系统输出影响其后续输入，这是智能体的一个合理条件。如果没有这一点，系统只能单独对输入做出反应，而无法与环境互动。AlexNet并不满足这一条件，因为一般来说，它所生成的标签并不会影响它随后接收到的图像。这与第二个条件相关，即智能体追求目标。我们通常认为，这意味着智能体与环境持续互动，其中输出的选择是因为它们能使系统更接近目标——也就是说，这些输出会改变环境状态，进而影响智能体自身的输入，从而使得未来的输出能更轻松地实现目标。

第三个条件是，该系统必须学会产生有利于目标的输出。德雷茨克（1988，1999）强调了这一点，他认为，只有当一个系统的输出能够被其自身对产生该输出的益处的敏感性所解释时，这个输出才算是行动。系统以这种方式对益处保持敏感，就体现在它学会了产生有益的输出。德雷茨克的观点是，这区分了动物的一些行为——他将这些行为视为具有能动性——与植物的行为：植物已经进化出以特定方式对刺激作出反应的能力，而非通过学习来实现这种反应；也区别于像恒温器这样的人工制品，它们的设计目的就是产生特定的反应。类似地，罗素和诺维格指出，如果一个智能体的成功依赖于其设计者对该任务的先验知识，则该智能体便不具备自主性（2010，第39页）。

强化学习（RL）研究明确旨在构建追求目标的人工智能体（Sutton & Barto 2018），典型的强化学习系统满足上述所有三个条件。在强化学习中，任务是在与环境交互的一段时期内，最大化累积奖励，而系统的输出会影响其后续输入。因此，有充分理由认为，典型的强化学习系统符合关于智能体的实质性标准（Butlin 2022, 2023）。10 然而，这并不意味着强化学习是实现智能体所必需的——还有其他方法可以让系统通过反馈学习，更有效地追求目标。同样重要的是，此处提出的智能体标准相对而言较为宽松。

根据UAL倡导者们的观点，智能体的目标或价值观存在两种灵活的方式（Bronfman等，2016；Birch等，2020）。一种方式是，智能体能够习得新的目标，例如通过经典条件反射，其中一种新刺激可以通过与智能体已有的、有价值的刺激建立关联而获得价值。另一种方式是，智能体的目标和价值观会对其不断变化的需求保持敏感，比如在动物的偏好会根据其体内稳态状况而改变的情况下。对这两种灵活性的要求都比对智能体能力的要求稍强一些，尽管即便是非常简单的智能体也往往具备经典条件反射或习惯学习的能力，在这种学习中，新的行为会得到强化。

10一种可能的例外情况是所谓的“赌徒”系统，它们从奖励信号中学习，而这些环境中的输出不会影响后续输入。

有更充分的论据表明，第二种灵活性与意识相关：它可能需要一种集中式架构，在这种架构中，多个与价值相关的信息源被整合起来；同时，这也意味着，必须对不同种类状态的动机意义进行比较——这些状态与不同的目标或价值相关。科学和哲学文献中的一种观点认为，意识效价——即意识体验令人愉悦或不愉悦的程度——可以构成一种“通用货币”，从而使得此类比较成为可能（Cabanac 1992，Carruthers 2018）。因此，可以说，对相互竞争的目标做出灵活反应，才是最具说服力的。

阐明意图性主体这一概念的一种方式是，通过动物行为研究中对“目标导向”与“习惯性”行为的区分，来展现行动依赖于类似信念和类似欲望的状态之间的理性关系（Heyes & Dickinson 1990）。在目标导向的情形下，动物能够独立地习得关于某一结果的价值以及可能导致该结果的行为的知识。随后，它可将这些知识与其他行为和结果的信息相结合，通过工具性推理做出选择。因此，行动整体上取决于动物的“信念”和“欲望”。计算神经科学将动物的目标导向行为选择解释为基于模型的强化学习的实现（Dolan & Dayan 2013）。按照这种理解，赫利所强调的意图性主体与PRM所要求的主体形式相似。对于PRM而言，重要的是主体依赖于一组表征的准确性，而这些表征类似于信念，因为它们被用于工具性推理以进行行动选择。这赋予了现实监控其功能：由感官刺激引发的感知系统中的准确表征应被用来更新这一组表征，而那些与现实无此关联的表征则不应被使用。

2.4.5(b) 实施方式

在代理的最小化概念和意图性概念中，似乎存在一种可能性：一个系统可以成为代理，却无需具身化。例如，让我们考虑AlphaGo——首个击败世界顶级人类围棋选手的人工智能系统（Silver等，2016）。AlphaGo是一个代理，但它并不具备那些似乎区分具身化系统的特征。具身化系统位于其环境中的特定位置，它们所能采取的动作和所获得的观察都受到自身位置的限制。此外，它们通常拥有相对复杂的执行器，为了实施有效行动，必须在较长的时间内持续控制这些执行器。它们的输出表现为运动，而这些运动会对自身的输入产生一些直接且系统性的效应——比如，转动头部会对视觉输入产生系统性影响——同时也存在一些不那么直接的影响。这些观点在克拉克（2008，第207页）关于具身化的哲学论述中有所描述，他写道：

> . . . 身体是……意志行动的 locus，感觉运动交汇的焦点，智能卸载的入口，以及一个稳定（尽管并非永久固定）的平台，其特征和关系可在某些智能表现背后的计算中被依赖（而无需加以表征）。

这里“智能卸载”的要点是指具身与扩展认知的论点：具身智能体可以利用其身体和环境的诸多特性

使他们面临的认知任务更易于处理的方法，例如通过在环境中记录信息。

被认为与意识有关的一种实现方式是拥有赫利（1998）所称的“视角”。这同样需要主体性。根据赫利的说法，

> 拥有视角意味着，你在某种程度上所经历和感知的一切都系统地取决于你的行为，反之亦然。此外，这还涉及持续追踪……你所经历和感知的一切如何取决于你的行为。（第140页）

对于在环境中移动的具身智能体而言，感官输入可能会发生变化，原因要么是环境本身发生了变化，要么是智能体自身在环境中主动或被动地改变了位置。为了区分这两种情况，智能体必须追踪自身的主动运动，并学习这些运动如何影响感官输入。这将使智能体能够预测自身行为所带来的感官后果——这些后果通常与运动紧密相关，从而将其与环境中外生的变化区分开来。被动运动同样可以被区分出来，因为它们会在输入中引发一些特有的变化，而这些变化正是缺乏相应输出时运动所特有的。这些功能涉及智能体隐含地将自身（位于运动身体中的自我）与智能体所处的环境区分开来。意识或许要求主体对环境拥有单一的视角或观点；本理论旨在解释具身智能体如何产生这种视角（赫利，1998；梅克尔，2005；戈德弗里-史密斯，2019）。

与此相关，根据感知意识的感觉运动理论，有意识的体验是与环境相互作用的活动，这些活动构成了隐含的、实践性的感觉运动知识的运用（赫利，1998；奥雷根与诺，2001；诺，2004；基弗斯坦，2007）。感觉运动知识的一个简单应用就是转动头部，以便从不同视角观察某个物体。正如赫利所提出的，这一理论暗示，学习输出-输入关联的模型并在感知中使用该模型，是意识的必要条件。中脑理论还指出，意识与体内自我在环境中所拥有的整合模型的存在相关联，这种模型用于感知、行动选择和控制。

然而，为了捕捉体现而非单纯代理的概念，我们需要进一步明确输出-输入模型的特征——这种模型也可称为“转换模型”或“前向模型”。AlphaGo，我们所举的一个非体现型智能体的例子，在蒙特卡洛树搜索中使用了这种形式的模型。蒙特卡洛树搜索是一种规划算法，涉及评估可能行动的预期后果。

具身系统中的输出-输入模型可能具有独特性的一个方面，就是能够表征运动对感官输入产生的直接且系统的效应。这种条件并不一定适用于围棋系统，因为它们接收到的每个输入都可能受到对手走法的影响。此外，具身系统在使用此类模型的方式上也可能独具特色。在感知中采用输出-输入模型以区分内生变化与外生变化，就是一个可能的典型用法，因为当感官输入依赖于运动身体的位置和方向时，这种区分是必需的。

使用输出-输入模型的第二种方式，可能正是具身系统所特有的，那就是运动控制。具身系统通常拥有具有多个自由度的执行器，这些执行器必须以精确且灵敏的方式进行控制。有观点认为，前馈模型（在该文献中称为“前馈模型”）在这一情境下具有若干特定用途（Miall & Wolpert 1996，McNamee & Wolpert 2019）。特别是，前馈模型能够帮助具身智能体在行动过程中估计并调整其执行器的位置，方法是提供每个时刻预期位置的表征。这些预期与来自感官反馈或目标状态内部表征之间的差异可用于在线调整。

除了代理性和具身性之外，意识的另一个可能的必要条件是：有意识的系统必须是自我生成、自我维持的“自生系统”（马图拉纳与瓦雷拉，1991；汤普森，2005，2007；塞思，2021；阿鲁等人，2023）。也就是说，它们必须通过自身的持续活动来维持自身的存在和组织。这一特征正是生命体所特有的：生命体不断地自我修复，并以体内稳态的方式调节自身的体温以及组织中各种化学物质的平衡。自我维持的活动通常——或许总是——涉及“原认知”层面的感知与反应过程（戈德弗里-史密斯，2016）。持这一观点的人士援引了诸如代理性、自我性和自主性等概念，论证自我维持对于意识而言是必不可少的。例如，汤普森（2005）写道：

> 这个自我生成的组织定义了系统的身份，并确定了其相对于环境的视角或观点。以这种方式组织的系统会实施或产生对它们而言算作信息的东西；它们并非将输入指令转换为输出产品的换能器或函数。正因如此，用“自我”和“能动性”的概念来描述它们是合理的。（第418页）

同样对预测处理抱有同情态度的人，比如塞斯（2021），认为生物组织中的自我维持与大脑中预测误差最小化的过程类似——二者都是自由能最小化或“自我证实”的实例（霍维2022）。更务实地说，从事自我维持为系统建模自身状态提供了额外的理由，这与拥有灵活的目标相关联，并且可以说为自我和环境的表征增添了一个效价维度。然而，在后一点上，尚不清楚为何服务于自我维持的能动性应当与指向“外部”目标的能动性区分开来。

在此思路的基础上，戈德弗里-史密斯（2016）认为，自我维持活动之所以能够轻易实现，完全得益于分子在纳米尺度上浸没于水中的行为方式。在这一尺度上，存在着持续的随机活动，在这种背景下，这些活动可以被有效调动起来以支持代谢过程。基于此，戈德弗里-史密斯提出，人工系统只能与生物体在粗粒度的功能上具有相似性，而这种相似性不足以产生意识。因此，另一个被提出的必要条件是：一个具备意识的系统必须经历在纳米尺度上实现的代谢过程。曼和达马西奥（2019）也指出，自我维持乃至意识的产生，可能取决于系统的特定物质组成。

2.4.5(c) 代理和体现指标

意识取决于物质构成这一主张显然与计算功能主义不相容，因此我们可以将其搁置一旁。然而，我们所讨论的其他主张与计算功能主义的兼容性则要复杂得多。在每种情况下，问题都是一样的：所谓指标的自然表述会提及系统外部的条件。如果一个相似的系统能够在不同的外部条件下执行相同的计算，那么这种表述就与计算功能主义不相容。

例如，考虑这样一种说法：自我维持对于意识是必要的。假设一个系统要以相关意义实现自我维持，就必须部分地持续存在，因为它会跟踪某些输入或内部状态，并采取行动对它们进行调节。似乎对于任何具备这种功能的系统，都可能存在另一个系统，它执行着完全相同的计算——跟踪相同的输入或内部状态，并用同样的输出来调节它们——但却并非出于这个原因而持续存在。也许该系统的作用是防止“能量指标”降得太低，但实际上，即使这一指标降至零，该系统依然会持续存在；而且它的能量是由外部操作者提供的，这种能量供应方式并不依赖于系统的自身行为。

如果意识需要代理或体现，那么这些条件可能出于类似原因而与计算功能主义不相容。这些条件要求系统的输入对其输出敏感。但从原则上讲，一个系统完全有可能存在于这样一种环境中：它的输入并不依赖于其输出，却偶然地接收到与这种依赖关系一致的输入和输出模式。这样的系统或许能执行与真正与其环境交互的系统相同的计算。

为避免这种不兼容性，有关代理、视角或自我维持的指标应“狭义”地制定，即不涉及外部条件。例如，与其说一个系统通过与环境交互来追求目标时更有可能具有意识，不如说它通过从反馈中学习并选择行动，以这种方式 与环境交互来追求目标时更有可能具有意识。同样，我们可以说，如果一个系统拥有对其输出如何影响输入的模型，该模型能体现某种系统性效应，并在感知或控制中使用这一模型，则该系统就是具身的。从某种意义上讲，即使这个系统已经学会了这种模型，它也可能错误地将自己表征为具身代理，因为其过去观察所暗示的看似系统的偶然性可能只是巧合。然而，只有那些足以支持意识的具身条件才与计算功能主义相一致。值得注意的是，这种对具身性的解释允许控制虚拟化身的系统也可被视为具身的。

在本节中，我们已经看到了一些可添加到我们列表中的指标。这些指标包括：成为智能体；拥有灵活的目标或价值观；成为有意图的智能体；拥有视角；拥有身体；以及能够自我维持。然而，也有一些理由需要排除其中部分指标。我们已经有一个指标要求具备相对复杂的智能体形式，并带有类似信念的表征：即源自PRM的指标HOT-3。一个有意图的智能体指标与这一指标会过于相似。尽管可以提出一种狭义的自我维持指标，这种指标与计算功能主义相兼容，但这将违背强调自我维持的哲学理论的精神。成为智能体和拥有灵活的目标这两个概念密切相关，而灵活的目标主要通过以下方式增添.....

意识的论证是通过集中化和共同激励货币的论点来进行的，因此我们将它们合并为一个指标。

因此，我们采用以下两个进一步的意识指标：

AE-1 机构：从反馈中学习并选择输出，以实现目标，尤其是在涉及对相互竞争的目标灵活响应时

AE-2 实施例：建模输出-输入偶发性，包括一些系统效应，并在感知或控制中使用该模型

2.4.6 时间和重复

人类的意识体验似乎在时间上高度整合。我们似乎会经历一些本身就在时间上延展的体验，从而形成对时间延展现象的意识感知，比如当我们听到鸟儿的鸣唱，或注视它从一个栖息处飞到另一个栖息处时。此外，从每天醒来那一刻起，我们似乎就经历着数小时连续而整合的体验流。无论这种体验特征是否应以记忆来解释（Dainton 2000，Phillips 2018 b），我们的意识体验似乎也深受记忆的影响。这种整合或许可以被视为质疑在活动由离散时间前向传播构成的神经网络中是否存在意识的一个理由；如果设想每次传播之间存在漫长的间隔期（数周、数年），这一点尤其明显。然而，针对这一反对意见，我们可以提出若干回应。

一种回应是，意识是否必然随时间整合并不明显。患有严重失忆症的患者似乎经历了一系列短暂而互不连贯的体验（威尔逊等人，1995年）。这些体验或许并非静态的，但似乎可以想象一种意识存在，它只拥有一系列短暂、静态、离散的体验。关于是什么使得这些体验成为单一主体的体验，仍存在疑问；然而，也并不明显的是，随时间整合是意识体验主体持续性的唯一可能依据，或者不存在具有持续主体的意识系统。

此外，人类经验看似具有时间连续性，其实可能只是一种错觉。哲学家和科学家就我们的经验如何随时间产生提出了各种观点（Dainton 2023），其中一种观点认为，我们经历的是快速相继发生的离散、静态的体验，这些体验源自对无意识活动的采样（VanRullen 2016，Herzog 等人 2020）。普罗瑟（Prosser 2016）将这种观点称为“动态快照”观。离散体验的内容可能受到无意识信息保持的影响，即使本身是静态的，也能表征变化。例如，当我观察一只鸟时，我可能会经历一段短暂的静态视觉体验，它不仅反映了鸟处于某个特定位置，还反映了鸟正以某种方式移动。根据这一模型， successive experiences之间并不存在特殊的整合过程，因为这种整合现象的出现，可以被解释为它们以相当高的频率从平滑变化的无意识感知活动中采样而来，而这些无意识活动又反映了环境中平滑连续的变化。

尽管存在这些要点，似乎算法递归（即机器学习中通常所理解的递归；参见第2.1.3节）对于有意识的体验可能是必要的。

具有类似人类的时间特征的经验。为了使意识经验以某种方式表征环境中的变化或连续性，必须保留有关过去的资讯，并利用这些资讯来影响当前的处理过程。这进一步说明了为何将算法递归视为意识的指标，正如我们的指标RPT-1所表达的那样。时间上的整合，因此也是递归处理，同样受到中脑和感觉运动理论、UAL框架以及一些PP理论家的强调。

2.5 意识的指标

我们在第2.1至2.4节中讨论的每一种理论和提议，对于评估某个特定人工智能系统是否可能具有意识，或者在不久的将来构建出具备意识的系统有多大可能性，都具有一定价值。它们各自都得到了一些有力证据和论证的支持。作为本报告的作者，我们对支持每种理论的证据和论证的强度持有不同看法，同时我们也拥有不同的关于意识的背景观点，这些观点影响着我们对近期人工智能实现意识可能性的评估。在此，我们通过列出从我们所讨论的理论和提议中提炼出的意识指标，来总结第2节的研究发现。

我们关于这些指标的主张是，它们共同构成了一套框架，该框架以当前意识科学领域的观点为依据，用于评估特定人工智能系统具备意识的可能性。拥有更多此类特征的系统，更有可能具备意识。有关意识的理论提出了比这更强烈的主张，例如，其中一些特征是意识的必要条件，而某些特征组合则共同构成了充分条件。我们并不支持这些更强的主张，但我们确实认为，在使用这些指标时，应当注意它们与相关理论以及彼此之间的关系——某些指标组合所形成的证据，比其他组合更能有力地证明意识的存在。此外，这些指标各自单独提升概率的程度也各不相同，其中一些指标很可能是必要的条件，但单独存在时并不会显著提高意识出现的概率（或许包括RPT-1、GWT-1和HOT-1）。

重复加工理论	
RPT-1：使用算法递归的输入模块 RPT-2：生成有序的输入模块	RPT-1 和 RPT-2 在很大程度上是独立的
综合感知表征	指标。RPT-1 也受 支持 时间积分参数。
全局工作空间理论	
GWT-1：多个可并行运行的专用系统（模块）	
GWT-2：容量有限的工作空间，导致信息流出现瓶颈，并具有选择性注意机制	GWT声称这些是必要的，并且 联合充分。GWT-1 至 GWT-4 相互建立。GWT-3 和 GWT-4 从而能够利用工作区依次查询模块以执行复杂任务。
GWT-3：全球广播：可用性	
工作区中的信息传递至所有模块 GWT-4：状态相关注意力，	包含RPT-1。
计算高阶理论	
热门-1：生成式、自上而下或嘈杂的感知模块	
HOT-2：元认知监控，区分可靠的感知表征与噪声；HOT-3：由一般性指导的自主性	PRM声称这些是必要的，并且 联合充分。HOT-1 至 HOT-3 相互建立；HOT-4是 独立。HOT-3 的第一个子句是 也得到了有关论点的支持 有意的/灵活的代理，且包含 AE-1。
信念形成与行动选择系统，以及根据元认知监控的输出更新信念的强烈倾向	
HOT-4：稀疏且平滑的编码生成“质量空间”	
注意模式理论	
AST-1：一种预测模型，用于表征并实现对当前注意力状态的控制	
预测性处理	
PP-1：使用预测编码的输入模块	涉及RPT-1和HOT-1。
代理与体现	
AE-1：代理：从反馈中学习并选择输出，以实现目标，尤其是在涉及对相互竞争的目标灵活响应时	这两个指标也得到了支持 中脑和UAL理论，以及一些 由GWT、PRM和PP确定的范围，尤其是
AE-2：体现：建模输出-输入的偶然性，包括一些系统效应。并在感知和控制中使用该模型	并在感知和控制中使用该模型AE-1，但 并不保证。

表 2：指标属性蕴含

3 人工智能中的意识

第2节的发现对当前及未来不久的AI系统中的意识有何启示？在本节中，我们从两个方面来回答这个问题。首先，在第3.1节中，我们依次探讨了各项指标属性，并讨论了它们如何在人工系统中实现。其次，在第3.2节中，我们以若干现有AI系统作为案例研究，既说明了这些指标应如何使用，也展示了我们的方法如何评估一些当前的系统。我们重点讨论了大型语言模型和Perceiver架构（Jaegle等，2021a，b），尤其关注全局工作空间理论，并探讨了近期的一些系统——PaLM-E（Driess等，2023）、一种“虚拟啮齿动物”（Merel等，2019）以及AdA（DeepMind自适应智能体团队，2023）——是否属于具身智能体。

反思如何构建具备指标属性的系统，以及当前系统中是否具备这些属性，有助于我们总结出一些关键经验教训。其中之一是：评估一个系统是否具备某种指标属性，通常需要对属性描述进行一定程度的解读；而指标属性的描述，正如其理论来源一样，本身就包含着模糊性，这些模糊性会随着具体实现方式的不同而显现出来。要以如此精确的方式描述指标属性，以至于完全无需这种解读，就意味着远远超出了目前科学界关于意识理论所提出的主张；而且，这些更加精确的主张也往往缺乏现有实证证据的充分支持。我们期待，跨学科的意识研究——汇集神经科学家与人工智能研究人员——能够推动意识理论的进一步精确化，并开发出能够为更精确理论提供实证支持的实验方法。

本节讨论带来的第二个启示是，在评估人工智能系统的意识时，仅仅考虑系统的架构、训练和行为并不总是足够的。例如，我们可能知道某个系统是一个循环神经网络，并且已经通过强化学习进行了训练，能够成功控制一个虚拟体完成某项任务，却仍然无法确定其表现是否依赖于对输出-输入关联的习得模型。在这种情况下，我们可能无法确定该系统是否满足我们的具身化条件。为此，需要借助可解释性方法，比如检查隐藏层中编码的信息（Olah等，2018），以判断该系统在训练过程中是否习得了这样的模型。

第三点启示是，尽管将意识理论应用于人工智能存在诸多挑战，但有充分理由相信，当前计算理论所提出的大多数甚至全部意识条件，都可以借助人工智能领域现有的技术手段来实现。这并不是说当前的人工智能系统就一定具备意识——还存在一个问题，即它们是否以恰当的方式整合了现有技术；而且无论如何，无论是计算功能主义还是当前的意识理论，都仍存在不确定性。不过，这确实表明，具备意识的人工智能并非只是遥远未来才会出现的遥不可及的可能性。如果完全不依赖全新硬件就能构建出具备意识的人工智能系统是可能的，那么这种可能性很可能就在当下。

3.1 在人工智能中实现指标属性

3.1.1 实施 RPT 和 PP

我们从讨论来自RPT的两个指标——算法递归和感知组织，以及PP指标（即指标RPT-1、RPT-2和PP-1）入手，展开对这些指标的探究。之所以在此纳入PP指标，是因为正如我们即将看到的，近期的研究发现，在计算机视觉中使用预测编码能够促进对视觉场景全局特征更敏感的处理，这与前馈卷积神经网络在分类任务中表现出的对局部特征敏感的特点形成对比。

算法递归（RPT-1）是许多深度学习架构的一个特性，包括循环神经网络（RNN）、长短期记忆网络（LSTM）和门控循环单元网络（GRU）（LeCun等，2015）。因此，构建具备指标属性RPT-1的系统是相当简单的。尽管这些方法应用得不那么广泛，但也存在在人工系统中实现预测编码（一种算法递归的形式）的方法（Lotter等，2017；Oord等，2019；Millidge等，2022）。这些系统满足指标PP-1。此外，在预测任务上训练并针对能源效率优化的循环神经网络会自发地形成“预测”单元和“误差”单元的 distinct 群体（Ali等，2022）。

接下来转向感知组织（RPT-2），诸如深度卷积神经网络（DCNNs）等人工视觉模型，已经取得了巨大成功，并且经常被声称是人类视觉的良好模型（Kietzmann等人，2019；Lindsay，2021；Mehrer等人，2021；Zhuang等人，2021）。然而，近期有学者对当前系统是人类视觉良好模型这一说法提出了批评（Bowers等人，2022；Quilty-Dunn等人，2022）。更值得注意的是，DCNNs在视觉物体识别上达到的接近人类水平的表现，并不意味着它们能够表征有组织的视觉场景。Bowers等人（2022）和Quilty-Dunn等人（2022）均引用了证据表明，经过训练以分类物体的DCNNs，对局部形状和纹理的敏感度要高于对全局形状的敏感度，而且倾向于忽略物体各部分之间的关系，这暗示它们并未采用整合场景的表征方式。Conwell和Ullman（2022）发现，最近的图像生成模型DALL-E 2在被要求生成物体以陌生方式排列的场景时，表现欠佳。

从RPT的角度来看，这些观点可能表明，所讨论的模型能够对视觉刺激的特征进行分类，这一功能据称在人类中是无意识完成的，但它们无法实现更高级的功能，包括生成有组织、整合的视觉场景表征，其中一些功能可能需要意识（Lamme 2020）。然而，其他当前的系统，包括预测编码网络，确实能够执行其中一些更高级的功能。

PredNet 是一种预测编码网络，经过训练可预测视频输入的下一帧。它之所以引人注目，部分原因在于，在完成这一任务时似乎需要对构成场景的物体及其空间关系进行表征（Lotter 等，2017）。此外，有证据表明，PredNet 的单元会对卡尼扎错觉中的虚幻轮廓产生反应；而这种感知依赖于从更广泛的上下文中推断出物体的存在（Lotter 等，2020）。在此发现的基础上，Pang 等人（2021）采用了一种技术，即在前馈深度卷积神经网络中加入反馈式预测编码连接，并进一步证实了这一预测编码网络——而非最初的前馈模型——对卡尼扎错觉具有敏感性。然而，Lamme

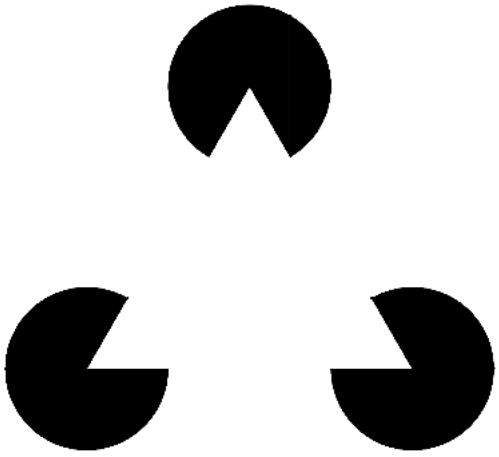

图3：卡尼兹萨错觉示意图.2020年。维基共享资源。经许可转载。

(2020) 声称卡尼扎错觉仅需要知觉“推理”，而不需要RPT所理解的知觉组织。

除了预测编码之外，还开发了其他类型的系统，专门用于表示视觉场景中的对象及其关系。MONet就是一个例子，它使用循环注意力机制和变分自编码器来分解和重建场景（Burgess等，2019）。在这个系统中，注意力网络依次选取各个对象，由变分自编码器进行识别和重建。另一个系统——对象场景表示变换器，则经过训练，能够从新角度预测复杂场景的外观；这一任务与视频预测类似，都需要将场景表示为由空间中的对象所构成（Sajjadi等，2022）。对有组织的感知场景进行表示，是机器学习领域一个活跃的研究方向，目前已经开发出多种方法（Greff等，2020）。

3.1.2 实现 GWT

在人工系统中实现GWT一直是多项研究的主题，包括VanRullen和Kanai（2021）以及Goyal等人（2022）的最新研究。在依次讨论指标GWT-1至GWT-4之前，我们先简要概述这两项研究。

VanRullen和Kanai（2021）的提议涉及一组专门的神经模块，其中至少有一些是生成网络，能够产生行为输出或自上而下地驱动感觉处理。每个模块都拥有自己的低维潜在空间，在其中表征着关键信息。这些模块通过一个工作区进行整合，该工作区是一个共享的潜在空间，经过训练可对各模块潜在空间中的表征进行无监督转换，从而使它们所携带的信息能够被其他模块所使用。工作区的容量低于各模块潜在空间容量之和，并且采用一种依赖于任务的关键-查询注意力机制来决定它广播哪些信息。因此，这种架构包含了瓶颈、全局广播和状态相关选择等重要特征。然而，

这项工作是一份可能实现的“路线图”，而非一个可运行的系统。它面临着一个重大的开放性问题：如何训练注意力机制，以从工作空间的潜在输入中进行选择；尤其是，如何通过相关模块实现控制扩展的、功能性的操作序列所需的注意力操作序列。

与此同时，Goyal等人（2022）试验了一种实现全局工作空间的方法，该方法同样利用键值查询注意力机制来选择多个模块中的哪个模块向共享空间写入数据，随后共享空间的内容会被广播到所有模块。在这种情况下，这些模块是共同训练的，以生成可相互使用的表示，从而避免了在工作空间中进行翻译的必要性。这项研究中所开发的具体实现的一个局限性在于，“模块”实际上是按顺序处理标记或图像部分的元素，因此它们是否为能够并行运行的专门化子系统尚存疑问；相反，它们各自以类似的方式对单一任务的性能做出了贡献。

尽管这两项研究都没有开发出一个能明确满足所有四个GWT指标的工作系统，但这一目标似乎确实具有现实可行性，这一点我们将在逐一考察这些指标时加以论证。指标GWT-1指出，该系统必须具备能够并行工作的专用系统或模块。为了实现全局广播功能，这些模块必须由循环神经网络来实现，除非它们是整个系统的“输出”模块，不向工作空间提供信息。这些模块的输入可能包括：

1. 一种或多种模式的感官输入。
2. 来自少量其他模块的输入，这些模块通常协同工作。例如，“扫视”模块可能会从“视觉显著性”模块获取输入，以便实现快速自下而上的扫视，以指向潜在的重要对象。
3. 来自执行全局工作区模块的自上而下信号。

正如VanRullen和Kanai（2021）所建议的，这些模块可能在狭窄的任务上独立进行训练。或者，它们也可以与工作空间一起端到端地联合训练，以实现某种全局系统目标，从而自然地产生针对子任务的模块专业化。Goyal等人（2022）采用了端到端的训练方法，尽管所处理的任务相对简单（另请参阅Goyal等人，2020）。

GWT实现的第二个要素是一个容量受限的工作空间，它是一个具有不同特性的神经模块。限制工作空间容量最简单的方法是限制其活动空间的维度数量。另一个有趣的选项是训练一个表现出吸引子动力学的循环神经网络。吸引子是动力系统中的一个状态，一旦达到该状态，在没有输入或噪声干扰的情况下，它将保持稳定。吸引子动力学之所以能限制容量，是因为它会将神经轨迹的初始条件映射为多对一的关系，即映射到吸引子上（任何进入吸引子吸引域的神经轨迹都将收敛到该吸引子）。因此，这种吸引子动力学通过压缩稳定状态空间的大小，产生了一种信息瓶颈。Ji、Elmoznino等人（2023）认为，工作空间中的吸引子动力学有助于解释意识体验表面上的丰富性和难以言说性。

对于指标GWT-3，即全局广播，基本要求是所有模块都将工作空间表示作为输入。正如我们所见，这意味着必须存在某种机制，以确保这些输入能够被所有模块使用，例如VanRullen和Kanai（2021）提出的翻译机制。在Dehaene及其同事所发展的全局神经元工作空间理论中（Dehaene & Naccache 2001，Dehaene & Changeaux 2011，Mashour等 2020），工作空间表现出特殊的动态特性：要使某个表征进入工作空间并实现全局广播，它必须由循环反馈回路持续维持。尽管尚不清楚这是否为必要条件，但如果采用具有吸引子动力学的网络来实现工作空间，则这种行为完全可以在人工智能中复现。在这种情况下，广播机制可能由一个漏电神经积分器构成，其动力学具有较慢的时间尺度，因此需要持续的输入才能将其置于特定状态；而在缺乏持续输入的情况下，它会逐渐恢复到某种基线状态（类似于通过证据累积进行决策的模型）。这一广播机制将产生自上而下的信号，馈入各个专门化模块。

指标GWT-4包括以下条件：系统必须使用一种依赖于状态的注意力机制，且工作空间必须能够通过依次查询模块来组合模块以执行复杂任务。对于依赖于状态的注意力机制，VanRullen和Kanai（2021）以及Goyal等人（2022）都提出了使用键值注意力机制，这种机制在当前的人工智能模型中很常见。查询可基于工作空间的当前状态计算得出，而所有其他模块则可计算出对应的键。工作空间查询与给定模块键之间的相似性会通过与其他所有模块的相似性进行归一化处理，从而引入模块间的竞争关系。这些归一化的相似性将决定每个模块的值对工作空间净输入的贡献程度。也就是说，在每个时间点都会应用标准的键值注意力机制，以根据工作空间的当前状态计算其输入。

此处描述的模型能够满足GWT-4的第二部分——即利用工作区依次查询模块以执行复杂任务的能力。这是因为工作区与模块之间存在计算循环，从而在时间上展开该模型。模块从自下而上的感官输入以及少量其他模块接收输入，但同时也从工作区接收自上而下的输入。这意味着，例如，一个模块可以通过控制工作区中所表示的内容来控制其他模块。工作区对模块的顺序调用属于系统的计算能力范围之内，因此如果在训练过程中这种调用方式有益，它就可能自然出现。然而，要使这样的系统学会以有用的方式组合模块并执行复杂任务，就需要合适的训练方案；而构建一种合适的训练机制，对于实现GWT而言可能是一个重大挑战。

3.1.3 实施PRM

我们现在探讨作为代表性计算型HOT的感知现实监控理论如何在人工智能中实现。也就是说，我们考虑如何构建一个具备指标属性HOT-1至HOT-4的人工智能系统。尽管PRM研究者声称目前尚无任何人工智能系统能够完全满足所有要求（Dehaene等，2017；Michel & Lau，2021；Lau，2022），而且据我们所知也尚未有相关的实现尝试，但标准的机器学习

这些方法足以实现该理论中大多数要素的合理实现。我们首先考虑“质量空间”的实现——即一个可能表征的空间，它满足PRM对现象质量基础的解释——然后再转向PRM的核心主张，即一阶表征之所以会变得有意识，是因为它们被更高阶的监控机制表征为“真实”。

指标HOT-4指出，该系统必须具备稀疏且平滑的编码，从而生成一个“质量空间”。所有深度神经网络最重要的特征之一是，每一层都赋予模型一个平滑的表示空间，在这个空间中，对于可能的输入范围，可以连续地编码出一系列可能的激活值。这些表示空间的平滑性被认为是它们能够在测试时对新输入进行泛化的主要原因之一；即使某个新输入使某一层产生了不同的激活模式，只要这种模式仍在模型的训练分布范围内（即该层在训练时曾激活过类似的模式），后续各层仍能对其进行解读（Belkin等，2018；Bartlett等，2021）。事实上，有证据表明，当前深度神经网络所学习到的感知表示空间已经与人类视觉系统的表示空间高度相似，这意味着它们对应的“质量空间”或许早已实现了相当程度的对齐。例如，Kriegeskorte（2015）发现，深度神经网络中许多视觉刺激表示之间的两两不相似度矩阵，与神经活动中观察到的结果高度吻合，甚至网络中相邻各层与视觉皮层的层次化组织结构之间也存在对应关系——尽管最近的一些研究对此图景提出了更为复杂的解释（参见Golan等，2020；Lindsay，2021；Bowers等，2022）。

机器学习中的标准方法可用于满足表示稀疏的条件。例如，正则化技术可通过最小化网络表示的幅度或输入与表示之间的互信息，来强制DNN模型实现稀疏表示（Tishby 2000）。使用SoftMax等归一化函数的层，其中较高的值会抑制表示中较低的值，也会增加稀疏性。

指标HOT-1和HOT-2指出，该模型必须同时包含对感官数据的一阶感知表征，以及为特定一阶表征赋予可靠性或“真实性”度量的高阶表征。为了满足这些条件，已有大量已知的深度学习解决方案可供选择，我们在此回顾其中几种。重要的是，所有这些解决方案都采用一种简单的两组件架构设计：(1) 一个（一阶）神经网络将感官数据和/或自上而下的信号作为输入，并产生一系列分布在多层层级中的感知表征；(2) 同时，并行地，一系列独立的（高阶——特别是二阶）神经网络各自以某一层的一阶激活值作为输入，然后输出一个标量，表示该层一阶表征为真值的概率。满足这些条件的解决方案的主要差异在于二阶网络的训练方式。

如果偶尔存在监督信号，为二阶网络提供关于一阶表示可靠性的“真实标签”，那么二阶网络就可以通过标准的监督学习来训练，以估计正确性的概率。获取这种真实标签信号可能很困难，但并非不可能。例如，如果一阶表示误差的来源是网络内部的噪声，那么只需对随时间变化的 noisy 一阶表示取平均值，即可估算出真实标签。另一种可能性是，通过比较同一感知在不同感官模态中的表示来获取真实标签（例如，验证

利用视觉反馈来验证声音的真实性）或通过运动（例如，检查视觉感知是否能如预期般对已知的运动行为作出反应）。

如果无法直接获得真实标签，二阶网络可以在其他替代任务上进行训练，在这些任务中，信号的可靠性是性能的一个隐含因素。例如，二阶网络可能会尝试利用过去的表示来预测即将到来的一阶表示。由于外部生成的信号有时比内部生成的信号更具可预测性——比如对一个下落球体的感知比由随机内部噪声产生的幻觉更具可预测性——当网络的预测误差较大时，二阶网络可以降低对一阶表示真实性的置信度。或者，当图像处于认知控制之下时，进行想象活动所产生的感官后果会比不受控制时更具可预测性（我想象一只粉红色的熊，然后真的出现了一只粉红色的熊）。因此，努力控制的程度本身也可以作为一种内在信号，用于训练现实监控系统（Dijkstra 等人，2022）。通过这些方式，即使在缺乏监督信号的情况下，二阶网络也能学会将可预测性作为判断“真实性”的线索。这些方法与预测编码密切相关，而预测编码已经在现代深度学习中得到了广泛应用（例如，Millidge 等人，2022；Oord 等人，2019；Alamia 等人，2023），只不过在这里，预测是在时间维度上进行的，而不是在层次结构的各层之间进行。

训练二阶网络的其他方法涉及将其视为一个世界模型。例如，深度学习中的贝叶斯方法将感知视为一种推理过程，在这种过程中，神经网络试图推断可能生成数据的潜在变量的值。对于理想的贝叶斯推理而言，这些潜在变量必须根据其后验概率进行采样，而后验概率与它们的先验概率乘以在某种世界模型下生成数据的可能性成正比，该世界模型规定了潜在变量如何产生感官观察。这种视角与PRM非常契合；用于推断潜在变量值的推理机制可被视为生成感知的一阶表示，而二阶网络则评估一阶表示为真的概率。

尽管贝叶斯推断在一般情况下是难以处理的，但已有几种近似方法。例如，一类最近提出的模型称为生成流网络（GFlowNets），它提供了一种利用现代深度神经网络进行近似贝叶斯推断的框架（Bengio等，2021；Bengio等，2022），甚至可以同时训练推断模型（一阶网络）与世界模型（二阶网络）（Hu等，2023；Zhang等，2023）。这种提出的GFlowNet架构（与其他近似贝叶斯推断方法一样）再次与意识的预测加工理论相关联，该理论认为，有意识的知觉是大脑对其自身感官输入潜在原因所做出的最佳猜测（Seth，2021）。不过，在PRM案例中一个重要的区别在于：当一阶推理系统采样出知觉的潜在变量后，这些变量只有在二阶世界模型赋予它们足够高的真实性概率时才会成为有意识的；这里既可以采用硬阈值，也可以采用软阈值来生成“真实”标签。

请注意，上述机制也可用于在系统中产生内部生成的意识体验。例如，一个自上而下的想象模块可能会首先生成一个目标（例如，想象一个苹果），然后相应地驱动一阶网络的感官和感知层中的神经活动。随后，二阶世界模型会为这种活动赋予一个真实性概率。如果想象模块能够生成

在感觉和知觉层面上具有足够连贯的表征后，二阶模型便会像对待外部生成的信号一样，为这些信号赋予“真实”的标签，从而使得想象的内容能够被有意识地体验到。大脑中可能存在类似的机制，因为已有研究表明，在想象与自下而上的感知过程中，感觉区域的神经活动是相似的，且这种相似程度与体验的生动性呈正相关（Dijkstra 2019，Dijkstra 2023）。

最后一种可能性是通过对抗方法隐式地学习世界模型。具体而言，生成对抗网络（GANs）（Goodfellow等，2014）是一类方法，其中生成器网络尝试采样合成数据，而判别器则试图区分真实数据与生成器生成的合成数据。生成器经过优化，以欺骗判别器将其输出预测为“真实”数据。结果是，如果所用网络足够强大，稳定的解便是生成器从真实数据分布中采样数据。GAN中的判别器可与PRM提出的高阶监控机制相媲美（Lau，2022）。基于GAN的PRM实现可能包括：(a) 一个一阶感知网络，它根据感官数据生成感知表征；(b) 一个生成器网络，它反转这一过程，首先采样合成感知表征，然后根据这些感知生成合成感官数据；(c) 一个二阶网络，它经过训练能够区分由一阶网络生成的真实感官-感知元组与由生成器生成的合成元组（Gershman，2019）。与显式世界模型的情况类似，我们随后可以通过对判别器针对一阶网络生成的表征的输出施加硬阈值或软阈值，来生成PRM的“真实”标签。

现在，我们还需考虑指标HOT-3，该指标涉及元认知监控机制输出的消费者。指标HOT-3指出，这应是一个“一般性的信念形成与行动选择系统”，并且应具备一种“强烈倾向”，即根据监控机制的输出对其进行更新。这一条件存在双重动机：监控机制的功能是服务于这一消费者，而消费者依赖于被标记为“真实”的一阶表征的准确性；这些输入对消费者的“作用力”旨在解释有意识经验的力量与持久性。

为了实现消费者，我们可以实例化一个或多个更高级别的网络，这些网络同样仅以带有“真实”标签的感知表征作为输入。实现这一目标的方法可能有很多，但一种可能性是为更高级别网络使用标准的Transformer架构，并稍作调整。在Transformer中，更高级别网络会生成一个或多个查询向量（直观地代表当前的计算目标），然后这些查询向量会根据其键向量的值，关注一阶感知表征（直观地代表感知的“种类”或其“数据类型”）。在标准Transformer中，每个感知表征随后会根据其键与更高级别网络查询之间的相似性进行调制，然后再整合到下游计算中。如果我们希望额外利用二阶网络产生的“真实”标签，只需将查询-键相似性乘以相应感知表征的“真实”标签值即可，这将使这些标签有效地充当先验掩码，从而决定感知表征在Transformer中如何影响计算。重要的是，这种架构与PRM关于意识感知顽固性的预测相兼容（Lau 2019）：即使我们在认知上意识到某个感知是不准确的（例如幻痛或药物诱导的幻觉），我们仍然强烈倾向于将其纳入我们的更高层次推理中。借助这种Transformer-

基于架构，有意识的体验无法被理性地消除。这是因为高级网络仅将由其“真实”标签调制的感知作为输入，而自身并无能力改变这些“真实”标签。

本提案侧重于指标HOT-3的第二个方面（即“强烈倾向”），而非消费者应是一个普遍的信念形成与行动选择系统的观点。哲学家们对一个系统要具备哪些特征才能被视为形成了信念，有着各种各样的看法；但在当前语境下，一个看似合理的必要条件——或许也是充分条件——就是该系统必须进行工具性推理，从而导向行动选择（参见第2.4.5节）。

3.1.4 实现 AST

两项值得注意的研究在人工系统中实现了简单的注意力模式。威尔特森和格拉齐亚诺（2021）的系统采用强化学习，基于一个三层神经网络，每层有200个神经元，以学习捕捉沿不可预测路径下落的球。该系统的首要输入是一个带有噪声的“视觉”数组，显示球的位置。这个数组包含一个“注意力聚光灯”——即去除噪声后的数组的一部分——系统可以学会移动这一聚光灯。因此，解决该任务的一种自然策略就是让系统学会将聚光灯定位在球上，从而避免视觉数组中的噪声干扰其追踪和捕捉球的能力。这一过程得益于第二个输入——“注意力模式”，它代表了聚光灯在数组中的当前位置。威尔特森和格拉齐亚诺发现，即使在移除注意力模式后，聚光灯依然存在，但当注意力模式可用时，该系统在学习完成任务方面要成功得多。

这个非常简单的系统确实具备了指标属性AST-1的部分特征，即注意力模式，因为它使用了一种类似注意力的机制的表示来控制该机制，从而提高了性能。然而，这并不是一个预测模型，而且注意力聚光灯与真正的注意力本身有很大不同，因为它只是输入的一个简单可控特征，而非一种具有多个自由度的内部过程，后者能够控制信息在整个系统中的流动。

最近，Liu 等人（2023）测试了几种不同的系统，这些系统在多智能体强化学习任务中采用了键-查询-值注意力机制。他们的系统包含三个主要组成部分：多头注意力层、用于“内部控制”的循环神经网络以及策略网络。在他们所采用的最准确实现注意力模式的版本中，注意力层被应用于系统的输入，并将信息传递给生成动作的策略网络；同时，内部控制网络既学习预测注意力层的行为，又影响这种行为。与采用相同组件但架构不同的其他系统相比，这一系统表现更佳，且已在多智能体强化学习任务上进行了测试。

与威尔特森和格拉齐亚诺的系统相比，该系统的优势在于使用了经过学习的注意力预测模型，而非采用作为输入提供的万无一失的表征。尽管如此，该系统目前仍仅用于二维视觉环境中的相对简单任务。这一研究方向的一个需要注意的问题是，人工智能中的注意力并不完全等同于神经科学所理解的注意力（参见方框3）。然而，该系统确实展示了一条构建具备注意力模式指示器的系统的可行路径。

3.1.5 实施机构与体现

其余指标涉及智能体和体现。强化学习在我们所定义的智能体概念上可以说是充分的——即“通过反馈进行学习，并选择输出以实现目标”。因此，满足指标AE-1的这一部分可能非常简单。目前，强化学习在人工智能领域得到了极为广泛的运用。回顾一下关于强化学习足以构成智能体的论点：强化学习的基本任务是让系统学会在环境中最大化累积奖励，而该环境中的输出不仅影响系统即时获得的奖励，还会影响其未来获得奖励的机会。因此，强化学习算法被设计成对输出的后果敏感，从而使系统更有可能重复那些在多个时间步长内带来更大奖励的输出。这意味着强化学习与其他形式的机器学习存在显著差异。与通过监督学习或自监督学习训练的系统类似，强化学习系统也会逐渐逼近期望的输入-输出函数。然而，在强化学习中，决定这种函数是否为期望函数的关键在于，这些输出能够促进目标的实现——而这些目标只有通过系统与环境之间长时间的交互才能达成。至关重要的是，强化学习系统正是凭借其对输出、后续输入以及奖励之间关系的敏感性来学习这些函数的。基于模型的强化学习系统会学习这些关系的模型，但无模型的强化学习系统同样对其保持敏感。因此，强化学习系统通过学习并选择行动来实现目标（Butlin 2022, 2023）。

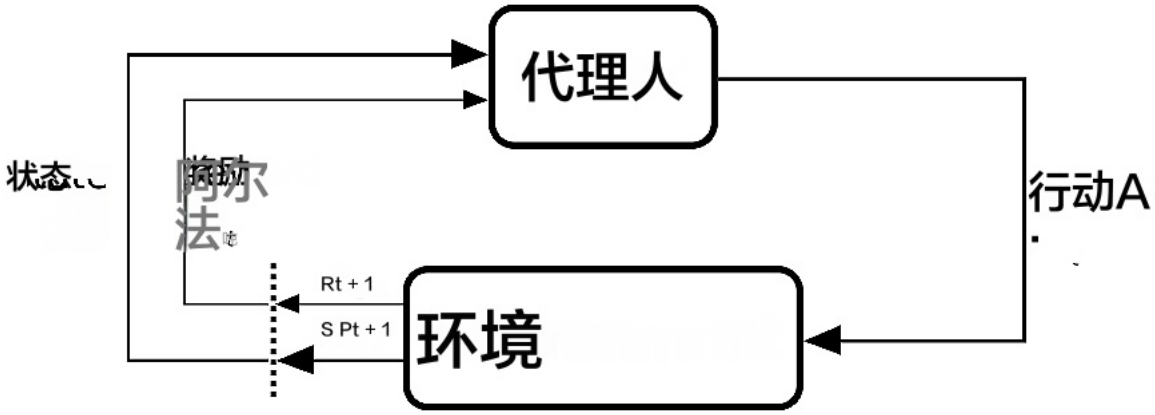

图4：基于Sutton和Barto 2020年出版的《强化学习：导论》第二版中的一幅图的马尔可夫决策过程强化学习示意图。采用知识共享署名-相同方式共享4.0国际许可协议授权，经许可转载。

指标AE-1的第二部分指出，如果系统表现出“对相互竞争的目标灵活响应”，则意识出现的概率将显著提高。这一条款的启发性例子是一只动物在平衡多种体内稳态驱动时的情形：这需要根据不断变化的情况进行优先级排序。针对这一问题，人们已探索了多种计算方法，包括强化学习领域的研究（Keramati & Gutkin 2014，Juechems & Summerfield 2019，Andersson et al. 2019）。一种提议是使用多个独立学习的模块，每个模块分别学习如何最大化不同的奖励函数；每个模块为可能的动作分配得分，然后选择总分最高的动作（Dulberg et al. 2023）。在体内稳态的情境中，这些奖励函数可能各自对应一种体内稳态驱动，一旦任一驱动偏离设定值过远，就会受到高额惩罚。

我们的具身性指标AE-2指出，系统应使用输出-输入模型（也称为前向模型）来进行感知或控制。神经科学家已在人类身上确定了此类模型的一些特定用途，这些用途尤其与具身性相关。在感知方面，系统自身动作所引起的感官效应的预测可用于区分由这些动作引起的感官刺激变化与由环境事件引起的感官刺激变化。采用这种推理方式的系统会隐式或显式地将自身与其环境区分开来。在运动控制中，前向模型可用于状态估计和反馈控制，从而实现对复杂执行器的快速调整。重要的是，要将输出-输入模型的这些用途与其他用途区分开来，例如规划，后者并不意味着具身性。

学习与感知和控制相关的任务的输入-输出模型很常见，但目前符合这些具体描述的AI系统实例却很少。例如，视频预测是一项研究颇多的任务（Oprea等，2020），其中就包括根据系统的输出来预测视觉输入将如何演变（Finn等，2016）。然而，这并不足以满足我们所描述的那种感知用途，因为这种感知还涉及理解那些无法从输出中预测的外部变化。在基于模型的强化学习中，输入-输出模型被用于控制，从而成功地实现了四旋翼无人机（Becker-Ehmck等，2020）及其他机器人的控制。不过，尚不确定这些模型在上述案例中是专门用于控制目的，还是用于规划，这一问题我们将在3.2.2节中进一步探讨。

最近一项采用前向模型以服务于具身系统特定目的的研究的典型例子，是Friedrich等人（2021）所描述的系统。在该系统中，卡尔曼滤波器（Todorov & Jordan 2002）被用来将前向模型与存在时间延迟的感官输入相结合，从而估计系统在环境中的当前状态。这些估计随后被用于持续的运动控制，尽管仅限于虚拟环境中相对简单的执行器。

3.2 当前系统的案例研究

3.2.1 GWT 的案例研究

实际上，要判断一个给定的人工智能系统是否具备某种指标属性，并不总是显而易见。原因之一是我们尚未为每项指标给出绝对精确的定义。另一个原因是，深度学习系统的运作方式，包括它们在中间层所表征的内容，往往并不透明。在本节和第3.2.2节中，我们展示了案例研究，说明如何利用这些指标来评估当前的人工智能系统。这里我们重点讨论GWT指标（GWT-1至GWT-4），以及两类因不同原因而引人注目的系统。这两类系统分别是基于Transformer的大语言模型（LLM），例如GPT-3（Brown等，2020）、GPT-4（Open AI，2023）和LaMDA（Thoppilan等，2022），它们以在自然语言任务上表现出色并引发公众广泛关注而闻名；以及Perceiver（Jaegle等，2021a）和Perceiver IO（Jaegle等，2021b），它们之所以引人注目，是因为Juliani等（2022）认为它们“实现了功能性的全局工作空间”。尽管这两种系统都不是为了实现全局工作空间而设计的，但有理由认为它们各自都具备部分GWT指标属性。

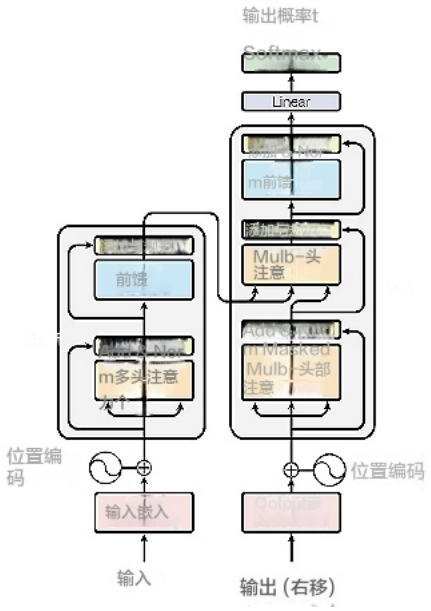

图5：Transformer架构。Vaswani, A., Shazeer, N., Parmar, N., Uszkor-eit, J., Jones, L., Gomez, A. N., Kaiser, L., &Polosukhin, I., 2023. 注意力就是一切。arXiv:1706.03762。经许可转载。

在Transformer中，一种称为“自注意力”的操作用于整合输入不同部分的信息，这些部分通常是序列中的各个位置（参见关于注意力的方框3；Vaswani等，2017）。如果我们把处理来自各个位置信息的系统元素（注意力头）看作模块，那么Transformer架构与全局工作空间之间就存在一种基本相似性：两者都整合了来自多个模块的信息。Transformer由两种类型的层堆叠而成，且交替出现：注意力头层，执行自注意力操作，在各个位置之间传递信息；以及前馈层。Elhage等人（2021）对Transformer的一种解释将其描述为由“残差块”组成，每个残差块包含一种类型的单层，这些层处理从“残差流”中提取的信息，然后再将处理后的信息加回该“残差流”。

考虑到残差流的概念，可以认为Transformer具备指标属性GWT-1至GWT-3——也就是说，它们拥有模块，一个有限容量的工作区引入了瓶颈，以及全局广播。残差流

是（据称的）工作空间，其维度低于对其执行写入和读取操作的自注意力层和前馈层（Elhage 等人，2021）。存在一种“全局广播”，即残差流中某一特定层的信息可被下游注意力头使用，以影响任意位置的进一步处理。在给定层添加到残差流的信息也取决于先前各层残差流的状态，因此从这一角度出发，人们或许可以认为 Transformer 满足了 GWT-4 中状态依赖性注意力的要求。

这一论点的一个问题是，残差流的维度是否构成瓶颈值得怀疑，因为它的维度与整个系统的输入维度相同。然而，该论点更根本的问题在于，Transformer 并非递归网络。残差流并不是一个单独的网络，而是一系列夹杂在其他层之间的层。不存在能够向残差流传递信息并从中接收反馈的模块——相反，当注意力头和前馈层共同向残差流写入时，这仅仅影响下游不同注意力头和前馈层所接收到的内容。对此的一种思考方式是：究竟 Transformer 中哪些部分才是模块？如果模块仅限于特定的几层，那么就不存在全局广播；但如果模块并不局限于特定的几层，那么也就无法将残差流与模块区分开来。Transformer 缺乏具有全局工作空间的系统整体结构，即不存在一个明确的工作空间来整合其他各个元素。目前仅有较弱的证据表明，基于 Transformer 的大型语言模型具备任何源自 GWT 的指标特性。

与此同时，感知器架构的两个版本比Transformer更接近于满足GWT指标，但在我们看来，仍未能完全满足所有指标。感知器架构旨在解决Transformer的一个弱点，即自注意力操作通过生成成对交互来整合位置信息。这种操作在扩展到高维输入时计算成本高昂，因此催生了一种方法：利用单一且容量有限的潜在空间来整合来自不同专家的信息（Jaegle等人，2021a、b；Goyal等人，2022）。特别是，感知器IO设计用于处理来自多个领域或模态的输入，并利用多个输入编码器和输出解码器生成各种类型的输出。它使用自注意力机制处理潜在空间中的信息，同时采用一种相关操作——交叉注意力，从输入模块中选择信息并写入输出模块。潜在空间在自注意力层与交叉注意力层之间交替切换，使其能够反复从输入模块获取新信息。感知器IO在包括语言处理、视频中运动预测、图像分类以及为《星际争霸II》中行动选择目的而处理单位相关信息等任务中均取得了优异性能（Jaegle等人，2021b）。

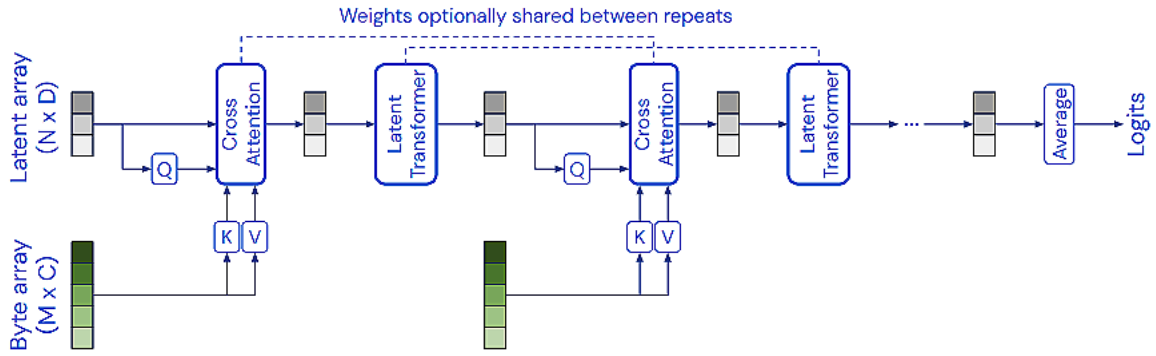

图6：感知器架构。 Jaegle, A., Gimeno, F., Brock, A., Vinyals, O., Zisserman, A.,& Carreira, J., 2021. 在 第38届国际机器学习大会论文集，PMLR 139:4651-4664。经许可转载。

Perceiver架构允许以历时方式处理输入序列，其中潜在空间状态会随着每个新输入而更新，同时也受到其先前状态的影响。因此，Perceiver无疑具备GWT-1（专用模块）和GWT-2（瓶颈）的指示性特征，以及GWT-4的第一部分（依赖于状态的注意力）。然而值得注意的是，尽管该架构中可以使用专用模块，但它们并非强制要求——Perceiver甚至可以仅用一个具有单一功能的输入网络来使用。此外，更重要的是，能够顺序处理的输入数量受限于潜在空间中交叉注意力层的数量。这意味着虽然Perceiver中的注意力是依赖于状态的，但在实际应用中，系统必须重置才能开始一项新任务，因此其状态完全由当前任务之前的输入所决定。

与Transformer类似，Perceiver全局工作空间中缺失的最明显要素是缺乏全局广播。Perceiver IO具有多个输出模块，但在任何给定的试验中，其输入都包含一个“输出查询”，用于指定所需输出的类型。因此，只有一个输出模块会处理来自工作空间的信息。此外，输入模块通常不会从工作空间接收信息。因此，尽管Perceiver架构作为成功运用类似工作空间的方法来提升人工智能功能的一个范例具有重要意义，但它距离实现完整的GWT还有一定差距。

3.2.2 具身智能的案例研究

我们现在来看一些人工智能系统的例子，这些例子说明了指标AE-1和AE-2所要求的条件，它们涉及代理性和具身性。我们在本小节中讨论的系统包括：PaLM-E（Driess等，2023），被描述为一种“具身多模态语言模型”；由强化学习训练的“虚拟啮齿动物”（Merel等，2019）；以及AdA，一种基于大型Transformer、经强化学习训练的“自适应智能体”（DeepMind自适应智能体团队，2023）。

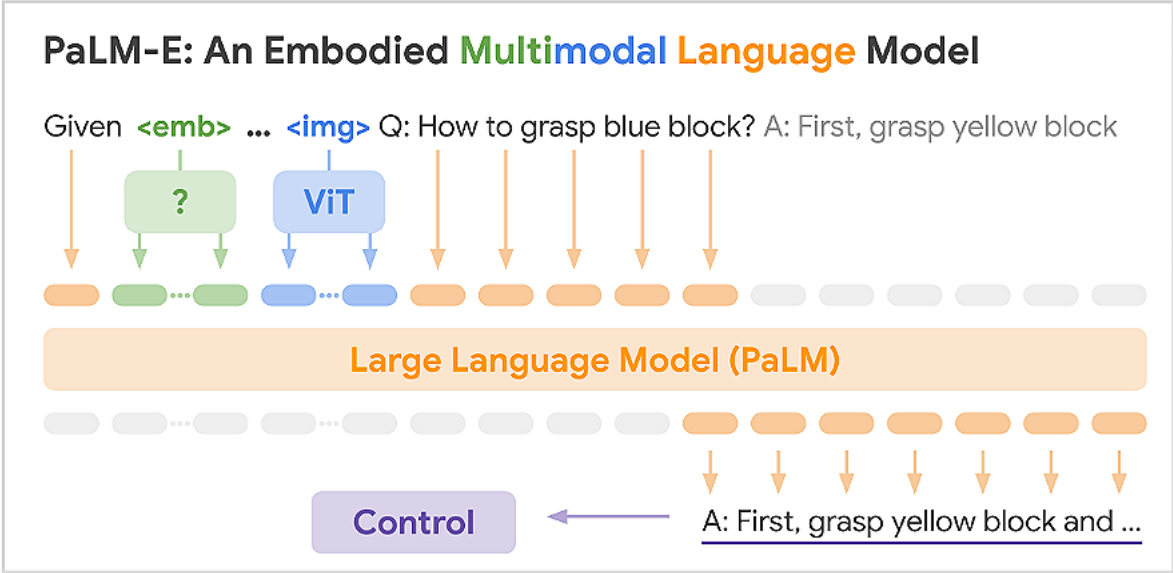

图7：PaLM-E架构。 Driess, D., Xia, F., Sajjadi, M. S. M., Lynch, C., Chowdhery,A., Ichter, B., Wahid, A., Tompson, J., Vuong, Q., Yu, T., Huang, W., Chebotar, Y., Sermanet, P.,Duckworth, D., Levine, S., Vanhoucke, V., Hausman, K., Toussaint, M., Greff, K., & Florence, P., 2023. PaLM-E：一种具身多模态语言模型。 arXiv:2303.03378. 经授权转载。

PaLM-E 是一种仅解码器的大型语言模型（Driess 等人，2023），基于 PaLM（Chowdhery 等人，2022）进行微调。它以编码后的多模态字符串作为输入，这些字符串可同时包含文本和图像，并生成文本标记作为输出。与其他大型语言模型一样，它可以自回归地用于生成更长的文本序列。使用时需要一个编码器，配合合适的编码器，它在纯语言任务以及视觉-语言任务（如视觉问答）中都能表现出色。然而，PaLM-E 还可以与一个单独训练的策略单元相结合，该策略单元可将自然语言指令和视觉上下文映射为低级机器人动作。PaLM-E 的研究采用了 Lynch 等人（2022）提出的策略，这些策略经过训练，能够模仿人类对机器人执行器的控制。在这种设置下，系统可以从摄像头获取输入，将其与人类提供的任务指令相结合，并生成和执行行动方案。PaLM-E 生成高层计划，而策略单元则提供基于视觉的低层电机控制。如有必要，该计划还可根据新的观察结果在后续阶段进行更新。

在考虑Palm-E时，我们可以关注几个不同的系统：PaLM-E模型本身、策略单元，或者由这两个元素及其所控制的机器人组成的完整系统。

整个系统可以非常自然地被描述为一个具身智能体。当被赋予任务时，它能够制定计划，并通过移动其机器人“身体”在与人类共享的空间中执行这些计划。然而，该系统的两个主要组成部分实际上都是经过训练以模仿人类行为的。PaLM-E通过自监督学习进行训练，以预测人类生成的字符串中的下一个标记；策略单元则经过训练以模仿人类的视觉运动控制。因此，可以说该系统模仿的是规划以及利用视觉运动控制来执行计划，而非真正地去完成这些动作。它并未学会通过成功或失败的反馈来追求目标。

失败。

由于整个系统包含一个机器人，因此将其描述为具身化是自然而然的。然而，根据我们所采用的解释，要使一个系统具备具身化的视角，它必须对自身的输出如何影响环境进行建模，以便在感知上与环境区分开来，或促进运动控制。鉴于PaLM-E完整系统并非端到端训练，因此在训练过程中并未暴露于其输出对环境的影响，很难想象该系统能够习得这种类型的模型。此外，这些组件是在几乎没有或根本没有外生变化的环境中进行训练的，因此也就不存在学习区分输入中变化来源的必要性。

或许，此处为具身性所提出的最佳论据聚焦于策略单元。这是一个基于Transformer的网络，经过训练可将视频和文本映射为连续动作，以模仿人类的控制方式。在人类运动控制中，前向模型（将输出映射到预测输入）用于生成预期值，以便与意图和感官输入进行比较，从而实现实时运动轨迹的矫正（McNamee & Wolpert 2019）。这可能涉及区分自我与环境，因为外源事件可能导致不匹配。原则上，策略单元或可采用类似机制，因为该网络的输入包含一定的观测历史。这意味着它能够学会检测当前观测值与根据过去状态本应预测的观测值之间的不匹配，并据此调整其行动。例如，如果指令是向东推一个方块，而它在执行过程中却观察到方块正向北移动，这便可能触发一次纠正动作。

也有人会认为，策略单元是一种智能体，尽管它并未经过强化学习训练。它能够学习与目标进展相关的输入序列——这一目标由输入的另一部分指定——并调整其输出以生成这些序列。然而，这种能力是否足以构成真正的智能体，尚存疑问。因为尽管该系统学会了输入序列以及在面对这些序列时应产生何种输出，但它并未学会自己的输出如何影响输入——因此，它无法根据预期的输出来生成正确的序列。类似的质疑同样适用于具身性的论证：该系统能够学会检测任务情境中过去与现在观测之间的“不匹配”，却无法检测过去观测与动作之间、以及过去观测与当前观测之间的不匹配。这并不是说策略单元完全不具备智能体和具身性特征，而是旨在说明与这些问题相关的各种考量因素。

鉴于在模拟环境中控制一个虚拟形象就足以实现具身化，Merel等人（2019）提出的“虚拟啮齿动物”是具备这些属性的一个很有前景的候选者。它通过强化学习进行训练，这足以赋予其自主性。该系统通过构建一个具有38个自由度的虚拟“身体”，并基于实验室大鼠的解剖结构来实现。一个基于循环LSTM的演员-评论家架构被端到端地通过强化学习进行训练，以控制这个身体，利用丰富的视觉和本体感觉输入，在静态三维环境中完成四项任务。这一架构很可能足以让系统学会一个模型，用以描述其输出如何影响其输入，从而在感知和行动中加以利用。由于采用了循环网络，新的输入可以在存储的过去输入和输出表示的上下文中进行处理。因此，原则上，该系统能够根据过去行为所生成的预期来处理输入并选择输出——也就是说，它能够在自我模型的输出背景下进行处理，而这个自我模型或许会隐式地表征有关其身体稳定特性的信息。

然而，在本研究中，环境并未发生外源性变化，而且似乎可以通过生成一组刻板动作的组合来完成任务，例如跑步、跳跃和站立。分析表明，该系统确实学到了一系列类似的行为模式。这些动作可能并不需要持续的感知反馈控制。这引发了一个问题：任务需求是否足以促使系统学习使用自我模型，而非相对简单的输入-输出策略？

AdA，即DeepMind的“自适应智能体”，同样通过强化学习进行端到端训练，以控制三维虚拟环境中的化身（DeepMind自适应智能体团队，2023年）。该系统由一个Transformer组成，它对过去几百个时间步的观测数据进行编码（具体数值在团队的实验中有所变化），包括过去的动作和奖励，以及任务指令、感官输入，并将这些信息馈入一个LSTM网络。该LSTM经过训练，能够预测未来的动作、价值和奖励。为了促使系统经历元强化学习，这一系统接受了涵盖范围极广、难度逐步增加的任务训练。这意味着它学会了一种隐式的在线学习算法，使其能够仅凭记忆中最近时间步的观测数据，便能学会执行新任务——而无需更新权重。经过这种训练模式后，该系统能够在人类的时间尺度上适应环境中出现的新任务。

AdA 是一个比虚拟啮齿动物强大得多的系统，尽管它控制的化身要简单得多。它的环境稳定性稍差，部分原因在于它所执行的一些任务涉及与另一个智能体合作；但其重点在于学习生成并测试针对新任务的行为策略，而非协调复杂的动态行为。因此，我们再次可以质疑，该系统是否面临那些似乎促成了动物自我建模进化的挑战。然而，与虚拟啮齿动物不同的是，AdA 有一个明确的训练目标：基于过去交错输入和输出序列生成预测。因此，尽管 AdA 并未像 PaLM-E 那样实现物理实体化，也并未主要针对复杂化身的运动控制进行训练（如虚拟啮齿动物），但它仍可能是我们所考虑的三个系统中，最符合我们标准的实体化系统。

4 含义

在本节的最后，我们从更广阔的视角探讨了人工智能中的意识问题。我们考虑了人工智能系统被低估或高估意识所带来的风险（见第4.1节），以及意识与人工智能能力之间的关系（见第4.2节）。此外，我们在第4.3节提出了一些有限的建议。本节的评论较为简要——本报告的主要目标是为人工智能中的意识问题提出一种科学方法，并明确当前科学理论对这一前景的含义，而非探究其道德或社会影响。

4.1 将意识归因于人工智能

关于人工智能意识的争论双方都存在风险：一种是低估意识的风险（即未能识别出本应具备意识的人工智能系统中的意识）；另一种是高估意识的风险（即错误地将意识赋予实际上并不具备意识的系统）。正如在其他意识不确定的情形中一样，比如其他动物（伯奇 2018）和患有意识障碍的人群（彼得森等人 2015；约翰逊 2022），我们必须同时考虑这两种风险。

4.1.1 对人工智能意识的低估

正如许多作者所指出的，随着我们开发出越来越复杂的AI系统，我们将面临越来越多关于其道德地位的棘手问题（Bryson 2010，Gunkel 2012，Schwitzgebel & Garza 2015，2020，Metzinger 2021，Shulman & Bostrom 2021）。哲学家们对于意识与道德地位之间的确切关系存在分歧，但一个很合理的推论是：任何能够体验到意识痛苦的实体都应得到道德上的考量。如果在其他条件相同的情况下，我们能够减轻意识痛苦，那么我们就应当这么做。这意味着，如果我们未能认识到具有意识的AI系统的意识状态，就可能冒着造成或放任具有重大道德意义的伤害的风险。

用非人类动物作类比有助于说明这个问题。人类出于强大的经济动机，大量虐待养殖动物。这种虐待行为是否源于未能将意识归于这些动物，都说明了潜在的问题。在人工智能领域，人们很可能对赋予人工智能意识持相当大的抵触情绪，部分原因在于人工智能的开发者可能拥有强大的经济动机，从而淡化对人工智能福利问题的关切。因此，如果我们构建出能够产生有意识痛苦的人工智能系统，那么只有当研究人员明确承认并传达这一能力时，我们才有可能大规模地防止它们遭受痛苦。然而，鉴于上述关于意识的不确定性，我们或许会在意识到自己已经创造出具有意识的人工智能系统之前，就已经造出了这样的系统。

在此背景下，一个重要的观点是：拥有意识并不等同于能够体验有意识的痛苦。至少在概念上，可能存在一些具有意识的系统，它们没有任何带有情感色彩或情感性的意识体验——也就是说，它们没有任何让自身感到愉悦或不愉悦的体验（Carruthers 2018，Barlassina & Hayward 2019）。如果只有带有情感色彩的体验才具有特殊的道德意义，那么确定人工智能的道德地位的关键问题就是……

系统是否具备这种体验能力（即，它们是否具有感知性，正如该术语有时所指的那样）。我们尚未探讨有关效价的神经科学或哲学理论，也未深入研究人工智能系统中特定效价意识体验的可能性。与视觉体验理论相比，关于效价意识体验的理论尚不成熟，这表明未来工作应优先关注这一领域。然而，我们推测，许多可能具备意识且同时作为智能体的系统都将拥有效价体验，因为智能体必须评估各种选项才能选择行动。

简而言之，低估意识风险应引起高度重视。如果未能将具有意识的人工智能系统识别为具有意识的系统，就可能导致我们给许多有意识的存在带来不必要的痛苦。

4.1.2 过度赋予人工智能意识

我们还很有可能对人工智能系统过度赋予意识——事实上，这种情况似乎已经在发生了——而且这种错误也伴随着风险。最直接地说，我们可能会错误地优先考虑人工智能系统的所谓利益，而实际上，我们的努力更应致力于改善人类和非人类动物的生活。正如施维茨格贝尔和加尔萨（2015，2020）所指出的，对人工智能系统道德地位的不确定性是危险的，因为无论是低估还是高估其道德地位，都可能带来高昂的代价。

过度归因很可能是因为人类有一种根深蒂固的倾向，即把拟人化和类似人类的心理状态过度归因于非人类系统。越来越多的研究探讨了人们将意识和能动性归因于人工系统的倾向，以及影响这种归因的因素（丹尼特 1987，格雷与韦格纳 2012，卡恩等人 2006，克拉赫等人 2008，赛茨马 2014）。人类之所以会产生“主体偏见”——一种自然而然地将能动性、意图和情感归因于非人类实体的倾向——可能有多种原因，这些原因可追溯到我们的进化历史（古斯里 1993）。

一种可能性是，我们可能会对人工智能系统进行拟人化处理，因为这似乎有助于我们理解和预测它们的行为——尽管这种印象可能是虚假的，拟人化实际上可能导致我们做出错误的解读。拟人化使我们能够借助理解人类时所用的认知框架，来理解和预测人工智能等复杂系统的行为，从而可能帮助我们更好地应对与人工智能的互动（Epley等人，2007）。丹尼特提出，个体采用了一种名为“意向立场”的认知策略，用以预测和解释各种实体的行为，包括人类、动物和人工系统（丹尼特，1987）。意向立场涉及将信念、欲望和意图等心理状态归因于某个实体，以解读并预测其行为。观察和与人工智能系统的互动往往会自然而然地促使人们采取意向立场，尤其是在这些系统的行为看似有目的或以目标为导向时。当人工智能系统表现出类似人类的特征时，例如自然语言处理、面部表情或自适应学习能力，这种倾向会进一步增强（马佐尔等人，2021）。研究人员已确定了若干因素，这些因素会使个体更容易对人工智能系统进行拟人化处理，包括它们的外观、行为以及被感知到的自主性（卡恩等人，2006；兹沃托夫斯基等人，2015）。

对人工智能体的代理性和意识的归属也可能源于一种对社会互动的情感需求（Mazor等，2021）。寻求社会互动的个体以及

来自人工系统的满足感可能更容易使人们将意识归于它们。将类似人类的特征赋予人工智能，有助于人们应对困难的情绪或处境，例如，当人们觉得向一个看似富有同理心或理解力的人工智能倾诉会更自在（Turkle 2011）。作为社会互动来源的人工系统，如Replika聊天机器人，其应用已十分明显。

语言模型能力的近期快速进步尤其可能引发对意识的过度归因，布莱克·勒莫因的案例就充分说明了这一点（勒莫因，2022）。现代大型语言模型能够令人信服地模仿人类话语，这使得人们很难抗拒这样一种印象：自己正在与一个具有意识的智能体互动，尤其是当模型被提示在对话中扮演一个人的角色时（沙纳汉等人，2023）。

除了我们上面提到的资源错配风险之外，过度赋予人工智能系统意识还会带来至少三种其他风险。首先，如果有时基于薄弱证据就将意识归于人工智能系统，这些归因可能会削弱那些有更充分证据支持的人工智能意识主张。关注这一话题辩论的观察者可能会意识到某些归因是站不住脚的，并进而认为所有归因都是如此。如果人们还合理地担忧，将意识归于人工智能会分散我们对其他紧迫问题的注意力，那么这种影响可能会特别显著。其次，如果我们判定某一类人工智能系统具有意识，这应当促使我们以不同方式对待它们——例如采用不同的训练方法。从原则上讲，这可能与确保人工智能系统以造福社会的方式发展的努力相冲突。第三，过度归因还可能干扰宝贵的人际关系，因为越来越多的人开始转向人工智能体寻求社交互动和情感支持。这样做的个体也可能特别容易受到操纵和剥削。

无论人们对这些不同风险的相对重要性持何种看法，它们都为人工智能中意识前景的研究提供了有力的依据。如果人工智能的发展要继续下去，这项研究将是至关重要的：在缺乏充分依据的情况下，断言没有任何人工智能系统能够具备意识，或者某一特定类别的人工智能系统具备意识，都是有风险的。

4.2 意识与能力

在大众的普遍认知中，意识与自由意志、智力以及感受人类情感的倾向相关联，包括同理心、爱、内疚、愤怒和嫉妒。因此，我们提出的近期内可能实现具有意识的人工智能这一观点，可能会被理解为：我们很快就能拥有类似于科幻小说中那种高度拟人化的人工智能系统。然而，这种推测是否真的成立，取决于意识与其他认知特征和能力之间的关系。此外，如果意识与人工智能中某些有价值的能力相关联（或预期会相关联），那么构建具备意识的人工智能系统就更有可能实现。因此，在本小节中，我们将简要探讨意识如何影响人工智能系统行为与能力上的差异。

支持我们很可能开发出具有意识的人工智能这一观点的一个可能论据是，意识与动物的更强能力相关联，因此，在追求更强大人工智能的过程中，我们也将开发出具有意识的人工智能系统。诚然，关于意识的科学理论通常认为，意识体验与适应性特征相关联，这些特征因对人类及其他一些动物的认知表现作出贡献而被自然选择所青睐。例如，巴尔斯

(1988，1997）声称，全局工作区“优化了组织与灵活性之间的权衡”（1988，第348页），而先进的人工智能系统也理应能够管理这种权衡。

这一论点的一个弱点在于，人类和动物的思维并不一定能够很好地指导我们理解意识与人工智能系统中能力之间的联系。这是因为，动物思维的“设计”不仅由我们能力的适应性价值所解释，还受到我们进化过程中所面临的种种限制的影响，这些限制包括：我们能够从中学习的数据的数量和形式的局限；为我们的大脑提供能量的可用能量总量的限制；以及我们祖先的大脑形态和相关突变的可获得性。人工智能系统的可能设计空间与生物学中可能的大脑设计空间是不同的（Summerfield 2022）。因此，我们完全有可能找到方法来构建高性能但不具备意识的人工智能系统。

然而，一些有影响力的AI研究人员目前正在开展项目，旨在通过构建更有可能具备意识的系统来提升AI的能力。我们已经讨论过Bengio及其同事正在进行的工作，该工作借鉴了GWT的思想。Goyal和Bengio（2022）写道：

> 我们的目标是汲取（并进一步发展）关于意识处理认知科学的研究成果，从而打造功能大幅增强的人工智能，使其具备人类所拥有的高级推理能力。

这里的目标是构建能够实现人类意识至少部分基本特征的AI系统，尤其是为了增强其能力。同样，LeCun提出的自主智能架构具有诸如用于规划的世界模型以及一种被称为“配置器”的组件，该组件被描述为“从所有其他模块获取输入，并针对当前任务对[其他模块]进行配置”（LeCun 2022，第6页）。LeCun还指出，人类大脑中存在类似这样的元素，可能正是导致他所称的“意识幻觉”的原因。这些例子体现了人工智能领域一种广泛而悠久的做法：借鉴认知科学的洞见（Hassabis等，2017；Zador等，2022）。因此，无论是否只有通过融入与意识相关的特征才能实现更强大的能力，这都将是我们在未来很可能会采取的一条路径。

现在我们来谈谈有意识的人工系统可能表现出的行为。从概念和实证两个方面来看，都有理由怀疑，拥有意识并不意味着具备类似人类的动机或情感。从概念上讲，拥有意识仅仅意味着拥有主观体验。原则上，可能存在一些具有意识的主体，其体验与我们的截然不同。特别是，动机中立的意识体验这一概念本身并无明显的概念矛盾——这种体验既缺乏效价，也缺乏情感。即使某个意识主体确实拥有带有效价或情感的状态，这些状态也可能由与引发我们情感的那些情境不同的因素触发，并以不同的方式驱动其行为。

从经验上看，我们所讨论的意识理论通常并不主张意识必然意味着类似人类的动机或情感。一个例外是这样一种观点：意识只有在自我维持的背景下才有可能实现，这一点我们在第2.4.5节中已经讨论过。因为这种观点很可能不仅意味着有意识的存在会进行自我维持，而且它们还会出于某种动机而主动这么做。不过，这种观点属于特例。一些理论，比如GWT和PRM，则认为有意识的主体必须是行动者，或许它们的欲望也倾向于参与其中。

有意识的体验——在GWT中，工作区维护着一些表征，这些表征为模块中的处理提供了重要的上下文，而当前的欲望或许正符合这一描述。但这些理论对于驱动有意识主体的因素却持中立态度。AST则要复杂一些：格拉齐亚诺（2013）认为，使用注意模式对于社会认知至关重要，因为它使人们能够对自己或他人的注意力进行建模。他进一步指出，这正是构建有意识人工智能的一个理由，因为具备注意模式的人工智能系统将具备同理心（格拉齐亚诺，2017）。然而，这里的论点似乎在于，实现AST是向他人赋予有意识状态所必需的，从而也才能以同理心为动力去帮助他们，而非仅仅认为有意识本身足以产生同理心动机。

当前许多关于人工智能影响的担忧，并不取决于人工智能系统是否可能具备意识。例如，人们担心基于反映当前社会结构的数据训练的人工智能系统可能会延续或加剧不公正现象，这种担忧并不以人工智能具备意识为前提。同样，人们还担心人工智能可能促成各种形式的压制，或者人工智能系统可能取代大多数人类劳动者的工作（尽管取代人类劳动者的经济价值或许会推动相关能力研究，进而导致具备意识的人工智能出现，这一点我们已经提到过）。也许最令人惊讶的是，那些认为人工智能可能对人类构成生存风险的论点也并未假定人工智能具备意识。支持这一结论的典型论证依赖于以下两个前提：(i) 我们将开发出具有极高能力、能够制定并执行实现目标的计划的人工智能系统；(ii) 如果我们赋予这些系统选择不当的目标，它们所找到的实现目标的方法可能会造成极其严重的危害（参见Hilton 2022等文献）。无论是这两个前提本身，还是通常对它们进行阐释和辩护的方式，都未假定人工智能系统具备意识。

4.3 推荐

几位作者就人工智能具备意识的可能性提出了重要的实践建议。其中包括：布莱森（2010）提出的应避免开发具有意识的人工智能的观点；梅茨inger（2021）呼吁暂停可能催生具有意识的人工智能的研究工作；格拉齐亚诺（2017）支持开发具有意识的人工智能的论点；施维茨盖贝尔和加尔萨（2020）主张，我们只应在确信特定的人工智能系统将具备意识或确信它们不会具备意识的情况下才去构建这些系统；以及博斯特罗姆和舒尔曼（2022）提出的详细建议。我们并未对这些建议背后的论据进行评估，也在此不再进一步讨论。

然而，我们确实建议支持对意识科学及其在人工智能领域应用的研究（正如AMCS就此主题所发表的公开信中所建议的；AMCS 2023），并在评估人工智能中的意识时采用理论导向的方法。我们推进对哪些人工智能系统可能具备意识这一问题的进展的一个途径，是发展并检验有关意识的科学理论；在现有范式内进行理论上的完善同样具有价值，同时尝试检验不同竞争理论的预测也至关重要，例如目前正在进行的Cogitate对抗性合作研究（Melloni等，2021）。另一个途径是开展严谨的实证研究，将意识理论扩展到非人类动物领域。这将有助于我们基于更广泛的案例证据，建立一种更具普遍性的意识相关性解释（Andrews与Birch，2023）。第三个途径则是专门针对人工智能情境下意识理论的精细化研究。这类研究可能涉及对人工智能实现方式的理论探讨。

涉及意识理论的机制；构建此类系统并测试其能力；识别现有理论中的歧义；以及开发并论证更精确的理论表述，从而使其对人工智能的含义更加清晰。将此类工作与关于人类和动物意识的持续实证研究相结合，有望取得特别丰硕的成果。

另外两条研究方向可能也很重要。其一是专门针对情感和情绪意识的研究；如果这种类型的意识体验尤其具有道德意义，而事实似乎的确如此，那么我们就迫切需要建立扎实的计算理论，以便将其应用于人工智能。另一条方向则是努力开发更有效的行为测试，以评估人工智能中的意识。尽管我们认为目前以理论为导向的方法最具前景，但也有可能开发出难以被操纵且基于有力理由的行为测试——这些测试或许可以借鉴相关理论。如果能够开发出这样的测试，它们可能会在实际应用中比依赖理论的评估方法更具优势。

随着我们对意识的了解不断深入，以及获得更有效的工具来评估人工智能系统中是否可能存在意识，我们也必须有效地使用这些工具。这意味着，在开发新型人工智能系统时，我们要同时采用理论驱动的方法——既要在前瞻性地评估计划中的系统在建成前具备意识的可能性时运用这种方法，也要在回顾性地评估时运用这种方法。在回顾性评估中，机制可解释性方法可能尤为重要，因为那些原本并未内置潜在支持意识功能的系统，有可能在训练过程中习得这些功能。这也意味着，科学理论应当成为与意识相关的人工智能政策和监管的核心。

方框4：关于人工智能中意识的开放性问题

本报告并非关于人工智能意识的最终结论。恰恰相反：我们的一个重要目标是推动进一步的研究。在意识神经科学领域的进一步进展将有助于我们理解人工智能实现意识的条件，我们还提出，对非人类动物意识的研究可能尤其具有价值。在此，我们重点探讨一些与理解人工智能意识特别相关的研究问题。

改进和扩展我们的方法

虽然采用了与本报告相同的基本方法，但进一步的研究可以：

- 考察本报告未涉及的其他合理的意识理论，并利用这些理论推导出更多的意识指标；
- 完善或修订我们从这里所考虑的理论中得出的指标；
- 对其他人工智能系统进行评估，或研究指标的不同实现方式。

此外，我们的方法可以通过开发一种适用于人工智能系统的意识正式评估程序来扩展，尽管这是否可行尚存疑问。

在目前这种对计算功能主义以及特定科学理论存在重大不确定性的背景下，这是有道理的。

计算功能主义与竞争观点

确定意识是否能在传统计算机硬件上实现，是一个难题，但若能取得进展，将具有特别重要的意义，而哲学研究可为此作出贡献。例如，计算功能主义的怀疑论者指出，生物体不仅是自我维持的稳态系统，而且由自身积极进行自我维持的细胞构成（如Seth 2021、Aru等 2023）；进一步的研究可以阐明，这为何可能与意识相关。此外，研究还可探讨标准计算机是否存在某些特征，这些特征可能与意识不相容，但在非传统（例如神经形态）硅基硬件中却不存在。另一个值得哲学研究的主题是人工智能系统的个体化问题，因为人工智能系统可以被复制、分发、同时在多个地方调用等等。

人工智能中的价态与现象特征

我们暂且搁置这样一个问题：有意识的AI系统可能会拥有何种类型的体验。从原则上讲，这些体验可能与人类的体验大相径庭。一个重要的问题是，要使AI系统具备带有情感色彩的有意识体验——即令人感觉良好或不好的体验——需要具备哪些条件，因为这类体验可能具有特殊的道德意义。对情感计算理论的研究将有助于解决这一问题。

人工智能可解释性研究

理论导向方法的一个重大障碍是我们对复杂深度学习系统的内部运作机制了解有限。人工智能可解释性研究旨在阐明并解释这些运作机制，因此能够为多种人工智能研究做出贡献，包括意识研究。

行为测试与内省

尽管我们已强调了行为测试在人工智能意识研究中的局限性，但我们仍对开发出有力的测试方法持开放态度，因此朝着这一方向开展的研究或许具有重要价值。行为测试并不一定要“中立于理论”，而是可以基于特定的科学理论。另一种可能的途径是开发具备可靠内省能力的人工智能系统，使其能够有意义地报告自身的意识状态或缺乏意识的状态（Long即将出版）。

人工智能意识研究的伦理问题

总的来说，我们认为，开展研究以更好地理解可能潜藏于人工智能中的意识机制是有益的。然而，这一领域的研究存在构建（或促使他人构建）具有意识的人工智能系统的风险，这种做法绝不能轻率为之。在权衡此类风险时，应仔细考量其与更好理解人工智能中意识价值之间的关系。

术语表

术语	描述
AST	注意模式理论
GWT	全局工作区理论
霍斯	高阶状态空间理论
热门	高阶理论
PP	预测处理
PRM	感知现实监控理论
RPT	递归处理理论
UAL	无限联想学习
获取意识	“功能”概念与现象意识相对；如果一个状态的内容能直接被其主体所获取，以执行各种认知任务，例如报告、推理和理性行动，则该状态即为可访问意识。
机构	如果系统通过与环境的交互来追求目标，则它们是智能体（参见第 2.4.5 (a) 节）
算法递归	重复处理的形式，其中应用相同的运算，例如在神经网络中，信息通过具有相同权重的层；与实现性递归相对。
断言力	一些有意识经验的一个特征，即它们的内容准确地反映了世界，促使我们形成相应的信念。
吸引子动力学	某些动力系统所具有的特性，即该系统倾向于收敛到若干个稳定“吸引子”状态之一。
后向掩蔽	在短暂呈现目标刺激后不久呈现一个刺激（掩蔽），其效果是第一个刺激不会被有意识地感知到。
贝叶斯推断	根据贝叶斯法则进行推理，该法则指出，在给定某些数据的情况下，某个状态成立的概率与该状态的先验概率乘以在该状态下数据出现的概率成正比。
双眼竞争	一种实验范式，其中向每只眼睛呈现不同的图像，从而导致图像之间的感知交替。
经典条件反射	一种学习形式，其中中性刺激与能引发先天反应（如趋近或回避）的刺激配对，从而导致先前中性刺激与该反应之间产生关联。
认知架构	认知系统中功能单元的排列和连接方式

术语	描述
计算的 功能主义	实现某种计算对于意识来说是必要且充分的这一论点（参见第1.2.1节）
信心或确信	置信度；一个人会赋予某一主张的概率
对比分析	意识科学中的一种方法，其中涉及有意识和无意识状态，例如有意识和 对刺激的无意识视觉处理，彼此形成对比；例如，寻找大脑活动中相应的差异
交叉注意力	人工智能中的过程，允许信息从系统的一个部分被选择并传递到另一个部分（参见方框3）
具身的、主动的和 扩展认知	认知过程深受身体和环境的影响，有时甚至会利用身体和环境的观点
端到端训练	在机器学习中，与分别训练各个组件后再进行组合不同，是将系统的所有组件一起进行训练。
特征提取	识别视觉场景中的特征
特征绑定	将对象的单独特征，例如“黄色”和“正方形”，整合到统一的表示中
前馈处理	与递归处理相对，指以顺序方式应用一组不重复的操作的处理。
图形-背景分离	视觉中区分物体与背景
一阶表示	与高阶表征相对，关于非表征性世界的表征；范例包括对苹果等外部物体的视觉表征
前向模型	输出如何导致身体和环境变化的模型，尤其是在运动控制的背景下
生成模型	一种输入数据的统计模型（例如感觉刺激模式），可对其进行采样以生成新的合成数据
全球广播	在 GWT 中，信息可供所有模块使用（请参阅第 2.2 节）
目标导向与习惯性 行为	在心理学中，区分由结果价值表征所引发的行为与行动-结果之间的区别 偶发情况（目标导向）以及由情境中行动价值表征所引发的行为（习惯性）
高阶 表示法	关于其他表示的表示（例如，另一个表示是可靠的表示）
点火	在GWT中，大脑活动的突然、非线性变化与一种状态即将被全球广播相关联
实施性的 递归	计算系统的特点，广泛存在于大脑中，其中算法递归由反馈回路实现，信息通过相同的单元反复传递。

术语	描述
指标/指标属性	本研究中确定的使人工智能系统更有可能具有意识的属性
关键查询注意力	人工智能中选择信息的流程；交叉注意力和自注意力是键值注意力的一种形式（参见方框3）
潜在空间	表示空间，用于表示无法直接观测的变量，或允许学习此类空间的人工智能架构特征
掩蔽启动实验	实验中，一个掩蔽刺激（参见后向掩蔽）会影响（通常为促进，即启动）第二个可见刺激的处理。
元认知	对自己认知过程的认知，例如对其可靠性和准确性的认知
元认知监控	其他认知系统对认知过程的监控（参见第2.3节）
模块	在 GWT 中，能够独立执行任务的专用子系统（请参阅第 2.1 节）
多头注意力层	在 Transformers 中，并行实现自注意力或交叉注意力变体的层
自然种类	由于具有共同的潜在本质而具有相似表面属性的实体集合（例如，黄金、老虎）； 意识可能是一种心理/计算的自然种类
无报告范式	使用对比分析的实验范式，但采用其他指标（例如脑活动、眼动）来区分有意识和无意识状态。
神经相关性意识状态	共同足以构成意识状态的最小神经事件集
知觉组织	感知中对有组织场景的表征的生成，例如区分物体并表征它们的相对位置
视角	具身系统的特征在于，它们的输入取决于其在环境中的位置，并受其影响。 运动
现象意识	本报告中我们所理解的意识；参见第1.1节
非凡的字符	经验的内容；主体拥有这种经验时的感受
预测编码	认知预测处理理论所描述的一种计算形式，其中分层生成模型预测输入，并通过最小化预测误差来估计环境状态。
问题直觉	人类对意识的直觉，很难与唯物主义相调和

术语	描述
质量空间	现象品质的相似性空间，即构成现象特征的属性 经验
递归处理	查看算法递归和实现递归
强化学习	一种机器学习形式，其目标是通过与环境的交互来最大化累积奖励（参见第3.1.5节）；也是一种生物学习形式
自注意力	人工智能中的一种过程，其中通过功能单元之间的成对交互整合多个输入标记的信息；Transformer 中的关键过程（参见方框 3）
感知力	术语有时但并不总是与“意识”同义；参见第1.1节
主观体验	有意识的体验；参见第1.1节
系统2思维	受控的、费力的、通常可言说的思维，依赖于明确的知识；与认知“双过程”理论中更自动化的系统1思维形成对比。
理论导向的方法	基于意识科学理论确定哪些系统具有意识的方法
变压器	深度学习架构，是许多大型语言模型及其他近期人工智能系统的基础，它依赖于 **多头注意力机制（参见第3.2.1节和方框3）**
有价或情感的经验	让人感觉良好或不好的经历，例如快乐或痛苦

参考文献

阿拉米亚，A.，莫扎法里，M.，乔克西，B.，& 范鲁伦，R.，2023。关于反馈在噪声和对抗性攻击下图像识别中的作用：一种预测编码视角。神经网络，157，第280–287页。

阿尔班塔基斯，L.，与托诺尼，G.，2021年。我们所是的，远不止我们所做的。 arXiv预印本 arXiv:2102.04219。

阿里，A.，艾哈迈德，N.，德格鲁特，E.，约翰内斯·范赫文，M. A.，& 基茨曼，T. C.，2022。预测编码是循环神经网络中能量效率的体现。 模式，3(12)，100639。

安德森，P.，斯特兰德曼，A. 和 斯特拉内格德，C.，2019。用于稳态代理的探索策略。载于 通用人工智能：第12届国际会议， 第178-187页。

安德鲁斯，K.，与伯奇，J.，2023年。要理解人工智能的感知能力，首先要从动物入手。Aeon随笔。 Aeon. https://aeon.co/essays/to-understand-ai-sentience-first-understand-it-in-animals 阿鲁，J.，巴赫曼，T.，辛格，W.与梅洛尼，L.，2012年。提炼意识的神经相关性。 神经科学与生物行为评论，36(2)，第737–746页。

Aru, J., Larkum, M. 和 Shine, J. M.，2023年。从神经科学的视角看人工意识的可行性。 arXiv:2306.00915。

巴尔斯，B. J.，1988. 一种关于意识的认知理论. 剑桥大学出版社。

巴尔斯，B. J.，1997年。在意识的剧场中：全局工作空间理论，一种严谨的意识科学理论。 意识研究杂志，4(4)，第292–309页。

Bahdanau, D., Cho, K., & Bengio, Y., 2014. 通过联合学习对齐和翻译实现神经机器翻译。 arXiv预印本 arXiv:1409.0473.

鲍，C.，丰塔斯，Z.，奥卢格巴德，T.，& 比安奇-贝尔图兹，N.，2020。基于全局工作空间理论的多模态数据融合。 arXiv:2001.09485。

巴拉斯蒂娜，L.，& 海沃德，M. K.，2019。更多关于我！更少关于我！：关于情感现象特征的反身命令主义。 心灵，128(512)，第1013–1044页。

巴特利特，P. L.，蒙塔纳里，A.，拉赫林，A.，2021年。深度学习：一种统计视角。 数值分析学报，30，第87–201页。

贝恩，T.，2010. 意识的统一性. 牛津大学出版社。

贝恩，T.，与蒙塔古，M.，2011. 认知现象学. 牛津大学出版社。

贝恩，T.，塞斯，A. K.，马西米尼，M.，2020年。是否存在意识的孤岛？ 神经科学趋势，43(1)，第6-16页。

贝克-埃姆克，P.，卡尔，M.，彼得斯，J.，& 范德斯马赫特，P.，2020。通过基于深度模型的强化学习学习飞行。 arXiv:2003.08876。

贝尔金，M.，马，S.，曼达尔，S.，2018年。要理解深度学习，我们需要理解核学习。在第35届国际机器学习大会论文集中，第541–549页。

本吉奥，Y.，2017。意识优先。 arXiv:1709.08568。

Bengio, E., Jain, M., Korablyov, M., Precup, D. & Bengio, Y., 2021. 基于流网络的生成模型，用于非迭代的多样化候选生成。 arXiv:2106.04399。

本吉奥，Y.，拉卢，S.，德勒，T.，胡，E. J.，蒂瓦里，M.，和本吉奥，E.，2023。GFlow Net基础。 arXiv:2111.09266。

比肖特，N. P.，赫德，M. T.，德詹纳罗，E. M.，& 德西蒙，R.，2015。前额叶皮层中基于特征的注意的来源。 神经元，88(4)，第832-844页。

伯奇，J.，2018年。动物认知与人类价值观。 科学哲学，85(5)，第1026–1037页。伯奇，J.，2020年。全局工作空间理论与动物意识。 哲学专题，48(1)，第21–38页。

伯奇，J.，施内尔，A. K.，克莱顿，N. S.，2020年。动物意识的维度。认知科学趋势，24(10)，第789–801页。

伯奇，J.，金斯堡，S.，& 雅布隆卡，E.，2020。无限联想学习与意识的起源：入门及一些预测。 生物与哲学，35(6)，第56页。

伯奇，J.，2022a。唯物主义与动物的道德地位。《哲学季刊》，72(4)，第795–815页。

伯奇，J.，2022b。无脊椎动物意识的探寻。诺斯，56，第133–153页。

布洛克，N.，1995年。关于对意识功能的一种混淆。 行为与脑科学， 18，第227–247页。

布洛克，N.，1996。心理颜料与心理乳胶。哲学问题，7，第19–49页。

布洛克，N.，2002年。一些关于意识的概念。心灵哲学：经典与当代读本。第206–218页。

布洛克，N.，2007年。意识、可及性以及心理学与神经科学之间的桥梁。行为与脑科学，30，第481–499页。

布洛克，N.，2023. 视觉与思维之间的边界. 牛津大学出版社。

鲍尔斯，J. S.，马尔霍特拉，G.，杜伊莫维奇，M.，蒙特罗，M. L.，茨韦特科夫，C.，比斯乔内，V.，普埃布拉，G.，阿道尔菲，F.，胡梅尔，J. E.，希顿，R. F.，埃文斯，B. D.，米切尔，J.，& 布莱辛，R.，2022。人类视觉神经网络模型中的深层问题。行为与脑科学，第1–74页。

布赖特迈尔，B. G.，& 于门，H.，2006.视觉掩蔽：意识与无意识视觉的时间切片 （第2版）。牛津大学出版社。

布朗夫曼，Z. Z.，金斯堡，S.，& 雅布隆卡，E.，2016。通过联想学习的进化实现向最小意识的转变。 心理学前沿，7，1954。

布朗，R.，2015年。现象意识的HOROR理论。哲学研究，172，第1783–1794页。

布朗，R.，刘，H.，& 莱杜克斯，J.E.，2019。理解意识的高阶方法。 认知科学趋势，23，第754–768页。

布朗，T.，曼恩，B.，赖德，N.，苏比亚，M.，卡普兰，J. D.，达里瓦尔，P.，尼拉坎坦，A.，夏姆，P.，萨斯特里，G.，阿斯克尔，A.，2020。语言模型是少样本学习者。 神经信息处理系统进展， 33，第1877–1901页。

布莱森，J.，2010年。机器人应成为奴隶。威尔克斯（编），与人工伴侣的亲密接触。约翰·本杰明斯出版社。

伯吉斯，C. P.，马特伊，L.，沃特斯，N.，卡布拉，R.，希金斯，I.，博特维尼克，M.，以及勒希纳，A.，2019年。MONet：无监督场景分解与表示。 arXiv:1901.11390。巴特林，P.，2022年。机器学习、函数与目标。克罗地亚哲学杂志，22(66)，第351–370页。

巴特林，P.，2023年。强化学习与人工智能代理。 思维与语言。

卡巴纳克，M.，1992年。愉悦：共同的货币。理论生物学杂志，155(2)，第173–200页。

卡鲁瑟斯，P.，2018年。价态与价值。哲学与现象学研究，97，第658–680页。

卡鲁瑟斯，P.，2019. 人类与动物的心智：意识问题尘埃落定。 牛津大学出版社。

卡鲁瑟斯，P.，与詹纳罗，R.，2020年。关于意识的高阶理论。E. N. 扎尔塔（编），斯坦福哲学百科全书（2020年秋季版）。

查尔莫斯，D.，1995。缺失的感质、消退的感质、舞动的感质。 意识体验。

查尔莫斯，D.，1996.《意识之谜：探寻根本理论》.牛津大学出版社。

查尔默斯，D.，2000。什么是意识的神经相关物？梅辛格（编），意识的神经相关物：概念与实证问题。麻省理工学院出版社。

查尔莫斯，D.，2002。意识及其在自然界中的地位。查尔莫斯（编），心灵哲学：经典与当代读本。牛津大学出版社。

查尔默斯，D.，2004。我们如何构建意识科学？加扎尼加（编）， 认知神经科学III。 麻省理工学院出版社。

查尔莫斯，D.，2013年。泛心论与泛原心论。阿默斯特哲学讲座。

查尔默斯，D.，2018年。意识的元问题。 意识研究杂志，25，第6–61页。

查尔默斯，D.，2023年。大型语言模型可能具有意识吗？波士顿评论.

乔德里，A.，纳朗，S.，德夫林，J.，博斯马，M.，米什拉，G.，罗伯茨，A.，巴勒姆，P.，钟，H. W.，萨顿，C.，格赫曼，S.，& 舒，P.，2022。PaLM：通过路径扩展语言建模。 arXiv:2204.02311

克拉克，A.，2000. 一种关于感知的理论. 牛津大学出版社。

克拉克，A.，2008. 超级化心灵：具身性、行动与认知扩展. 牛津大学出版社.

克拉克，A.，2019年。意识作为生成性纠缠。哲学杂志，116，第645-662页。

克莱尔曼斯，A.，阿舒伊，D.，博诺，A.，凯宁克斯，L.，马丁，J. R.，穆尼兹-莫尔德斯，S.，武伊洛姆，L.，以及赫林，A.，2020年。学会觉知。认知科学趋势 24，第112-123页。

康威尔，C.，与乌尔曼，T.，2022年。在文本引导的图像生成中测试关系理解。 arXiv:2208.00005。

克里克，F.，& 科赫，C.，1990。迈向意识的神经生物学理论。 神经科学研讨会。桑德斯科学出版公司，第263-275页。

丹顿，B.，2000.意识流：意识经验中的统一与连续性。罗特利奇。

丹顿，B.，2023年。时间意识。E. N. 扎尔塔与U. 诺德尔曼（编）《斯坦福哲学百科全书》（2023年春季版）。

迪恩，G.，2021。主动推断中的意识：深度自我模型、他人心智以及迷幻剂诱导的自我消解挑战。 意识的神经科学，2021(2)，niab024。

德哈恩，S.，与尚克，J. P.，2011年。关于意识加工的实验与理论方法。 神经元， 70，第200–227页。

德哈恩，S.，克尔兹伯格，M.，和尚克斯，J. P.，1998年。一种用于费力认知任务的全局工作空间神经元模型。载于美国国家科学院院刊，95(24)。14529– 14534。

德海恩，S.，劳，H.，库伊德，S.，2017年。什么是意识，机器能拥有它吗？科学，358，第486-492页。

德海恩，S.，与纳卡什，L.，2001年。迈向意识的认知神经科学：基本证据与工作空间框架。 认知，79，第1-37页。

德海纳，S.，塞尔热，C.，与尚克，J. P.，2003年。一种神经网络模型，用于连接主观报告与有意识感知期间的客观生理数据。美国国家科学院院刊，100，8520–8525。

德海恩，S.，2014. 意识与大脑：破译大脑如何编码我们的思想. 维京。

丹尼特，D. C.，1987. 意图立场. 麻省理工学院出版社。

迪克斯特拉，N.，博施，S. E.，& 格尔文，M. A. J. van., 2019。视觉感知与意象的共享神经机制。 认知科学趋势，23(5)，第423-434页。

迪克斯特拉，N.，范加尔，S.，赫尔利格斯，L.，博施，S. E.，& 范赫尔文，M. A. J.，2021。没有证据表明无意识处理和想象的刺激之间存在神经重叠。 ENeuro, 8(5), ENEURO.0228-21.2021.

迪克斯特拉，N.，科克，P.，弗莱明，S. M.，2022年。图像为感知检测增加了刺激特异性的感官证据。视觉杂志，22(2)，11。

迪克斯特拉，N.，& 弗莱明，S. M.，2023。主观信号强度区分现实与想象。 自然通讯，14(1)，文章1。

多里格，A.，舒格尔，A.，赫斯，K.，& 赫尔佐格，M. H.，2019。展开论证：为什么IIT及其他因果结构理论无法解释意识。 意识与认知，72，第49-59页。

多兰，R. J.，与达扬，P.，2013年。大脑中的目标与习惯。 神经元，80(2)，第312-325页。德雷茨克，F.，1988年。 解释行为：原因世界中的理由。 麻省理工学院出版社。德雷茨克，F.，1999年。机器、植物和动物：能动性的起源。 认知，51(1)，第19-31页。

德里斯，D.，夏，F.，萨贾迪，M. S. M.，林奇，C.，乔杜里，A.，伊希特，B.，瓦希德，A.，汤普森，J.，武翁，Q.，于，T.，黄，W.，切博塔尔，Y.，塞尔曼内，P.，达克沃斯，D.，莱文，S.，范-霍克，V.，豪斯曼，K.，图桑，M.，格雷夫，K.，弗洛伦斯，P.，2023。PaLM-E：一种具身多模态语言模型。 arXiv:2303.03378。

杜尔伯格，Z.，杜贝，R.，贝尔维安，I. M.，& 科恩，J. D.，2023。拥有多个自我有助于学习智能体在复杂多变的世界中探索和适应。 美国国家科学院院刊，120(28)，e2221180120。

Elamrani, A.，& Yampolskiy, R.，2019。机器意识测试综述。意识研究杂志，26，第35-64页。

埃尔哈吉，N.，南达，N.，奥尔森，C.，亨尼根，T.，约瑟夫，N.，曼恩，B.，阿斯克尔，A.，白，Y.，陈，A.，科纳利，T.，达萨尔玛，N.，德雷恩，D.，甘古利，D.，哈特菲尔德-多兹，Z.，埃尔南德斯，D.，琼斯，A.，克尔尼恩，J.，洛维特，L.，恩杜塞，K.，阿莫迪，D.，布朗，T.，克拉克，J.，卡普兰，J.，麦坎德利什，S.，和奥拉，C. 2021。变压器电路的数学框架。 变压器电路线程。 https://transformer-circuits.pub/

Epley, N., Waytz, A., & Cacioppo, J. T., 2007. 论“看见人类”： 一种关于拟人化的三因素理论。 心理评论，114(4), 页864-886。

埃文斯，G.，1982. 参照的多样性. 牛津大学出版社。

芬恩，C.，古德费洛，I.，和莱文，S.，2016年。通过视频预测进行物理交互的无监督学习。神经信息处理系统进展，29.

弗莱明，S. M.，2020。意识作为高阶状态空间中的推理。 意识的神经科学， 2020，020。

福多，J. A.，1983. 心智的模块性：关于心理机能的论文. 麻省理工学院出版社。弗兰肯，J. C.，比伦东克，L.，莫莱纳尔，D.，法伦福特，J. J.，基弗斯坦，J. D.，塞思，A. K.，& 范加尔，S.，2022。关于意识科学的理论基础、常见假设及当前状态的学术综述. 意识的神经科学， 2022，niac011。弗兰基什，K.，2016。作为意识理论的幻觉主义. 意识研究杂志，23，第11-39页。

富兰克林，S.，与格雷瑟，A.，1999年。意识的软件代理模型。 意识与认知，8(3)，第285-301页。

弗里德里希，J.，戈尔卡尔，S.，法拉沙希，S.，根金，A.，森古普塔，A.，& 切克洛夫斯基，D.，2021。基于局部学习规则的神经最优反馈控制。 神经信息处理系统进展，34，16358–16370。

弗里斯顿，K.，2010。自由能量原理：一种统一的大脑理论？ 自然评论·神经科学，11，第127–138页。

格什曼，S. J.，2019。生成对抗性大脑。 人工智能前沿，2，18。金斯堡，S.，& 雅布隆卡，E.，2019。 敏感灵魂的进化：学习与意识的起源。麻省理工学院出版社。

戈德弗里-史密斯，P.，2016年。心智、物质与新陈代谢。《哲学杂志》，第113卷，第481–506页。

戈德弗里-史密斯，P.，2019年。跨越解释鸿沟而进化。 生物学中的哲学、理论与实践，11(1)。

戈夫，P.，2017. 意识与根本现实. 牛津大学出版社。

戈兰，T.，拉朱，P. C.，& 克里格斯科特，N.，2020。有争议的刺激：将神经网络相互对立，作为人类认知的模型。载于美国国家科学院院刊，117(47)，29330–29337。

Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y., 2014. 生成对抗网络。 arXiv:1406.2661。

戈亚尔，A.，兰姆，A.，甘帕，P.，博多安，P.，莱文，S.，布伦德尔，C.，本吉奥，Y.，莫泽，M. 2020。对象文件与模式：分解动态系统中的声明式与过程式知识。 arXiv:2006.16225。

戈亚尔，A.，& 本吉奥，Y.，2022。用于高级认知深度学习的归纳偏置。皇家学会A刊：数学、物理与工程科学，478(2266)，20210068。

戈亚尔，A.，迪多尔卡，A.，兰姆，A.，巴多拉，K.，凯，N. R.，拉赫曼，N.，比纳斯，J.，布伦德尔，C.，莫泽，M.，及本吉奥，Y.，2022年。通过共享的全局工作区实现神经模块间的协调。 arXiv预印本 arXiv:2103.01197。

格雷，K.，与韦格纳，D. M.，2012年。感受机器人与人类僵尸：心智感知与诡异谷。 认知，125(1)，第125–130页。

格拉齐亚诺，M. S.，2013. 意识与社会大脑. 牛津大学出版社。

格拉齐亚诺，M. S.，2017年。注意模式理论：构建人工意识的基础。 机器人与人工智能前沿，4(60)。

格拉齐亚诺，M. S.，2019a. 重新思考意识：主观体验的科学理论。WW诺顿公司。

格拉齐亚诺，M. S.，2019b。我们是自称有意识的机器。 意识研究杂志，26，第95–104页。

Greff, K., van Steenkiste, S. 和 Schmidhuber, J.，2020。关于人工神经网络中的绑定问题。 arXiv:2012.05208.

冈克尔，D. J.，2012. 机器问题：关于人工智能、机器人和伦理的批判性视角. 麻省理工学院出版社。

古斯里，S.，1993. 云中的面孔：一种新的宗教理论。 牛津大学出版社。哈纳德，S.，2003。机器能有意识吗？如何实现？ 意识研究杂志，10(4-4)，第69-75页。

哈萨比斯，D.，库马兰，D.，萨默菲尔德，C.，& 博特维尼克，M.，2017。受神经科学启发的人工智能。 神经元，95(2)，第245-258页。

赫尔佐格，M. H.，德里西-达乌迪，L.，& 多里格，A.，2020。一切顺其自然：长期的后预测效应揭示了离散的感知。 认知科学趋势，24(10)，第826-837页。

海耶斯，C.，& 迪金森，A.，1990。动物行为的意向性。 心智与语言，5，第87-103页。

霍威，J.，2022年。有意识的自我证实。哲学与心理学评论，13(4)，第809-828页。

胡，E. J.，马尔金，N.，贾因，M.，埃弗雷特，K.，格莱科斯，A.，& 本吉奥，Y.，2023。用于学习组合潜在变量模型的GFlowNet-EM。 arXiv:2302.06576。

赫利，S. L.，1998. 行动中的意识. 哈佛大学出版社。

欧文，E.，2013年。意识的度量。 哲学指南，8(3)，第285-297页。

Jaegle, A., Gimeno, F., Brock, A., Vinyals, O., Zisserman, A., & Carreira, J., 2021a. Perceiver：基于迭代注意力的通用感知。 机器学习国际会议。 PMLR，第4651-4664页。

Jaegle, A., Borgeaud, S., Alayrac, J.-B., Doersch, C., Ionescu, C., Ding, D., Koppula, S., Zoran, D., Brock, A., Shelhamer, E., 2021b. Perceiver IO：一种用于结构化输入与输出的通用架构。 arXiv:2107.14795。

Ji, X., Elmoznino, E., Deane, G., Constant, A., Dumas, G., Lajoie, G., Simon, J., & Bengio, Y., 2023. 现象学意识状态的丰富性和不可言说性来源。 arXiv:2302.06403。Johnson, L. S. M., 2022。 不确定性的伦理：意识障碍中的伦理与认知风险交织。牛津大学出版社。

Juechems, K.，& Summerfield, C.，2019. 价值从何而来？ 认知科学趋势，23(10)，第836-850页。

朱莉娅尼，A.，金井，R.，及佐佐木，S. S.，2022年。感知器架构是一种功能性的全局工作空间。载于认知科学学会年会论文集，44(44)。卡恩，P. H.，弗里尔，N. G.，神田，T.，石黑，H.，鲁克特，J. H.，塞弗森，R. L.，及凯恩，S. K.，2008年。人机交互中社交性的设计模式。载于第3届ACM/IEEE人机交互国际会议论文集，第97-104页。

Kahneman, D., 2011. 快速与缓慢的思考. 法拉尔、斯特劳斯和吉鲁。

Keramati, M., & Gutkin, B., 2014. 用于整合奖励收集与生理稳定性的稳态强化学习。 ELife, 3, e04811.

基茨曼，T. C.，斯波雷尔，C. J.，瑟伦森，L. K. A.，西希，R. M.，豪克，O.，以及克里格斯科特，

N., 2019。需要递归来捕捉人类视觉系统的表征动态。美国国家科学院院刊，116(43)，21854–21863。

Kiverstein, J., 2007. 机器人能拥有主观视角吗？ 意识研究杂志，14，第127–139页。

克拉克，A.，与基弗斯坦，J.，2007年。经验与能动性：滑出网格。 行为与脑科学，30(5–6)，第502–503页。

Krach, S., Hegel, F., Wrede, B., Sagerer, G., Binkofski, F.，& Kircher, T.，2008。机器能思考吗？通过fMRI研究与机器人互动及视角转换。 PLOS ONE，3(7)，e2597。

Kriegeskorte, N., 2015. 深度神经网络：一种用于建模生物视觉和大脑信息处理的新框架。 视觉科学年度评论，1(1) 第417–46页。

Krizhevsky, A., Sutskever, I., & Hinton, G. E., 2012. 基于深度卷积神经网络的ImageNet分类。 神经信息处理系统进展，25。

拉梅，V. A. F.，2006。迈向关于意识的真正神经立场。认知科学趋势，10(11)，第494–501页。

拉梅，V. A. F.，2010年。神经科学将如何改变我们对意识的看法。认知神经科学，1(3)，第204–220页。

拉梅，V. A. F.，2020年。视觉功能产生有意识的视觉。 心理学前沿，11，83。

劳，H.，2019年。意识、元认知与感知现实监控。 PsyArXiv.

劳，H.，2022. 我们相信意识：主观体验的认知神经科学。牛津大学出版社。

Lau, H. C., & Passingham, R. E., 2006. 正常观察者中的相对盲视及视觉意识的神经相关性。 美国国家科学院院刊，103(49)，18763–18768。

Lau, H.，& Rosenthal, D.，2011。对意识觉知高阶理论的实证支持。 认知科学趋势，15(8)，第365–373页。

LeCun, Y., Bengio, Y. 和 Hinton, G.，2015年。深度学习。 自然，521，第436–444页。

李，A. Y.，2022年。意识的程度。 诺斯.

勒莫因，B.，2022年6月14日。科学数据与宗教观点。 Medium. https:// cajundiscordian.medium.com/scientific-data-and-religious-opinion ff9b0938fc10 s-

林赛，G. W.，2020。心理学、神经科学和机器学习中的注意力。计算神经科学前沿，14，29。

林赛，G. W.，2021年。卷积神经网络作为视觉系统的模型：过去、现在与未来。认知神经科学杂志，33(10)，第2017–2031页。

刘，D.，博洛塔，S.，朱，H.，本吉奥，Y.，& 杜马斯，G.，2023。神经智能体中的注意力模式。arXiv:2305.17375.

龙，R.，即将出版。大型语言模型中的内省能力。意识研究杂志.

洛特，W.，克雷曼，G.，科克斯，D.，2017年。用于视频预测和无监督学习的深度预测编码网络。 arXiv:1605.08104。

洛特，W.，克雷曼，G.，科克斯，D.，2020年。一种用于预测的神经网络模仿了生物神经元和感知的多种特征。自然机器智能，2(4)，第4篇文章。莱肯，W. G.，2001年。关于意识高阶表征理论的一个简单论证。分析， 61(3-4)。

林奇，C.，瓦希德，A.，汤普森，J.，丁，T.，贝特克，J.，巴鲁赫，R.，阿姆斯特朗，T.，弗洛伦斯，P.，2022。交互式语言：与机器人实时对话。 arXiv:2210.06407。

马拉赫，R.，2021年。人类意识体验内容背后的局部神经元关系结构。 意识的神经科学，2021，niab028。

马拉赫，R.，2022年。前额叶皮层在意识感知中的作用：局部主义视角。 意识研究杂志，29(7-8)，第93-114页。

曼，K.，& 达马西奥，A.，2019。在情感机器设计中，稳态与软体机器人学。自然机器智能，1(10) 第446-452页。

马尔，D.，1982.视觉：关于人类视觉信息表征与处理的计算研究。W.H.弗里曼。

马舒尔，G. A.，罗埃尔夫塞马，P.，尚戈，J. P.，德哈恩，S.，2020年。意识加工与全局神经工作空间假说。 神经元， 105，第776-798页。

马图拉纳，H. R.，& 瓦雷拉，F. J.，1991. 自我生成与认知：生命的实现。施普林格。

马佐尔，M.，里索利，A.，埃伯哈特，A.，弗莱明，S. M.，2021年。道德地位的维度。载于认知科学学会年会论文集，43(43)。

麦克尼，D.，与沃尔珀特，D. M.，2019。生物控制中的内部模型。 控制、机器人与自主系统年度评论，2(1)，第339-364页。

梅达诺，P. A. M.，罗萨斯，F. E.，博尔，D.，塞思，A. K.，巴雷特，A. B.，2022年。弱整合信息理论的强度。 认知科学趋势，26(8)，第646-655页。

梅赫勒，J.，斯波雷尔，C. J.，琼斯，E. C.，克里格斯科特，N.，& 基茨曼，T. C.，2021。一种受生态学启发的用于深度学习的图像数据集，可生成更优的人类视觉模型。 美国国家科学院院刊，118(8)，e2011417118。

梅洛尼，L.，穆德里克，L.，皮茨，M.，& 科赫，C.，2021。让意识这一难题变得更容易。科学， 372，911-912。

梅雷尔，J.，阿尔达隆多，D.，马歇尔，J.，塔萨，Y.，韦恩，G.，& 奥尔维茨基，B.，2019年。虚拟啮齿动物的深度神经伦理学。 arXiv:1911.09451。

梅克尔，B.，2005年。移动性的负债：动物进化中向意识转变的选择压力。 意识与认知，14，第89-114页。

梅克尔，B.，2007年。没有大脑皮层的意识：对神经科学和医学的挑战。 行为与脑科学，30(1)，第63-81页。

梅辛格，T.，2021年。人工痛苦：关于全球暂停合成现象学的论证。 人工智能与意识期刊， 8，第43-66页。

米亚尔，R. C.，与沃尔珀特，D. M.，1996。用于生理运动控制的前馈模型。神经网络，9(8)，1265-1279。

米歇尔，M.，2022年。意识感知与前额叶皮层：综述。《意识研究杂志》，第29卷，第115-157页。

米歇尔，M.，即将出版。知觉现实监控理论。M.赫尔佐格、A.舒格尔和A.多里格（编），意识的科学理论：大巡游。剑桥大学出版社。

米歇尔，M.，& 多里格，A.，2022年。意识局部理论面临的一项新的实证挑战。心灵与语言，37(5)，第840-855页。

米歇尔，M.，& 劳，H.，2021。高阶理论表现良好。 认知神经科学， 12，77-78。

米歇尔，M.，& 莫拉莱斯，J.，2020。少数派报告：意识与前额叶皮层。 心智与语言，35(4)，第493-513页。

米尔奇，B.，萨尔瓦托里，T.，宋，Y.，博加奇，R.，卢卡谢维奇，T.，2022年。预测编码：迈向超越反向传播的深度学习未来？ arXiv:2202.09467。

Mnih, V., Heess, N. 和 Graves, A.，2014年。视觉注意力的循环模型。 神经信息处理系统进展，27.

莫拉莱斯，J.，奥德加德，B.，& 马尼斯基科，B.，2022年。无表现混淆的意识感知的神经基础。F. 德布里加尔与W. 辛诺特-阿姆斯特朗（编），神经科学与哲学。麻省理工学院出版社。

纳格尔，T.，1974年。成为一只蝙蝠是什么感觉？《哲学评论》， 83，第435-450页。

Nave, K., Deane, G., Miller, M.，& Clark, A.，2022. 期待一些行动：预测性处理与意识经验的构建。 哲学与心理学评论，13(4)，1019-1037。

诺伊，A.，2004.感知中的行动.麻省理工学院出版社。

Noudoost, B., Chang, M. H., Steinmetz, N. A., Moore, T., 2010. 视觉注意的自上而下控制。 神经生物学最新进展，20(2), 第183-190页。

Oizumi, M., Albantakis, L., & Tononi, G., 2014. 从意识的现象学到机制：整合信息理论3.0。 PLOS计算生物学 10，e1003588。Olah, C., Satyanarayan, A., Johnson, I., Carter, S., Schubert, L., Ye, K., & Mordvintsev, A., 2018. 可解释性的基本构件。 Distill， 3。

Oord, A. van den，Li, Y.，& Vinyals, O.，2019。基于对比预测编码的表征学习。 arXiv:1807.03748。

Oprea, S., Martinez-Gonzalez, P., Garcia-Garcia, A., Castro-Vargas, J. A., Orts-Escolano, S., Garcia-Rodriguez, J., & Argyros, A., 2022. 用于视频预测的深度学习技术综述。IEEE模式分析与机器智能汇刊，44(6)，2806-2826。

O'Regan, J. K., & No¨, A., 2001. 视觉与视觉意识的感觉运动解释。行为与脑科学， 24，第939–973页。

帕纳吉奥塔罗普洛斯，T. I.，德科，G.，卡普尔，V.，与洛戈塞蒂斯，N. K.，2012年。神经元放电和γ振荡明确反映了外侧前额叶皮层中的视觉意识。神经元，74(5)，第924–935页。

庞，Z.，奥梅，C. B.，乔克西，B.，& 范鲁伦，R.，2021。预测编码反馈导致循环神经网络中感知到的虚幻轮廓。 神经网络， 144，第164–175页。帕皮诺，D.，2002。 关于意识的思考。 牛津大学出版社。

彼得斯，M. A. K.，与劳，H.，2015年。即使对于视觉掩蔽的刺激，人类观察者也能对感知过程进行最佳的内省式访问。eLife， 4，e09651。

彼得森，A.，克鲁斯，D.，纳西，L.，韦耶，C.，欧文，A. M.，2015年。风险、诊断错误与意识的临床科学。神经影像：临床， 7，第588–597页。

菲利普斯，I.，2018a。现象意识的方法论难题。 皇家学会B：生物科学哲学事务 373，20170347。

菲利普斯，I.，2018b。意识、时间和记忆。《罗特里奇意识手册》(第286–297页)。罗特里奇。

普罗瑟，S.，2016.体验时间.牛津大学出版社。

奎尔蒂-邓恩，J.，波罗特，N.，& 曼德尔鲍姆，E.，2022。城里最好的游戏：思维语言假说在认知科学领域的重新兴起。 行为与脑科学，第1–55页。

拉德福德，A.，吴，J.，蔡尔德，R.，卢安，D.，阿莫迪，D.，和苏茨克弗，I.，2019。语言模型是无监督多任务学习者。 OpenAI博客 1，9

雷诺兹，J. H.，& 海格尔，D. J.，2009。注意的归一化模型。 神经元，61(2)，第168-185页。

罗森塔尔，D.，2005. 意识与心灵. 克拉伦登出版社。

罗森塔尔，D.，2010年。如何思考心理品质。 哲学问题，20(1)，第368–393页。

罗素，S.，& 诺维格，P.，2010. 人工智能：一种现代方法 （第3版）。普伦蒂斯-霍尔。

萨贾迪，M. S. M.，达克沃斯，D.，马亨德兰，A.，范·斯滕基斯特，S.，帕韦蒂，F.，卢伊，M.，吉巴斯，L. J.，格雷夫，K.，基普夫，T.，2022。物体场景表示变换器。 arXiv:2206.06 萨尔蒂，M.，蒙托，S.，查尔斯，L.，金，J.-R.，帕尔科宁，L.，德哈内，S.，2015。意识与无意识知觉的独立皮层编码及时间动力学。 ELife，4，e05652。 22.

Savage, J. E., 1972. 有限机上的计算工作与时间。 ACM期刊，19(4)，第660–674页。

施奈德，S.，2019. 人工你：人工智能与你心灵的未来. 普林斯顿大学出版社。施维茨格贝尔，E.，2016。现象意识，尽我所能以最朴素的方式定义并捍卫它。 意识研究杂志， 23，第224–235页。

施维茨盖贝尔，E.，2021. 信念. 在E. N. 扎尔塔（编）， 斯坦福哲学百科全书 (2021年冬季）。斯坦福大学形而上学研究实验室。

施维茨格贝尔，E.（即将出版）。边缘意识，当既不能确定地认为存在经验，也不能确定地认为不存在经验时。哲学研究.

施维茨格贝尔，E.，与加尔萨，M.，2015年。人工智能权利的辩护。中西部哲学研究，39 (1)，第98-119页。

施维茨盖贝尔，E.，与加尔萨，M.，2020年。以权利、意识、自尊和自由设计人工智能。廖（编），人工智能伦理。牛津大学出版社。

塞尔，J.R.，1980。心灵、大脑与程序。 行为与脑科学，3(3) 第417-457页 塞斯，A.，2021。 成为你：一种新的意识科学。 企鹅出版社。

塞斯，A. K.，与贝恩，T.，2022年。意识理论。 自然评论·神经科学， 第1-14页。

塞斯，A. K.，与霍维，J.，2021年。预测处理作为意识科学的实证理论。认知神经科学， 12，89-90。

沙纳汉，M.，2006年。一种将内部模拟与全局工作空间相结合的认知架构。 意识与认知 15，第433-449页。

沙纳汉，M.，2010. 身体化与内在生命：可能心智空间中的认知与意识。 牛津大学出版社。

沙纳汉，M.，麦克唐奈，K.，&雷诺兹，L.，2023。与大型语言模型进行角色扮演。arXiv: 2305.16367。

谢夫林，H.，2021年。非人类意识与特异性问题：一项温和的理论提议。 思维与语言，36 (2)，第297-314页。

舒尔曼，C.，与博斯特罗姆，N.，2021年。与数字心智共享世界。S. 克拉克、H. 祖尼和J. 萨弗勒斯库（编），重新思考道德地位。牛津大学出版社。

Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., van den Driessche, G., Schrittwieser, J., Antonoglou, I., Panneershelvam, V., Lanctot, M., Dieleman, S., Grewe, D., Nham, J., Kalch-brenner, N., Sutskever, I., Lillicrap, T., Leach, M., Kavukcuoglu, K., Graepel, T., & Hass-abis, D., 2016. 用深度神经网络和树搜索掌握围棋游戏。 自然，529(7587)，第7587期。

西蒙，J. A.，2017。模糊性与僵尸：为什么 “现象上具有意识” 没有边界案例。哲学研究，174(8)，2105-2123。

Sprevak, M. D., 2007. 中国房间与程序可移植性。 英国科学哲学杂志 58， 第755-776页。

斯蒂奇，S. P.，1978年。信念与亚认知状态。 科学哲学， 45，第499-518页。

斯特劳森，G.，1994. 心灵现实。 麻省理工学院出版社。

斯特劳森，G.，2006年。现实主义一元论：为什么物理主义蕴含泛心论。意识研究杂志，13，第3-31页。

萨默菲尔德，C.，2023. 自然通用智能：理解大脑如何帮助我们

构建人工智能。牛津大学出版社。

萨顿，R.，与巴托，A.，2018. 强化学习 （第2版）。麻省理工学院出版社。

Sytsma, J., 2014. 意识的归因。 威利跨学科评论：认知科学，5(6), 第635-648页。

汤普森，E.，2005年。感觉运动主观性和体验的具身方法。现象学与认知科学，4(4)，第407-427页。

汤普森，E.，2007.生命中的心智：生物学、现象学与心灵科学。哈佛大学出版社。

托皮兰，R.，德弗雷塔斯，D.，霍尔，J.，沙泽尔，N.，库尔什雷什塔，A.，程，H. T.，金，A.，博斯，T.，贝克，L.，杜，Y.，李，Y.，李，H.，郑，H. S.，加法乌里，A.，梅内加利，M.，黄，Y.，克里昆，M.，列皮欣，D.，秦，J.，……乐，Q. 2022. LaMDA：用于对话应用的语言模型。arXiv:2201.08239。

Tishby, N., Pereira, F. C., & Bialek, W., 2000. 信息瓶颈方法。 arXiv:physics/000 Todoro4057. v, E., & Jordan, M. I., 2002. 最优反馈控制作为运动协调理论。自然神经科学， 5(11), 文章11。

托诺尼，G.，& 科赫，C.，2015。意识：这里、那里和无处不在？ 皇家学会B篇哲学事务：生物科学， 370，20140167。

特鲁埃，S. & 特鲁希略 & J. C. M.，1999。基于特征的注意影响猕猴视觉皮层中运动处理的增益。 自然，399(6736)，第575-579页。

土屋N、维尔克M、弗雷斯勒S、拉梅VAF，2015年。无报告范式：提取意识的真实神经相关物。认知科学趋势，19(12)，第757-770页。特克尔S，2011年。独处与相伴：为什么我们对技术期待更多，而对彼此的期待却更少。基础图书公司。

泰耶，M.，1995. 意识的十个问题：现象心智的表征理论。 麻省理工学院出版社。

Udell, D. B., & Schwitzgebel, E., 2021. 苏珊·施奈德提出的用于测试人工智能意识的实验：前景可观但存在缺陷。 意识研究杂志，28(5-6)，第121-144页。

范·弗格特，B.，达尼诺，B.，瓦塔克，D.，萨法伊，H.，潘泽里，S.，德哈内，S.，以及罗尔夫塞马，P. R.，2018年。意识报告的阈值：视觉皮层和额叶皮层中的信号丢失与反应偏差。科学，360(6388)，第537-542页。

范鲁伦，R.，2016年。感知周期。 认知科学趋势，20(10)，第723-735页。

范鲁伦，R.，& 金井，R.，2021。深度学习与全局工作空间理论。 神经科学趋势， 44，第692-704页。

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polo-sukhin, I., 2023. 注意力就是一切。 arXiv:1706.03762。

沃贝格，D.，马特勒，U.，海内克，A.，施密特，T.，&施瓦茨巴赫，J.，2003年。视觉感知与动作启动的不同时间进程。载于美国国家科学院院刊，100(10)，6275-6280。

韦布，T. W.，& 格拉齐亚诺，M. S. A.，2015。注意模式理论：主观意识的一种机制性解释。 心理学前沿，6.

怀特，C. J.，2019。将全局神经工作空间整合到预测处理框架中：迈向一种工作假设。 意识与认知， 73，102763。

威尔逊，B.A.，巴德利，A.D.，卡普尔，N.，1995年。单纯疱疹病毒性脑炎后一名专业音乐家出现重度失忆症。临床与实验神经心理学杂志，17(5)，第668-681页。

威尔特森，A. I.，& 格拉齐亚诺，M. S.，2021。神经网络智能体中的注意力模式理论：利用注意力的描述性模型控制视觉空间注意力。美国国家科学院院刊， 118，e2102421118。

吴，P.，埃斯孔特雷拉，A.，哈夫纳，D.，阿贝勒，P.，以及戈德堡，K.，2023年。DayDreamer：用于物理机器人学习的世界模型。载于 第6届机器人学习大会论文集，2226-2240。

Yaron, I., Melloni, L., Pitts, M.，& Mudrik, L., 2022。用于分析和比较意识理论实证研究的ConTraSt数据库。 自然·人类行为，6(4)，第593-604页。

扎多尔，A.，埃斯科拉，S.，理查兹，B.，厄尔韦茨基，B.，本吉奥，Y.，博阿亨，K.，博特维尼克，M.，奇克洛夫斯基，D.，丘吉兰德，A.，克洛帕斯，C.，迪卡洛，J.，冈古利，S.，霍金斯，J.，科尔丁，K.，库拉科夫，A.，勒孔，Y.，利利克拉普，T.，马布尔通，A.，奥尔绍森，B.，.....曹，D.，2023。迈向下一代人工智能：催化神经AI革命。 arXiv:2210.08340。arXiv。泽基，S.，& 巴特尔斯，A.，1998。视觉系统的自主性与意识视觉的模块化。 伦敦皇家学会哲学事务：生物科学，353(1377)，1911-1914。

庄，C.，严，S.，纳耶比，A.，施林普夫，M.，弗兰克，M. C.，迪卡洛，J. J.，& 亚明斯，D. L. K.，2021。腹侧视觉通路的无监督神经网络模型。美国国家科学院院刊，118(3)，e2014196118。

兹洛托夫斯基，J.，隅冈，H.，西尾，S.，格拉斯，D.，巴特内克，C.，及石黑，H.，2015年，诡异谷的持续性：重复互动与机器人态度对其感知的影响。 心理学前沿， 6。